

UNIVERSITÀ
DI TORINO

Università degli Studi di Torino

Corso di Laurea in Informatica

MultiEMit: il ruolo della multimodalità e del contesto nel riconoscimento automatico di emozioni e ironia in social media italiani

Tesi di Laurea Magistrale

Relatrice
Viviana Patti

Correlatore
Oscar Araque

Correlatore
Daniel Russo

Candidato
Andrea Luparia
916384

Anno Accademico 2024/2025

Dichiarazione di originalità

Dichiaro di essere responsabile del contenuto dell'elaborato che presento al fine del conseguimento del titolo, di non avere plagiato in tutto o in parte il lavoro prodotto da altri e di aver citato le fonti originali in modo congruente alle normative vigenti in materia di plagio e di diritto d'autore. Sono inoltre consapevole che nel caso la mia dichiarazione risultasse mendace, potrei incorrere nelle sanzioni previste dalla legge e la mia ammissione alla prova finale potrebbe essere negata.

Dichiarazione di uno di AI Generativa

Durante la preparazione di questo lavoro, gli autori hanno usato Gemini per: pianificare il lavoro, migliorare lo stile di scrittura e controllare la grammatica. Dopo aver usato questi servizi, gli autori hanno ricontrollato e modificato i contenuti come necessario e si prendono piena responsabilitá per la publicazione del contenuto.

Avvertenza sui contenuti. Questa tesi include esempi di post sui social media tratti dal dataset MultiEMit che potrebbero contenere un linguaggio offensivo, essere politicamente connotati o avere contenuti disturbanti per alcuni lettori. Questi esempi sono riprodotti esclusivamente a scopo di analisi scientifica.

Ringraziamenti

Prima della lettura, vorrei dedicare un momento per ringraziare le persone che mi hanno accompagnato in questo percorso di laurea magistrale e progetto di tesi.

Il primo grazie va alla mia relatrice, Viviana Patti, non solo per avermi permesso di iniziare questo progetto di tesi, ma anche per avermi dato la spinta e l'opportunità di vivere l'esperienza Erasmus a Madrid.

Ringrazio di cuore l'Universidad Politécnica de Madrid per l'accoglienza. Un grazie speciale va a Oscar che è stato un vero punto di riferimento: mi hai fatto sentire a casa a chilometri di distanza e la tua guida nei primi mesi di sviluppo del progetto è stata preziosissima. I tre mesi a Madrid sono stati di sicuro indimenticabili.

Voglio esprimere la mia riconoscenza anche a Daniel. Grazie per aver sia contribuito alla creazione del dataset e per avermi aiutato tantissimo a svolgere gli esperimenti. Scusami ancora per aver creato la catena di mail piú lunga della storia.

Infine, le parole non basterebbero per ringraziare la mia famiglia. Mi siete stati sempre stati vicini e i primi a tendermi la mano nei momenti di bisogno. Grazie per avermi supportato e sopportato in questi anni di studio. Non ce l'avrei mai fatta senza di voi.

Abstract

Comprendere le reali emozioni degli utenti sui social media richiede oggi di superare i limiti della semplice analisi testuale. Spesso, infatti, immagini e meme completano o capovolgono il significato delle parole, rendendo i classici modelli unimodali inefficaci o fuorvianti di fronte a costrutti complessi come l'ironia.

Per affrontare questa problematica, in questo lavoro di tesi viene introdotto **MultiEMit**, un dataset multimodale in lingua italiana estratto da Twitter e Instagram, collezionato con l'obiettivo di monitorare le emozioni dei telespettatori sui social media, a partire ai contenuti generati da utenti che animano il dibattito online commentando programmi televisivi di vario genere. Il corpus si distingue per l'applicazione di un profondo schema di annotazione multi-livello che copre emozioni - secondo il modello delle emozioni di Plutchik - ironia, offensività, target e relazione semiotica tra testo e immagine.

Per valutare l'impatto del contesto visivo sul task di Riconoscimento di Emozioni e Ironia dai testi, sono stati confrontati modelli basati su architetture a Transformer allenati sul nuovo dataset proposto. In particolare la sperimentazione ha previsto lo sviluppo di un'architettura composta da due encoders, uno testuale e uno visivo, messa a confronto con i moderni Large Multimodal Models generativi (Pixtral). Sebbene l'integrazione dell'immagine migliori complessivamente le capacità predittive dei modelli, il fattore decisivo si è rivelato l'introduzione del *correlation prompting*, che ha permesso di fornire esplicitamente ai modelli la conoscenza statistica a priori delle relazioni tra etichette, ad esempio, il forte legame tra sarcasmo, disgusto e divergenza visiva.

In conclusione, lo studio dimostra che per rilevare lo stato d'animo degli utenti online in termini di emozioni l'analisi testuale isolata è insufficiente: l'integrazione del contesto visivo, unita alla capacità di fornire al modello le correlazioni logiche di fenomeni complessi (come ironia o odio), rappresenta un requisito indispensabile.

Abstract

Understanding users' true emotions on social media today requires overcoming the limitations of simple textual analysis. Images and memes often complement or subvert the meaning of words, rendering classic unimodal models ineffective or misleading when dealing with complex constructs such as irony.

To address this issue, this thesis introduces **MultiEMit**, an Italian multimodal dataset extracted from Twitter and Instagram. It was collected with the aim of monitoring viewers' emotions on social media, based on user-generated content that drives online discussions about various television programs. The corpus stands out for its application of a comprehensive multi-level annotation scheme covering emotions—based on Plutchik's emotion model—irony, offensiveness, targets, and the semiotic relationship between text and image.

To evaluate the impact of visual context on the Emotion and Irony Recognition task, models based on Transformer architectures trained on the newly proposed dataset were compared. Specifically, the experiments involved the development of an architecture comprising two encoders, one textual and one visual, which was then compared against modern generative Large Multimodal Models (Pixtral). Although image integration generally improves the overall predictive capabilities of the models, the decisive factor proved to be the introduction of *correlation prompting*. This technique allowed explicitly providing the models with a priori statistical knowledge of the relationships between labels, such as the strong link between sarcasm, disgust, and visual divergence.

In conclusion, this study demonstrates that relying solely on isolated textual analysis is insufficient for detecting the emotional state of online users. Integrating visual context, coupled with the ability to provide the model with logical correlations of complex phenomena (such as irony or hate speech), represents an indispensable requirement.

Indice

Introduzione **x**

1 Contesto Teorico **1**

1.1 Teoria delle Emozioni 1

1.2 Teoria dell'Ironia e del Sarcasmo 5

1.3 Teoria delle Relazioni Semiotiche tra testo e immagine 7

1.4 Dagli approcci tradizionali ai Transformer 10

1.5 Il Transformer 11

1.5.1 L'Encoder e il Decoder 13

1.5.2 Tre famiglie di modelli 13

1.6 I Modelli Utilizzati: BERT e Pixtral 14

1.6.1 BERT: Bidirectional Encoder Representations from Transformers 14

1.6.2 Mistral e Pixtral: encoder visivo e decoder testuale . . 15

2 Stato dell'Arte **16**

2.1 BRIGHTER e le lingue poco rappresentate 16

2.2 Emotion Detection in italiano: risorse, modelli e shared tasks 17

2.2.1 FEEL-IT 17

2.2.2 MultiEmotions-It: Un approccio multi-livello a Emozioni e Sarcasmo 18

2.2.3 EMit (EVALITA 2023 18

2.3 Irony Detection in italiano 19

2.3.1 IronITA (EVALITA 2018) 19

3 Il Dataset MultiEMit **21**

3.1 Dominio dei Dati 21
3.2 Metodologia e Schema di Annotazione 22
3.2.1 Ambiguità e Accordo tra Annotatori 24
3.3 Distribuzione del Dataset 25
3.4 Analisi delle Correlazioni 28
3.4.1 Correlazioni dal punto di vista delle Emozioni 29
3.4.2 Correlazioni dal punto di vista dell'Ironia 30
3.4.3 Correlazioni dal punto di vista delle Relazioni Semiotiche 32

4 Design sperimentale **33**
4.1 Definizione dei Task e Metriche 33
4.1.1 Task di classificazione 33
4.1.2 Metriche di valutazione 34
4.2 Esperimenti con BERT 35
4.2.1 Modelli pre-addestrati 36
4.2.2 Riconoscimento delle emozioni 36
4.2.3 Riconoscimento dell'ironia 37
4.2.4 Riconoscimento della relazione semiotica 37
4.2.5 Addestramento con correlazioni 37
4.2.6 Parametri di addestramento e split dei dati 38
4.3 Architettura multimodale Dual-Encoder 39
4.3.1 Encoder testuale e visivo 39
4.3.2 Fusione e classificazione 40
4.4 Esperimenti con Pixtral 41
4.4.1 Strategie di Prompting 42
4.4.2 Strategie Zero-Shot e Few-Shot 44
4.4.3 Fine-tuning di Pixtral 50
4.4.4 Addestramento tramite LoRA (Low-Rank Adaptation) 51

5 Risultati Sperimentali e Valutazione **52**
5.1 Setup Sperimentale 52
5.2 Riconoscimento delle Emozioni 53

5.2.1 Evoluzione delle Baseline Testuali e Codifica delle Emozioni . . . 53
5.2.2 Emozioni Text-only vs Dual-Encoder . . . 57
5.2.3 Esperimenti Multimodali con Pixtral . . . 58
5.3 Rilevamento dell'Ironia . . . 59
5.3.1 Ironia Text-only vs Dual-Encoder . . . 59
5.3.2 Esperimenti Multimodali con Pixtral . . . 61
5.4 Riconoscimento delle Relazioni Semiotiche . . . 62
5.4.1 Relazioni Testuale vs Dual-Encoder . . . 62
5.4.2 Esperimenti Multimodali con Pixtral . . . 63
5.5 Discussione dei Risultati e Limiti . . . 65

6 Analisi dei Risultati ed Esperimenti **66**
6.1 Analisi sui Subset Relazionali . . . 66
6.1.1 Classificazione di Emozioni e Ironia nei Subsets . . . 67
6.1.2 Analisi sulla Relation Detection nei diversi Modelli . . 68
6.2 Allucinazioni Generative e Truncation Parameter in Pixtral . 70
6.3 Esperimento con Image Captioning . . . 73

Conclusione **77**

Appendice **79**

Bibliografia **98**

Introduzione

Ogni giorno, milioni di persone commentano sui social media ciò che vedono in televisione. Questi commenti sono spesso brevi, informali e accompagnati da immagini (meme, screenshot o foto) che arricchiscono o ribaltano completamente il significato del testo. Capire le emozioni espresse in questi post è fondamentale per il monitoraggio delle opinioni del pubblico e l'analisi del gradimento televisivo. Tuttavia, riconoscere automaticamente sfumature complesse come le emozioni e l'ironia rappresenta una sfida ardua per l'intelligenza artificiale, specialmente quando si analizza esclusivamente il testo.

Il lavoro oggetto di questa tesi nasce da un'osservazione emersa durante la fase di costruzione di un corpus annotato di post multimodali costituiti da testi accompagnati da immagini, estratti da social media. Sottoponendo agli annotatori umani gli stessi post in due fasi distinte (prima potendo leggere solo il testo, poi potendo osservare anche l'immagine di riferimento), abbiamo notato un netto incremento nell'accordo sulle etichette assegnate durante la seconda fase. L'informazione visiva, infatti, spesso fornisce il contesto necessario per comprendere il vero significato del messaggio. Da questa osservazione scaturisce la domanda centrale della nostra ricerca: se le immagini sono determinanti per la comprensione umana, possono risultare altrettanto decisive per i modelli di classificazione automatica?

Per rispondere a questo interrogativo, abbiamo strutturato il nostro studio attorno a tre domande di ricerca (Research Questions) principali:

- **RQ1**: L'integrazione del contesto visivo migliora le prestazioni del riconoscimento emotivo e dell'ironia rispetto ai modelli puramente testuali?
- **RQ2**: Sfruttare le correlazioni statistiche tra le etichette (ad esempio, il legame ricorrente tra ironia e gioia o odio e rabbia) migliora l'efficacia delle predizioni dei modelli?
- **RQ3**: Come si confrontano modelli specializzati e leggeri, come Encoders basati su BERT e VIT, con i moderni modelli linguistici mul-

timodali di grandi dimensioni, come Pixtral, su task così specifici?

Per indagare questi aspetti, abbiamo sviluppato e analizzato **MultiEMit**, un dataset multimodale estratto da Twitter (ora X) e Instagram, focalizzato sui programmi televisivi italiani. La peculiarità di MultiEMit risiede nella sua complessa annotazione multi-livello, che classifica ogni post rispetto a emozioni, ironia, offensività, target e relazione semiotica tra testo e immagine. Su questo dataset abbiamo sviluppato e confrontato diversi modelli di classificazione: dopo avere creato una serie di baseline puramente testuali allenando modelli BERT, è stata valutata l'aggiunta di un encoder visivo per fondere le due modalità (testi e immagine) e, infine, è stata proposta una sperimentazione mirata a sfruttare le correlazioni tra i diversi livelli di annotazione, per inserire negli input dei modelli piú informazioni riguardo ai post.

L'elaborato è organizzato come segue:

- Il **Capitolo 1** introduce il contesto teorico, presentando le teorie sulle emozioni, l'ironia e le architetture di base dei modelli a Transformers.
- Il **Capitolo 2** presenta lo stato dell'arte nel riconoscimento delle emozioni e dell'ironia per la lingua italiana.
- Il **Capitolo 3** descrive la genesi del dataset MultiEMit, il suo schema di annotazione multi-livello e l'analisi delle correlazioni tra le etichette.
- Il **Capitolo 4** illustra il design sperimentale, definendo i task e spiegando l'architettura dei modelli proposti, dalle baseline testuali al Dual-Encoder, fino al prompting di Pixtral.
- Il **Capitolo 5** riporta i risultati sperimentali e la loro valutazione per ciascuno dei task affrontati.
- Il **Capitolo 6** approfondisce i risultati ottenuti, analizzando il comportamento dei modelli su subset specifici e indagando fenomeni come le allucinazioni generative.

Capitolo 1

Contesto Teorico

La Sentiment Analysis (SA) è un campo dell'elaborazione del linguaggio naturale (NLP) che si occupa di identificare e classificare automaticamente il tono emotivo espresso in un testo in positivo, negativo o neutro [1]. Questo approccio, pur essendo efficace per applicazioni come il monitoraggio della reputazione di un brand, presenta limiti evidenti quando si lavora con contenuti ricchi di sfumature. Due stati emotivi profondamente diversi come la rabbia e la tristezza vengono entrambi etichettati come "negativi", perdendo informazione fondamentale per comprendere il reale stato d'animo dell'autore.

L'Emotion Detection (ED) supera questo limite adottando una classificazione a grana fine: invece di una semplice polarità, si identificano le emozioni specifiche espresse nel testo. Questa granularità diventa indispensabile nel contesto della Social TV [2], in cui i telespettatori interagiscono con programmi televisivi attraverso post sui social contenenti determinati hashtags (e.g., #propagandalive), i commenti sono spesso ironici, sarcastici o volutamente ambigui. Un tweet che esprime disgusto verso un concorrente e uno che esprime tristezza per la sua eliminazione richiedono risposte di analisi completamente diverse, nonostante entrambi risulterebbero esprimere un sentiment "negativo" in un'ottica di semplice analisi della polarità del sentiment.

1.1 Teoria delle Emozioni

Per la classificazione delle emozioni questo lavoro fa riferimento alle categorie di emozioni previste dalla teoria psico-evoluzionista dello psicologo Robert Plutchik [3, 4]. Secondo Plutchik, le emozioni non sono semplici stati d'animo, ma risposte adattive sviluppate nel corso dell'evoluzione per garantire la sopravvivenza. Ogni emozione primaria corrisponde a un comportamento

fondamentale: la paura innesca la fuga dal pericolo, la rabbia prepara alla lotta, il disgusto allontana da sostanze nocive. In questa prospettiva, l'emozione è una catena di eventi che parte da uno stimolo ambientale e termina con un impulso all'azione.

Il cuore della teoria è la cosiddetta **Ruota delle Emozioni** (Figura 1.2), un modello che organizza le emozioni in base a similarità e intensità. Plutchik individua otto emozioni primarie, disposte a coppie di opposti:

- *Gioia* e *Tristezza*
- *Fiducia* e *Disgusto*
- *Paura* e *Rabbia*
- *Sorpresa* e *Anticipazione*

La ruota originale di Plutchik è in realtà un modello tridimensionale (Figura 1.1): oltre alla posizione circolare (che indica similarità), ogni emozione varia anche in intensità lungo l'asse verticale. Ad esempio, la *Rabbia* può scalare verso l'*Irritazione* (meno intensa) o verso la *Collera* (più intensa). Nel nostro schema di annotazione non utilizziamo questa dimensione di intensità, limitandoci alle otto emozioni primarie nel loro livello base.

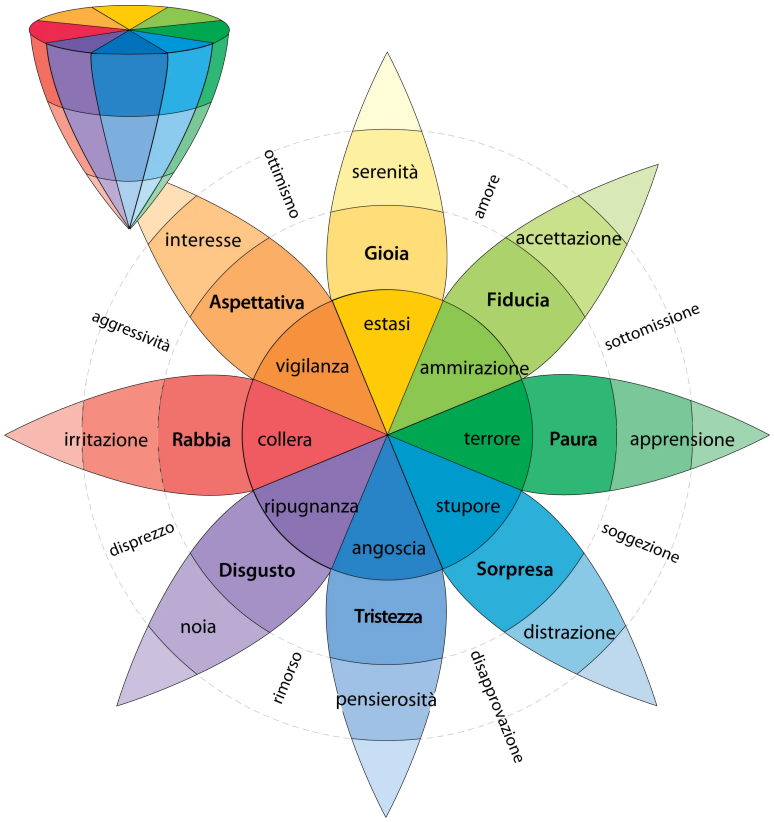


Figura 1.1: Modello tridimensionale delle emozioni di Plutchik. L'asse verticale rappresenta l'intensità: le emozioni più intense (es. Collera) si trovano in alto, quelle più attenuate (es. Irritazione) in basso.

Un aspetto centrale della teoria riguarda la combinazione delle emozioni primarie in emozioni più complesse, dette **diadi**. Plutchik distingue tre livelli di combinazione in base alla distanza delle emozioni sulla ruota:

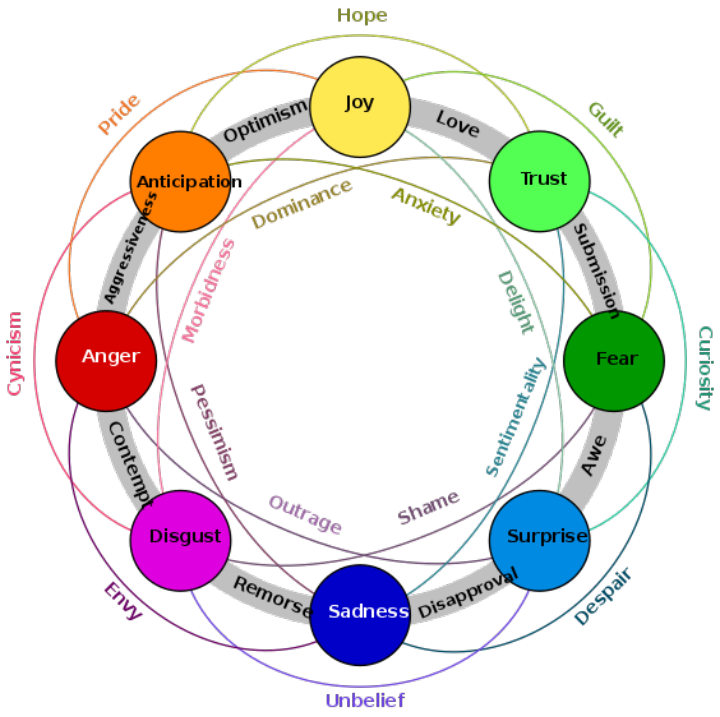


Figura 1.2: Ruota delle emozioni di Plutchik e relative combinazioni (diadi).

- **Diadi primarie:** combinazioni di emozioni adiacenti. Producono sentimenti comuni e facilmente riconoscibili:
  - *Gioia + Fiducia = Amore*
  - *Fiducia + Paura = Sottomissione*
  - *Anticipazione + Gioia = Ottimismo*
- **Diadi secondarie:** combinazioni di emozioni separate da una posizione. Generano sentimenti più sfumati:
  - *Gioia + Paura = Senso di colpa*
  - *Tristezza + Rabbia = Invidia*
  - *Disgusto + Paura = Vergogna*
- **Diadi terziarie:** combinazioni di emozioni separate da due posizioni. Producono stati emotivi rari e complessi:
  - *Gioia + Sorpresa = Delizia*
  - *Anticipazione + Paura = Ansia*

– *Tristezza + Disgusto = Rimorso*

Nel nostro schema di annotazione, ideato per l'analisi di testi generati dagli utenti, abbiamo adottato le otto emozioni primarie di Plutchik integrandole con due etichette aggiuntive. La prima è *Amore*, che rappresenta una delle diadi più frequenti e rilevanti nei commenti social; la seconda è *Neutro*, un'etichetta fondamentale per catalogare i casi in cui non traspare alcuna emozione esplicita. Questa scelta ci ha permesso di mantenere un buon compromesso tra granularità analitica e praticità del processo di annotazione.

1.2 Teoria dell'Ironia e del Sarcasmo

L'ironia e il sarcasmo sono fenomeni linguistici complessi da modellare computazionalmente. Sebbene nel linguaggio comune vengano spesso usati come sinonimi, nel dominio analitico è necessario distinguerli: l'**ironia** opera un ribaltamento del significato per produrre un'incongruenza, spesso con intento ludico o di critica lieve; il **sarcasmo** è invece una forma di ironia amara e pungente, con intento esplicitamente offensivo o denigratorio[1].

Per comprendere come l'ironia venga costruita nei social network, facciamo riferimento a due teorie principali descritte da Gentile [5]:

- **Interpretazione classica (contraddizione):** L'ironia nasce dalla contraddizione tra il significato letterale del testo e l'intento reale dell'autore. Nei commenti social, questa contraddizione è tipicamente *pragmatica*: per coglierla, il lettore deve condividere un *common ground* con l'autore. Nel contesto della Social TV, chi commenta dà per scontato che gli altri spettatori abbiano visto la trasmissione e possano quindi inferire il vero significato della battuta.
- **Teoria ecoica:** L'ironia non nasce da una contraddizione diretta, ma dalla *menzione indiretta* di un pensiero altrui. L'autore cita qualcosa per prenderne le distanze o esprimere dissenso. Sui social network questa forma è molto diffusa tramite *meme* ed è spesso incentivata dalle emittenti stesse, che pubblicano in tempo reale citazioni paradossali dei concorrenti per alimentare il dibattito ironico. Un esempio in Figura 1.3

[1] `https://www.treccani.it/vocabolario/sarcasmo/`



Figura 1.3: Esempio di ironia multimodale ecoica: il testo cita una frase di Enzo Miccio in cui chiede di poter avere un piatto da portata per mangiare quando invece si trovano in una situazione in cui è impossibile averlo. L'autore prende in giro Miccio citandolo e facendogli quindi da eco.

Un esempio di ironia classica dal nostro corpus:

"che bel rapporto padre e figlia.....#pechinoexpress"

Senza conoscere il contesto della puntata, il testo sembra un complimento sincero. In realtà, chi ha seguito la trasmissione sa che i due concorrenti avevano avuto un litigio e il commento esprime l'esatto contrario di ciò che dice letteralmente.

Nel dato multimodale, l'ironia si manifesta spesso attraverso la **relazione divergente** tra testo e immagine. Consideriamo l'esempio in Figura 1.4:

"199 gradini dopo, costantino che aspetta le coppie #pechinoexpress"



Figura 1.4: Esempio di ironia multimodale: il testo descrive una scena di Pechino Express, ma l'immagine mostra Sanremo. L'accostamento genera un significato ironico assente in entrambe le componenti prese singolarmente.

Il testo fa riferimento al conduttore Costantino della Gherardesca che, in cima a una lunga scalinata, attende i concorrenti per spuntarli da un libretto rosso che usa per registrare gli arrivi dei partecipanti. L'immagine però non mostra quella scena: raffigura invece Antonella Clerici e Amadeus sul palco di Sanremo di fronte a un libro comicamente gigante. L'ironia nasce dal paragone implicito tra il libretto di Costantino e quel libro sproporzionato, un accostamento comprensibile solo combinando testo e immagine.

Questa dinamica si collega direttamente alla tassonomia delle relazioni semiotiche che presentiamo nella sezione successiva: molti post ironici presentano una relazione *Divergente* tra testo e immagine, rendendo l'analisi visiva indispensabile per una corretta interpretazione del sentiment.

1.3 Teoria delle Relazioni Semiotiche tra testo e immagine

Nei social media, testo e immagine non sono entità separate: interagiscono per costruire il significato complessivo del messaggio. Questa interazione è particolarmente evidente nel contesto della Social TV, dove gli utenti commentano i programmi accompagnando i propri post con screenshot, meme o immagini di repertorio.

Per classificare formalmente il rapporto tra componente testuale e visiva, adottiamo la tassonomia proposta da Kruk et al. [6] insieme a Dan Juraf-

sky, che distingue tre categorie di relazione semiotica: *parallela*, *additiva* e *divergente*.

Relazione Parallela. Il testo e l'immagine veicolano le stesse informazioni in modo indipendente. Il messaggio sarebbe comprensibile osservando una sola delle due modalità. Un esempio dal nostro corpus (Figura 1.5):

"Moscow Mule e #propagandalive''



Figura 1.5: Esempio di relazione **Parallela**: testo e immagine veicolano le stesse informazioni (un Moscow Mule durante Propaganda Live).

Il testo nomina un cocktail e il programma televisivo; l'immagine mostra esattamente un Moscow Mule con Propaganda Live sullo sfondo. Non si crea alcun significato aggiuntivo dalla combinazione: le due componenti si limitano a confermarsi a vicenda.

Relazione Additiva. Le due modalità si arricchiscono reciprocamente. L'immagine fornisce un contesto visivo che il testo non specifica, oppure il

testo aggiunge informazioni assenti nell'immagine. La combinazione genera un messaggio più ricco delle singole parti. Un esempio (Figura 1.6):

"montaggio imbarazzante...ma tifiamo per voi!!!!!!''



Figura 1.6: Esempio di relazione **Additiva**: il testo aggiunge sostegno emotivo all'immagine dei concorrenti Annandrea Vitrano e Claudio Casisa, nonostante la critica verso il montaggio.

L'immagine mostra i concorrenti Annandrea Vitrano e Claudio Casisa in posa che indicano la telecamera. Il testo aggiunge il sostegno dell'autore verso di loro, ma allo stesso tempo critica il montaggio usato per presentare la coppia in televisione. Senza il testo, l'immagine sarebbe solo una foto di due persone con facce strane che guardano la telecamera; senza l'immagine, non sapremmo né chi tifa l'autore, né della sua critica verso la regia.

Relazione Divergente. Il testo e l'immagine sembrano contrastare o non avere un legame immediato. La loro giustapposizione crea però un nuovo significato, spesso ironico. Questa è la categoria più interessante per l'analisi

del sentiment, perché senza l'immagine il messaggio verrebbe frainteso. Un esempio (Figura 1.7):

"Toninelli: 'Grazie a #propagandalive' La reazione di Zoro:''



Figura 1.7: Esempio di relazione **Divergente**: il testo cita ironicamente un politico, l'immagine mostra un calciatore come metafora della "reazione'' del conduttore. Il significato emerge solo dalla combinazione.

Il testo cita ironicamente Danilo Toninelli, politico del Movimento 5 Stelle che nel periodo della puntata era frequente bersaglio di satira. L'immagine però non mostra né Toninelli né il conduttore Diego Bianchi (Zoro): raffigura invece il calciatore Giorgio Chiellini con un'espressione di soddisfazione beffarda. L'accostamento segue il classico schema del meme: l'immagine rappresenta metaforicamente la "reazione di Zoro'' ai ringraziamenti paradossali del politico. Il significato ironico emerge solo dalla combinazione delle due componenti.

1.4 Dagli approcci tradizionali ai Transformer

Fra i sistemi di classificazione del sentiment nel testo più semplici possiamo annoverare quelli basavati su dizionari di parole etichettate secondo la loro connotazione affettiva, in termini di sentiment polarity, noti come *lessici di sentiment (sentiment lexicons)* [1, 7]. L'idea è semplice: contare quante parole "positive'' e "negative'' compaiono in un testo per determinarne la polarità. Questi approcci, pur essendo interpretabili e veloci, presentano limiti strutturali: non gestiscono il contesto ("non è male'' può venire classificato come negativo per la presenza di "male''), falliscono sistematicamente in presenza di ironia e richiedono la costruzione manuale di dizionari per ogni lingua e dominio.

L'introduzione di approcci basati su tecniche di Machine Learning supervisionato ha migliorato le prestazioni, permettendo ai modelli di apprendere pattern direttamente dai dati. Tuttavia, la vera svolta è arrivata con le architetture neurali profonde e in particolare con il meccanismo di *Self-Attention*, che ha dato origine ai Transformer.

1.5 Il Transformer

Prima dell'arrivo dei Transformer, l'elaborazione del linguaggio naturale si basava su modelli sequenziali, come le Recurrent Neural Networks (RNN) [8] e le Long Short-Term Memory (LSTM) [9]. Questi modelli elaborano il testo una parola alla volta, da sinistra a destra. Questo approccio passo-passo presenta due criticità intrinseche. La prima è la lentezza dell'addestramento: l'elaborazione di una parola dipende dal completamento della precedente, rendendo impossibile parallelizzare i calcoli. La seconda criticità è il problema della memoria a lungo termine. Nelle frasi lunghe, le informazioni iniziali si degradano man mano che la rete elabora i termini successivi, facendo perdere al modello il contesto globale.

Per superare questi limiti strutturali, è stato introdotto il modello **Transformer**[10], illustrato in Figura 1.8 . Questa architettura abbandona l'elaborazione sequenziale a favore di un approccio simultaneo.

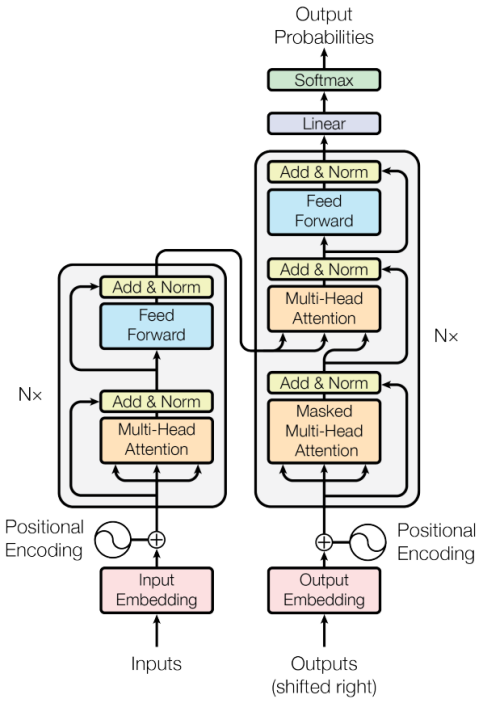


Figura 1.8: Architettura originale del Transformer, composta da un blocco Encoder (a sinistra) e un blocco Decoder (a destra). Fonte: Vaswani et al. [10].

Come osserviamo nello schema, l'architettura originale si compone di un blocco Encoder e un blocco Decoder. Il vero motore di questa struttura risiede nel meccanismo di **Self-Attention**. Invece di far passare l'informazione linearmente, questo meccanismo calcola una connessione matematica diretta tra ogni parola e tutte le altre parole della frase, simultaneamente. Di conseguenza, la distanza tra due termini logicamente connessi si riduce sempre a un singolo calcolo, annullando il problema della degradazione della memoria.

Ad esempio, nella frase "La pianta è stata annaffiata", il modello crea un collegamento diretto tra "pianta" e "annaffiata". Riesce quindi a comprendere immediatamente che si tratta di un vegetale (e non di una mappa), indipendentemente dalla lunghezza del testo che separa le due parole. Inoltre, potendo processare l'intera frase in parallelo tramite calcoli matriciali, i tempi di addestramento si riducono drasticamente. Questa efficienza ha permesso lo sviluppo degli attuali Large Language Models (LLMs).

Tuttavia, analizzando criticamente questo approccio, notiamo che rinunciare alla sequenzialità introduce un nuovo ostacolo. Elaborando l'intera frase simultaneamente, il modello perde l'informazione sull'ordine delle parole.

Senza questa indicazione, il Transformer confonderebbe frasi sintatticamente diverse ma composte dagli stessi termini (ad esempio, "il cane morde l'uomo" rispetto a "l'uomo morde il cane").

Per risolvere questa problematica, l'architettura utilizza il **Positional Encoding**. Vengono generati dei vettori numerici che si sommano direttamente alle rappresentazioni iniziali delle parole (gli *embedding*) prima dell'elaborazione nel blocco Encoder. Questi vettori iniettano in ogni parola una coordinata spaziale esatta. In questo modo, quando il Self-Attention calcola i collegamenti, valuta non solo l'affinità semantica, ma anche la posizione relativa dei termini, preservando la sintassi originale in modo altamente efficiente.

1.5.1 L'Encoder e il Decoder

Il Transformer originale (Figura 1.8) era pensato per la traduzione automatica e si componeva di due blocchi distinti:

- **Encoder (il lettore):** Prende il testo in input e lo "comprende". Analizza la frase guardando il contesto di ogni parola sia a destra che a sinistra (*bidirezionale*) e produce una rappresentazione matematica densa di significato, chiamata *embedding*.
- **Decoder (lo scrittore):** Riceve la comprensione dell'Encoder e genera l'output (ad esempio, la frase tradotta). Lavora in modo *autoregressivo*: produce una parola, guarda cosa ha appena scritto, e genera la successiva, finché non ha terminato.

A partire da questa struttura, i ricercatori hanno scoperto che potevano usare solo una delle due componenti a seconda del task da svolgere. Sono così nate tre famiglie di modelli.

1.5.2 Tre famiglie di modelli

Modelli Encoder-Decoder. Mantengono l'architettura originale completa. L'Encoder legge e comprende l'input, il Decoder genera un output strutturato. Esempi noti sono BART [11] e T5 [12]. Sono ideali per task come la **traduzione automatica** e il **riassunto di testi** (summarization), dove serve sia comprendere un testo lungo sia produrne uno nuovo.

Modelli Solo-Encoder. Eliminano il Decoder e si concentrano esclusivamente sulla comprensione. Leggono il testo in entrambe le direzioni e spesso vengono addestrati nascondendo una parola in una frase e il modello deve

indovinarla dal contesto circostante (*Masked Language Modeling*). Questi modelli eccellono nei task di **classificazione**: analisi del sentiment, rilevamento di spam, estrazione di entità (trovare nomi di persona o luoghi in un documento). Non generano testo, ma sono campioni nel capire le sfumature di significato di un testo esistente.

Modelli Solo-Decoder. Eliminano l'Encoder e si concentrano sulla generazione. Leggono il testo solo da sinistra a destra e il loro unico obiettivo durante l'addestramento è prevedere la parola successiva (*Causal Language Modeling*). Avendo letto miliardi di testi durante il pre-training, questa semplice capacità predittiva li rende in grado di conversare, ragionare e scrivere testi coerenti [13]. Sono ideali per **chatbot**, **generazione di codice**, **scrittura creativa** e in generale per qualsiasi task in cui l'output è testo libero.

1.6 I Modelli Utilizzati: BERT e Pixtral

In questo lavoro confrontiamo due filosofie opposte: un modello Solo-Encoder specializzato tramite fine-tuning (BERT) e un modello Solo-Decoder multimodale usato in modalità zero-shot e few-shot (Pixtral).

1.6.1 BERT: Bidirectional Encoder Representations from Transformers

BERT [14] (Bidirectional Encoder Representations from Transformers), rilasciato da Google nel 2018, è il capostipite dei modelli Solo-Encoder. La sua caratteristica distintiva è la **bidirezionalità**: quando analizza una parola, considera contemporaneamente tutto ciò che viene prima e tutto ciò che viene dopo. Questo gli permette di cogliere sfumature di significato che un modello unidirezionale perderebbe.

BERT non genera testo: il suo compito è produrre rappresentazioni numeriche (*embeddings*) ricche di informazione semantica. Per utilizzarlo in un task specifico come la classificazione del sentiment, si aggiunge una piccola rete neurale in cima (la *classifier head*) e si effettua un **fine-tuning**: i pesi del modello vengono aggiornati su un dataset etichettato specifico per il task. Il risultato è un classificatore altamente accurato, ma rigido, che funziona solo per le classi su cui è stato addestrato.

In questo studio utilizziamo due varianti di BERT pre-addestrate per l'italiano:

- **FEEL-IT** [15]: specializzato per l'analisi del sentiment e delle emozioni in italiano.
- **UmBERTo** [16]: un modello BERT italiano allenato sul *Whole Word Masking*, ovvero sul task di predire una parola mancante all'interno di una frase (eg. Data la frase "La capitale d'Italia é <mask>" il modello restituisce <mask> = "Roma").

1.6.2 Mistral e Pixtral: encoder visivo e decoder testuale

I moderni **Large Language Models (LLMs)** come **Mistral** [17] seguono l'architettura Solo-Decoder. Il loro addestramento consiste nel prevedere la parola successiva su enormi quantità di testo. Da questa capacità apparentemente semplice emerge un comportamento sorprendente: i modelli imparano a ragionare, seguire istruzioni e risolvere problemi mai visti prima [18, 19].

Mistral 7B [2], rilasciato da Mistral AI nel 2023, è un esempio di efficienza: nonostante abbia "solo'' 7 miliardi di parametri (pochi rispetto ai giganti da 70-400 miliardi), utilizza tecniche di attenzione ottimizzate che gli permettono di elaborare testi lunghi con risorse limitate.

Pixtral [20], rilasciato nel 2024, rappresenta l'evoluzione multimodale di Mistral. Accanto al Decoder testuale, integra un **Vision Encoder**: un componente che "traduce'' le immagini nella stessa rappresentazione usata per il testo. Questo permette a Pixtral di "vedere'' le immagini allegate a un messaggio e di ragionare congiuntamente su testo e contenuto visivo, esattamente ciò che serve per analizzare i post multimodali dei social media.

L'approccio d'uso di Pixtral è opposto a quello di BERT: invece di fare fine-tuning, si sfrutta il **prompting**. Il modello riceve istruzioni in linguaggio naturale (ad esempio: "Analizza questo post e indica le emozioni presenti'') e può operare in diverse modalità: *zero-shot*, quando non riceve alcun esempio e deve inferire la risposta solo dalle istruzioni, oppure *few-shot*, quando gli vengono forniti alcuni esempi di input-output attesi [13]. In entrambi i casi, il modello sfrutta la conoscenza acquisita durante il pre-training. Questo secondo approccio è flessibile, permette al modelli di risolvere task nuovi senza riaddestramento, ma è meno preciso di un modello addestrato.

[2] `https://huggingface.co/mistralai/Mistral-7B-Instruct-v0.3`

Capitolo 2

Stato dell'Arte

In questa sezione viene presentata una rassegna di risorse e modelli per la rilevazione delle emozioni e dell'ironia nei social media, con particolare focus sulla lingua italiana.

2.1 BRIGHTER e le lingue poco rappresentate

La maggior parte delle risorse per l'Emotion Detection è disponibile esclusivamente in inglese. Questo sbilanciamento limita lo sviluppo di sistemi affidabili per altre lingue, costringendo i ricercatori a ripiegare su traduzioni automatiche o su modelli multilingue addestrati prevalentemente su dati anglofoni.

Il progetto BRIGHTER [21] (BRIdging the Gap in Human-Annotated Textual Emotion Recognition) affronta direttamente questo problema, proponendo una collezione di circa 100.000 istanze annotate manualmente in 28 lingue diverse, principalmente parlate in Africa, Asia, Europa dell'Est e America Latina. Lo schema di annotazione è *multi-label* e prevede sei emozioni di base di Ekman [22] (gioia, tristezza, rabbia, paura, sorpresa, disgusto) più una classe neutra; a ogni emozione rilevata viene inoltre associato un livello di intensità su una scala da 0 a 3.

A livello sperimentale, gli autori hanno valutato le prestazioni di diversi modelli multilingue e Large Language Models. I risultati mostrano come anche le architetture LLM più recenti fatichino a riconoscere correttamente le emozioni nei testi, specialmente per le lingue poco rappresentate. Emerge inoltre un dato interessante: i modelli ottengono punteggi nettamente migliori quando i prompt vengono formulati in inglese anziché nella lingua target.

Analizzando la composizione del corpus, emerge però un paradosso.

Nonostante la vocazione dichiarata verso le lingue "sotto-rappresentate", BRIGHTER include inglese, cinese, spagnolo, portoghese e tedesco tutte nella top 15 mondiale per numero di parlanti[1]. L'italiano, che si colloca al 32° posto, non trova invece spazio nel dataset e viene citato unicamente attraverso un riferimento a FEEL-IT [15].

Questa assenza in un progetto di respiro così ampio evidenzia come l'italiano rischi di rimanere ai margini della ricerca sull'Emotion Detection. Un divario che il corpus MultiEMit, presentato in questa tesi, si propone di colmare.

2.2 Emotion Detection in italiano: risorse, modelli e shared tasks

2.2.1 FEEL-IT

FEEL-IT [15] è un corpus creato presso l'Università Bocconi. É stato creato tramite un processo di annotazione interamente manuale: i due autori principali, entrambi madrelingua italiani con background in NLP, hanno etichettato ogni istanza.

Il corpus contiene 2.037 tweet raccolti monitorando i *trending topics* giornalieri tra il 20 agosto e il 12 ottobre 2020, ovvero gli argomenti più discussi. Questa strategia ha permesso di coprire domini molto diversi: dalla salute (`#covid19`, `#mascherina`) allo sport (`#F1`, `#Juventus`), dagli show televisivi (`#GFvip`, `#pomeriggio5`) alla politica (`#DiMaio`). Lo schema di annotazione prevede quattro emozioni di base secondo uno dei modelli dello psicologo Paul Ekman [23]: *rabbia* (912 istanze), *gioia* (728), *tristezza* (294) e *paura* (103). Come ci si può attendere in un dataset ecologico, la distribuzione è sbilanciata, con *rabbia* e *gioia* che costituiscono la maggioranza dei campioni.

A livello sperimentale, gli autori hanno valutato diversi approcci di classificazione. Il modello UmBERTo[2] fine-tuned ha ottenuto i risultati migliori. Un aspetto interessante è che FEEL-IT può essere utilizzato anche per la sentiment analysis, collassando *gioia* nella classe positiva e le altre emozioni nella classe negativa. In quest'ottica è stato testato sul benchmark italiano di sentiment analysis SENTIPOLC16 [24].

I modelli rilasciati pubblicamente[3] sono stati utilizzati come punto di partenza per i nostri esperimenti.

[1] `https://www.ethnologue.com/insights/ethnologue200/`

[2] `https://huggingface.co/Musixmatch/umberto-commoncrawl-cased-v1`

[3] `https://huggingface.co/MilaNLProc/feel-it-italian-sentiment`

2.2.2 MultiEmotions-It: Un approccio multi-livello a Emozioni e Sarcasmo

Un ulteriore e fondamentale passo avanti per l'analisi delle emozioni in lingua italiana è rappresentato da **MultiEmotions-It** [25]. Sviluppato nel 2020, questo dataset si discosta dai tradizionali corpora testuali concentrandosi su commenti estratti da YouTube e Facebook, specificamente in risposta a video musicali e spot pubblicitari. La vera innovazione di questa risorsa, tuttavia, risiede nella sua complessa struttura di annotazione multi-livello.

Invece di limitarsi a una singola etichetta, ogni commento all'interno del dataset è stato valutato manualmente da più annotatori su quattro dimensioni parallele: la pertinenza (il commento riguarda il post?), la polarità del *sentiment* (positivo, negativo o neutro), le emozioni e la presenza di sarcasmo. Per la categorizzazione emotiva, gli autori hanno scelto di adottare integralmente il framework teorico di Plutchik, etichettando i testi con le otto emozioni primarie: gioia, tristezza, paura, rabbia, fiducia, disgusto, sorpresa e anticipazione.

A livello sperimentale, il lavoro ha testato diverse architetture di classificazione. I risultati hanno confermato empiricamente una dinamica cruciale: mentre l'estrazione della polarità (positivo/negativo) raggiunge prestazioni solide, la classificazione a grana fine delle otto emozioni e, soprattutto, il rilevamento del sarcasmo rappresentano sfide computazionali estremamente ardue e soggette a forte ambiguità dovute alla complessità del task.

2.2.3 EMit (EVALITA 2023

Il corpus **EMit** (Emotions in Italian) [26] rappresenta il punto di riferimento più affine alla nostra ricerca. Sviluppato nell'ambito del progetto M.EMO.RAI [4] ed proposto nell'ambito dello *shared task* durante la campagna di valutazione EVALITA 2023, EMit raccoglie messaggi generati da utenti su Twitter e Instagram. Il dataset è composto da 5.966 post distribuiti su un ventaglio di programmi televisivi italiani diversi per genere e pubblico: dal *Festival di Sanremo* a *Don Matteo* o *Il Collegio*.

L'aspetto fondamentale di questo dataset rispetto al nostro elaborato è il suo schema di annotazione, progettato per catturare le dinamiche comunicative della Social TV. Similmente a MultiEmotions-It, il corpus adotta la tassonomia *multi-label* delle emozioni di Plutchik, ma la arricchisce con livelli specifici per il dominio. Oltre a tracciare la presenza di ironia e offensività, introduce la distinzione del *target* dell'emozione: i modelli devono

[4] `https://www.insalutenews.it/in-salute/piattaforma-sullintelligenza-artificiale-monitora-e-analizza-emozioni-e-passioni-dei-telespettatori-sui-social-media/`

discriminare se il commento sia rivolto al "contenuto" (gli eventi, i temi narrati e ospiti occasionali) oppure al "contenitore" (il programma in sé, i conduttori, la regia o ospiti fissi).

Nel contesto della competizione EVALITA 2023, i modelli partecipanti sono stati valutati su due fronti: la classificazione delle emozioni (Subtask A) e l'identificazione del target (Subtask B). I risultati hanno evidenziato un problema sulle capacità di generalizzazione: sebbene si ottengano prestazioni discrete sui dati appartenenti alle stesse trasmissioni usate per il training (*in-domain*), le performance crollano drasticamente nelle valutazioni su trasmissioni non note (*out-of-domain*). I modelli testuali faticano a generalizzare il riconoscimento emotivo quando vengono esposti a format televisivi mai visti prima.

Queste evidenze confermano la natura sfidante del dominio e del task di Emotion Detection. Partendo dalla idea concettuale e annotativa di EMit, il nostro lavoro con MultiEMit si propone di fare il passo successivo introducendo la multimodalità. Grazie alla sua dimensione e distribuzione su diversi programmi televisivi, i dati di EMit sono stati impiegati nella fase sperimentale di questo elaborato: sono stati uniti con i nostri dati testuali per comporre il set di addestramento e irrobustire il *fine-tuning* degli encoder testuali destinati al task di Emotion Detection.

2.3 Irony Detection in italiano

2.3.1 IronITA (EVALITA 2018)

L'analisi dell'ironia e del sarcasmo rappresenta una sfida complessa per i classificatori testuali, in quanto richiede di decodificare il reale intento comunicativo oltre il significato letterale delle parole. Per affrontare questa problematica in lingua italiana, troviamo **IronITA** [27], uno *shared task* di EVALITA 2018 dedicato all'analisi di tweet. Lo schema di etichettatura opera su due livelli: il primo determina la presenza o assenza di ironia (Subtask A), mentre il secondo isola, all'interno dei testi ironici, i casi specifici di sarcasmo (Subtask B), definito come un'ironia con intenti esplicitamente offensivi o denigratori.

Per chiarire questa distinzione tra ironia e sarcasmo, osserviamo un esempio: *"Complimenti, genio: sei riuscito a sbagliare anche l'ovvio."*, l'appellativo "genio" non è un semplice ribaltamento ironico del significato letterale. Viene utilizzato con chiaro intento denigratorio per attaccare direttamente il bersaglio, ovvero un caso di sarcasmo.

Il corpus di IronITA comprende quasi 5.000 tweet. Pur essendo una collezione puramente testuale, questi dati si sono rivelati utili per il nostro lavoro.

Al pari di quanto fatto con EMit, i dati di IronITA sono stati impiegati per l'addestramento dei nostri modelli. Nello specifico, sono state effettuate sessioni di addestramento sul modello UmBERTo[5], dotando l'encoder testuale di competenza sui pattern dell'ironia italiana prima dell'addestramento definitivo su MultiEMit.

[5] https://huggingface.co/Musixmatch/umberto-commoncrawl-cased-v1

Capitolo 3

Il Dataset MultiEMit

3.1 Dominio dei Dati

Il dataset MultiEMit affonda le proprie radici nel progetto **M.EMO.RAI**[1], nato dalla collaborazione tra il Dipartimento di Informatica dell'Università di Torino e la Direzione ICT della Rai nel 2020. L'obiettivo del progetto era affiancare ai tradizionali dati Auditel l'analisi delle reazioni del pubblico espresse sui social network. Il contributo principale di M.EMO.RAI è stato applicare tecniche di Emotion Detection nell'ambito della Social TV, abbandonando la classificazione della polarità (positivo, negativo, neutro) in favore di un'analisi a grana più fine basata sullo schema di Plutchik.

Da M.EMO.RAI sono nati due corpus che costituiscono la base di MultiEMit:

1. **ProSAT** [28], focalizzato sui post di Twitter relativi a *Propaganda Live*, un talk show satirico in onda su LA7 condotto da Diego Bianchi (Zoro). Il programma mescola satira politica, reportage giornalistici e interazione con i social media, stimolando la partecipazione del pubblico online. I dati si riferiscono alla puntata del **19 novembre 2021**, in cui Diego Bianchi documentò la crisi umanitaria dei migranti al confine tra Polonia e Bielorussia. L'evento ha generato una forte risposta emotiva su Twitter, caratterizzata da indignazione, tristezza e solidarietà.

2. **EMit (Pechino Express)**, sviluppato come estensione del corpus EMit originale [26], raccoglie post relativi a *Pechino Express*, un reality show d'avventura trasmesso su Rai2. Il format prevede una gara

[1] `https://www.insalutenews.it/in-salute/piattaforma-sullintelligenza-artificiale-monitora-e-analizza-emozioni-e-passioni-dei-telespettatori-sui-social-media/`

a coppie che si sfidano lungo un percorso a tappe attraverso diversi paesi. I dati si riferiscono alla prima puntata dell'ottava edizione (**11 febbraio 2020**). I commenti tendono a essere più leggeri rispetto a Propaganda Live, focalizzati sull'intrattenimento e sulle dinamiche tra i concorrenti.

È importante non confondere EMit (Pechino Express) con il corpus EMit presentato nel Capitolo 2, che comprende 5.966 post relativi a diversi programmi televisivi. Quest'ultimo è stato utilizzato come risorsa supplementare per il training dei nostri modelli, mentre nel resto di questo capitolo useremo sempre la dicitura "EMit (Pechino Express)" per riferirci al sottoinsieme specifico.

MultiEMit nasce dalla fusione di ProSAT e EMit (Pechino Express). Entrambi i corpus condividono una caratteristica fondamentale: ciascuno contiene un dataset **solo testuale** e un dataset **multimodale** (testo + immagine). Questa distinzione ci permette di confrontare direttamente le performance dei modelli con e senza la componente visiva.

La scelta di raccogliere dati multimodali riflette la natura della comunicazione sui social network. L'interazione tra pubblico e programmi televisivi avviene sempre più spesso tramite post che combinano testo e immagini: screenshot del programma, meme o GIF che modificano o amplificano il significato del messaggio scritto dall'utente.

3.2 Metodologia e Schema di Annotazione

Per formalizzare e semplificare il processo di annotazione, abbiamo utilizzato la piattaforma **Sensitag** (Figura 3.1), un'interfaccia web intuitiva sviluppata dal Dipartimento di Informatica dell'Università di Torino e creata originariamente proprio per far fronte alle necessità del progetto M.EMO.RAI. Grazie all'accesso a questa piattaforma garantitoci dall'Ateneo, siamo riusciti a etichettare agevolmente ogni post nei vari livelli di annotazione stabiliti.

Il processo di etichettatura ha coinvolto tre annotatori per dataset, tutti con background in informatica o linguistica. Il gold standard finale (ovvero l'etichetta considerata corretta) è stato stabilito adottando un semplice criterio di maggioranza: è stata scelta l'etichetta su cui concordavano almeno due annotatori su tre.

Sfruttando le capacità di classificazione predisposte originariamente da M.EMO.RAI in Sensitag (Emotion, Ironia, Odio, Target) con l'aggiunta del nostro quinto livello personalizzato dedicato alle immagini, il dataset è stato annotato complessivamente su cinque livelli distinti:

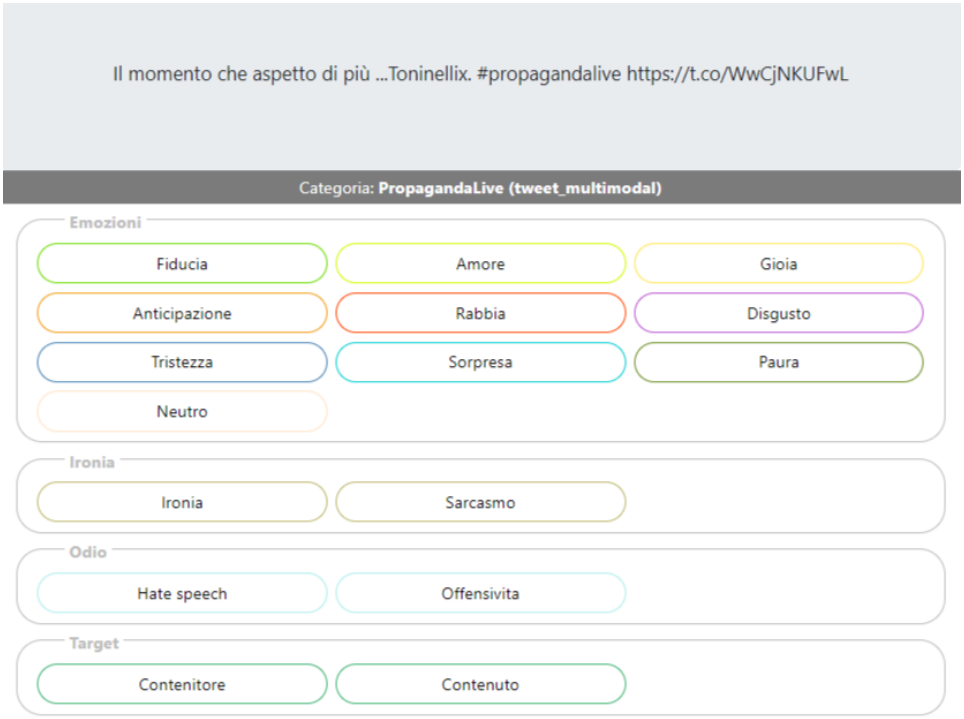


Figura 3.1: L'interfaccia dell'applicativo web Sensitag.

1. **Emozioni:** Si basa sulla "Ruota delle Emozioni" (Figura 1.2) di **Plutchik**, che identifica otto emozioni primarie opposte a coppie: Gioia-Tristezza, Fiducia-Disgusto, Paura-Rabbia, Sorpresa-Anticipazione. Al modello sono state aggiunte le etichette **Amore** (una diade frequente data da Gioia + Fiducia) e **Neutro**. Un singolo post può essere annotato con più emozioni (multi-label).
2. **Ironia:** Un livello che segnala la presenza di ironia o sarcasmo (inteso come una specifica categoria di ironia) nel testo.
3. **Hate Speech/Offensività:** Indica la presenza di linguaggio offensivo o incitamento all'odio.
4. **Target:** Distingue se il commento è rivolto al:
   - **Contenuto:** Gli argomenti trattati, i temi, i fatti raccontati, ospiti una volta.
   - **Contenitore):** La trasmissione stessa, il conduttore, gli ospiti ricorrenti, la qualità tecnica o la regia.
5. **Relazione Semiotica Testo-Immagine:** Ispirandosi al lavoro di Kruk et al. [6], abbiamo classificato la relazione tra le due modalità in:

- **Additiva:** L'immagine e il testo si arricchiscono a vicenda, ampliando il significato complessivo.
- **Parallela:** L'immagine e il testo veicolano indipendentemente lo stesso identico messaggio.
- **Divergente:** Il testo e l'immagine sembrano in contrasto o non correlati a prima vista, ma insieme creano un nuovo significato (tipico di meme o ironia).

3.2.1 Ambiguità e Accordo tra Annotatori

Nonostante le linee guida, è naturale che persone diverse possano interpretare lo stesso testo in modi diversi. Questa ambiguità è particolarmente evidente quando si tratta di classificare le emozioni, che spesso si sovrappongono o si combinano in modi complessi.

Consideriamo un esempio concreto dal nostro dataset:

> *"Terribile mi vergogno di essere Europeo #propagandalive #Refugees #Bielorussia #Polonia #RefugeesNeedHelp..."*



Figura 3.2: Esempio di post ambiguo: il testo "Terribile mi vergogno di essere Europeo".

Questo post, accompagnato da immagini del reportage sui migranti al confine polacco-bielorusso (Figura 3.2), può essere interpretato in almeno tre modi diversi:

- **Vergogna:** L'autore prova vergogna per come l'Europa sta gestendo la crisi. Secondo lo schema di Plutchik, la vergogna è una diade composta da *Disgusto* e *Paura*.
- **Disprezzo:** L'autore esprime disprezzo verso le istituzioni europee. In questo caso, le emozioni primarie sarebbero *Rabbia* e *Disgusto*.
- **Disapprovazione:** L'autore disapprova le politiche europee, con una combinazione di *Sorpresa* e *Tristezza*.

Tutte e tre le interpretazioni sono legittime, e annotatori diversi potrebbero scegliere combinazioni di emozioni differenti. Questo tipo di ambiguità si è rivelato una delle sfide principali durante la creazione del dataset.

Tuttavia, abbiamo osservato un fenomeno interessante: quando gli annotatori potevano vedere anche l'immagine allegata al post, l'accordo tra di loro aumentava. Nel caso dell'esempio precedente, l'immagine che mostra rifugiati infreddoliti, incluso un bambino, fornisce un contesto emotivo forte che orienta l'interpretazione verso la tristezza e la compassione, riducendo l'ambiguità. Questa osservazione è stata verificata empiricamente calcolando la Kappa di Fleiss sui dati del subset ProSAT: per la maggior parte delle etichette, l'indice di accordo è aumentato passando dall'annotazione senza immagine a quella con immagine [28]. Tale evidenza è stata una delle motivazioni principali per lo sviluppo di un approccio multimodale: se l'immagine aiuta gli esseri umani a interpretare meglio il messaggio, può aiutare anche i modelli di classificazione.

3.3 Distribuzione del Dataset

Dopo il consolidamento del gold standard, il corpus MultiEMit risulta composto da due split principali:

- Un dataset puramente **Testuale** di **2.909** post.
- Un dataset **Multimodale** (testo + immagine) di **645** post.

Come tipico dei dati provenienti dai social media, la distribuzione delle classi è naturalmente sbilanciata. Di seguito presentiamo la distribuzione delle etichette per ciascun livello di annotazione. Per entrambi i dataset, testuale e multimodale, riportiamo anche la suddivisione tra i dati provenienti da **ProSAT** (Propaganda Live) e da **EMit** (Pechino Express), evidenziando come il contesto del programma televisivo influenzi significativamente la composizione emotiva e ironica dei post. Si noti che il livello delle emozioni è *multi-label* (un singolo post può esprimere più emozioni contemporaneamente), pertanto i conteggi per riga non sommano al numero totale di post.

Le Tabelle 3.1 e 3.2 presentano la distribuzione completa delle etichette nei due dataset.

Tabella 3.1: Distribuzione delle etichette nel dataset testuale di MultiEMit (2.909 post), con suddivisione per programma.

Etichetta	**Totale (2.909)**	**ProSAT**	**EMit**
Emozioni (multi-label)			
Amore	340	119	221
Anticipazione	201	75	126
Disgusto	410	207	203
Fiducia	613	281	332
Gioia	552	257	295
Neutro	321	31	290
Paura	55	44	11
Rabbia	163	121	42
Sorpresa	486	225	261
Tristezza	255	211	44
Ironia			
Ironia	481	237	244
Non ironico	2.072	828	1.244
Sarcasmo	41	15	26
Offensività			
Offensivo	52	31	21
Target			
Contenitore	1.147	343	804
Contenuto	1.138	710	428

La distribuzione delle etichette riflette chiaramente il contesto dei due programmi televisivi, con pattern che si confermano sia nel dataset testuale che in quello multimodale.

Le emozioni più frequenti in entrambi i dataset sono *Fiducia* e *Gioia*, a testimonianza dell'atteggiamento generalmente positivo del pubblico verso i programmi seguiti. Le emozioni negative, invece, mostrano una distribuzione molto diversa tra i due programmi. Nei dati ProSAT, la puntata sulla crisi dei migranti ha generato forti reazioni: *Tristezza*, *Rabbia* e *Paura* sono quasi interamente concentrate in questo sottoinsieme, sia nel dataset testuale che nel multimodale. Nei dati EMit (Pechino Express) queste emozioni sono invece quasi assenti, coerentemente con il tono leggero del reality. Domina l'*Anticipazione*, legata all'entusiasmo per la prima puntata della stagione, mentre il *Disgusto* (sorprendentemente alto per un programma di intrattenimento) trova spiegazione nelle prove affrontate dai concorrenti, come mangiare insetti.

Tabella 3.2: Distribuzione delle etichette nel dataset multimodale di MultiEMit (645 post), con suddivisione per programma.

Etichetta	**Totale (645)**	**ProSAT**	**EMit**
Emozioni (multi-label)			
Amore	50	17	33
Anticipazione	61	10	51
Disgusto	78	18	60
Fiducia	214	82	132
Gioia	168	79	89
Neutro	90	21	69
Paura	4	4	0
Rabbia	34	29	5
Sorpresa	82	24	58
Tristezza	25	23	2
Ironia			
Ironia	109	21	88
Non ironico	516	199	317
Sarcasmo	20	5	15
Offensività			
Offensivo	6	3	3
Target			
Contenitore	395	103	292
Contenuto	199	85	114
Relazione Semiotica			
Additiva	389	158	231
Divergente	158	42	116
Parallela	100	10	90

L'ironia è un fenomeno pervasivo ma distribuito in modo disomogeneo. Nel dataset testuale i post ironici sono bilanciati tra i due programmi, mentre nel multimodale l'ironia risulta nettamente concentrata in EMit (Pechino Express). Questo dato è apparentemente controintuitivo: Propaganda Live è una trasmissione satirica, eppure i post ironici con immagine sono pochi. La spiegazione risiede nel contenuto specifico della puntata analizzata, che ha generato reazioni prevalentemente serie. Il sarcasmo e l'offensività sono complessivamente rari in entrambi i dataset.

Anche la distinzione tra Contenuto e Contenitore mostra un pattern coerente. I post su ProSAT sono prevalentemente orientati al Contenuto, in quanto il pubblico reagisce ai fatti raccontati nel reportage. I post su EMit (Pechino Express) sono invece orientati al Contenitore: i commenti riguardano il programma stesso, i conduttori e i concorrenti.

Le relazioni semiotiche, disponibili solo per il dataset multimodale, mostrano la prevalenza della relazione *Additiva*, in cui testo e immagine si arricchiscono a vicenda. In EMit (Pechino Express) dominano anche le relazioni *Parallela* e *Divergente*: i post includono screenshot che illustrano letteralmente il testo, oppure meme che creano contrasto ironico. In ProSAT la relazione *Additiva* è quella dominante (le immagini del reportage forniscono contesto emotivo), mentre la *Parallela* è quasi assente, poiché i post non si limitano a descrivere ciò che si vede ma aggiungono commento e opinione.

Questa distribuzione sbilanciata, sia tra le classi che tra i programmi, rappresenta una delle sfide principali affrontate durante l'addestramento dei modelli.

3.4 Analisi delle Correlazioni

Una delle caratteristiche distintive del dataset MultiEMit è l'annotazione su più livelli (emozioni, ironia, target, ecc.). Questa ricchezza informativa ci ha permesso di indagare le relazioni intrinseche tra le diverse dimensioni semantiche e pragmatiche dei post, calcolando il **coefficiente di correlazione di Pearson** tra tutte le coppie di etichette.

Questo indice statistico misura in modo diretto quanto due variabili tendano a presentarsi insieme e il suo valore varia tra -1 e 1. Un punteggio positivo indica che due etichette compaiono spesso nello stesso messaggio, creando un'associazione logica. Un punteggio negativo suggerisce invece che le due etichette tendono a escludersi a vicenda. Valori vicini allo zero indicano infine l'assenza di un legame evidente.

L'analisi ha rivelato l'esistenza di forti interdipendenze, suggerendo che la presenza di una determinata classe (es. ironia) possa essere un forte indizio per la presenza di altre (es. gioia). Queste correlazioni sono state successivamente incorporate come informazione contestuale nei prompt dei modelli (Sezione 4.2.5).

Le matrici di correlazione sono organizzate in tre prospettive complementari: la prima pone le *emozioni* come variabili di riferimento (righe) rispetto a tutti gli altri livelli (Figura 3.3); la seconda quella dell'*ironia* (Figura 3.4); la terza assume la prospettiva delle *relazioni semiotiche* (Figura 3.5).

3.4.1 Correlazioni dal punto di vista delle Emozioni

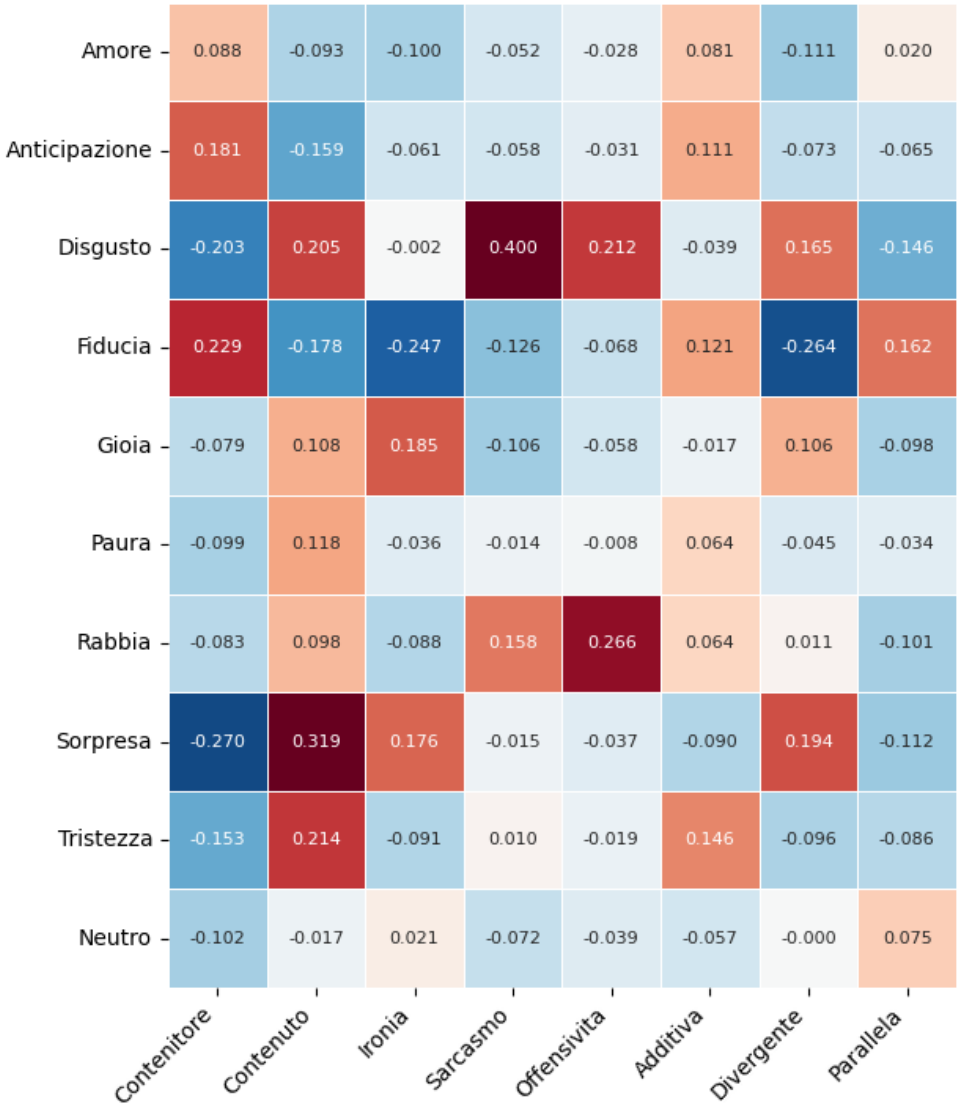


Figura 3.3: Matrice di correlazione di Pearson tra le 10 emozioni (righe) e le etichette di target, ironia, offensività e relazione semiotica (colonne).

La Figura 3.3 mostra diversi pattern che riflettono le dinamiche comunicative nel contesto della Social TV.

Il primo aspetto che emerge è una netta separazione tra *Contenitore* e *Contenuto*. Le emozioni orientate al programma in quanto trasmissione (come *Fiducia* e *Anticipazione*) correlano positivamente con il target Contenitore, indicando un atteggiamento di apprezzamento e attesa verso il for-

mat. Al contrario, le emozioni reattive ai temi trattati (*Sorpresa*, *Tristezza*, *Disgusto*) correlano con il Contenuto. In particolare, la *Sorpresa* mostra l'associazione più forte con il Contenuto dell'intera matrice, suggerendo che le reazioni di stupore siano quasi esclusivamente dirette verso ciò che viene raccontato, non verso chi lo racconta.

Per quanto riguarda l'ironia, i post che esprimono *Fiducia* verso il programma tendono a essere sinceri e diretti, mentre *Sorpresa* e *Gioia* si associano più frequentemente a contenuti ironici. Il sarcasmo mostra invece un profilo più aggressivo: l'associazione più forte dell'intera matrice è quella tra sarcasmo e *Disgusto*, seguita dalla *Rabbia*. L'offensività segue un pattern simile ma ancora più marcato, confermando che il linguaggio offensivo nel corpus si manifesta quasi esclusivamente in contesti di forte negatività emotiva.

Infine, le relazioni semiotiche mostrano associazioni coerenti con il loro meccanismo comunicativo. La relazione *Divergente* si associa alla *Sorpresa* e non alla *Fiducia*: il contrasto tra testo e immagine genera stupore e non si associa a espressioni di apprezzamento diretto. La relazione *Parallela* mostra il profilo opposto, associandosi alla *Fiducia* e allontanandosi dal *Disgusto*. Questo suggerisce un uso più letterale e neutro della combinazione testo-immagine nei post di apprezzamento.

3.4.2 Correlazioni dal punto di vista dell'Ironia

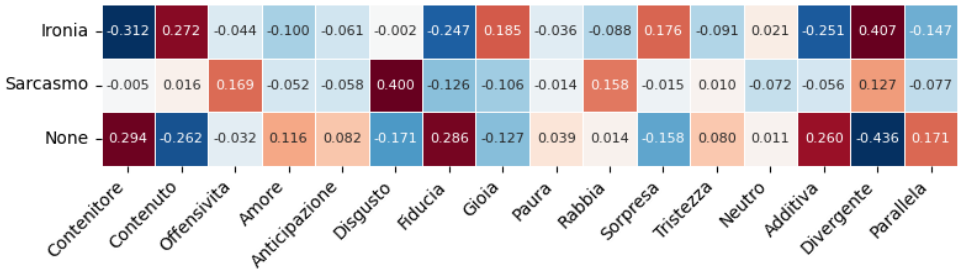


Figura 3.4: Matrice di correlazione di Pearson tra le etichette di ironia (righe) e tutte le altre etichette (colonne). La classe *None* è stata inclusa unicamente in questa analisi.

La Figura 3.4 presenta la seconda prospettiva dell'analisi, utilizzando le etichette dell'ironia come variabili di riferimento. In questa matrice compare anche la classe *None*. Questa etichetta è stata aggiunta successivamente alla fase di etichettatura manuale. Ci è servita per avere una classe neutra nei task di Irony Detection, in quanto abbiamo impostato il problema come una classificazione multi-classe (dove le etichette possibili sono "Ironia", "Sarcasmo" e "None" per indicare la non presenza). Per questo motivo il termine

None non compare nelle tabelle di distribuzione iniziali, dove l'assenza di ironia era semplicemente indicata come "Non ironico".

Analizzando i dati, notiamo che ironia e sarcasmo mostrano profili molto diversi. L'ironia si associa in modo forte alla relazione visiva Divergente e al target Contenuto, legandosi spesso a emozioni come Gioia e Sorpresa. Questo suggerisce un'ironia prevalentemente leggera e divertita. Il sarcasmo, al contrario, si allontana da questi toni per legarsi a emozioni aggressive come Disgusto e Rabbia, associandosi spesso alla presenza di linguaggio offensivo. Troviamo quindi una conferma diretta alla definizione pragmatica: il sarcasmo si comporta nei nostri dati come un'ironia con chiaro intento denigratorio.

Il profilo della classe *None* risulta quasi speculare a quello dell'ironia. I post privi di ironia si legano fortemente alla Fiducia e al target Contenitore. Sul piano visivo, mostrano un'affinità con le relazioni Additiva e Parallela, mentre si allontanano in modo marcato dalla relazione Divergente. In pratica, i commenti sinceri e diretti sul programma televisivo sono tipicamente accompagnati da immagini che arricchiscono o replicano il testo, senza creare contrasti.

Unendo queste osservazioni, possiamo notare un quadro coerente. Il perno dell'ironia si basa sulla triade Ironia-Divergente-Contenuto: l'effetto umoristico si manifesta preferibilmente attraverso la dissonanza tra testo e immagine in risposta ai temi trattati. Simmetricamente, l'assenza di ironia si associa alla sincerità emotiva, alla complementarità visiva e all'attenzione al programma in sé. In sintesi, emerge un quadro molto chiaro. L'ironia nei nostri dati si basa sul contrasto: l'effetto umoristico si manifesta spesso attraverso la contraddizione tra testo e immagine (Divergente) in risposta ai temi trattati dai programmi (Contenuto). Al contrario, l'assenza di ironia è legata a messaggi diretti: gli utenti esprimono emozioni sincere sul programma in sé (Contenitore) e accompagnano il testo con immagini coerenti che confermano il messaggio (Additiva).

3.4.3 Correlazioni dal punto di vista delle Relazioni Semiotiche

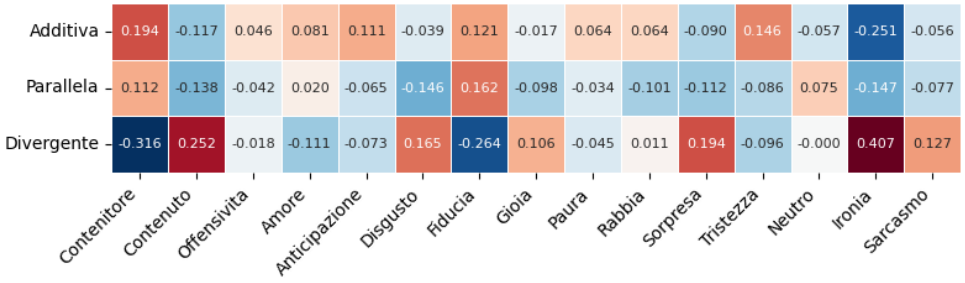


Figura 3.5: Matrice di correlazione di Pearson tra le 3 relazioni semiotiche (righe) e tutte le altre etichette (colonne).

La Figura 3.5 conferma e approfondisce i legami emersi dalla prospettiva delle emozioni.

La relazione *Divergente* mostra l'associazione più forte dell'intera analisi con l'*Ironia*, confermando che il contrasto deliberato tra testo e immagine è il meccanismo semiotico privilegiato per veicolare messaggi ironici nei social media. Questa associazione è coerente con la natura dei meme e dei post satirici, dove l'effetto umoristico nasce proprio dalla dissonanza tra le due modalità. La Divergente si allontana invece dal *Contenitore* e dalla *Fiducia*, mentre si associa al *Contenuto* e alla *Sorpresa*: i post divergenti sono tipicamente reazioni sarcastiche o ironiche ai contenuti trasmessi, non espressioni di apprezzamento verso il programma.

La relazione *Additiva* mostra un profilo quasi opposto: si associa al *Contenitore* e alla *Tristezza*, e si allontana dall'*Ironia*. Nei post additivi l'immagine arricchisce il testo in modo coerente (ad esempio, uno screenshot del programma accompagnato da un commento emotivo sulla scena mostrata).

La relazione *Parallela* mostra correlazioni generalmente deboli, con una leggera associazione positiva con la *Fiducia* e negativa con il *Disgusto* e l'*Ironia*. Questo profilo suggerisce un uso più descrittivo e neutro della combinazione testo-immagine: il testo ripete ciò che l'immagine mostra, senza aggiungere valutazione emotiva o intento ironico.

Capitolo 4

Design sperimentale

Questo capitolo descrive l'intero percorso sperimentale adottato per affrontare i task di classificazione sul dataset MultiEMit. La Sezione 4.1 definisce formalmente i tre task e le metriche di valutazione. La Sezione 4.2 illustra la creazione dei modelli testuali di base, i modelli pre-addestrati utilizzati e i parametri di addestramento. La Sezione 4.3 presenta l'architettura multimodale *Dual-Encoder* che integra testo e immagine. Infine, la Sezione 4.4 descrive gli esperimenti condotti con il Large Multimodal Model Pixtral.

4.1 Definizione dei Task e Metriche

Il nostro studio affronta tre task di classificazione distinti, ciascuno dei quali modella un diverso livello semantico del dataset MultiEMit.

4.1.1 Task di classificazione

Emotion Recognition (Multi-label). Il riconoscimento delle emozioni è formulato come un problema di **classificazione multi-label**: per ciascun post, il modello deve predire zero, una o più emozioni contemporaneamente, tra le 10 classi dello schema adottato (le 8 emozioni primarie di Plutchik più *Amore* e *Neutro*). Questa scelta riflette la realtà dei dati: un singolo tweet può esprimere simultaneamente emozioni diverse secondo il meccanismo delle diadi di Plutchik (ad esempio, *Gioia* e *Fiducia* co-occorrono nel sentimento di *Amore*).

Irony Detection (Multiclasse). Il riconoscimento dell'ironia è formulato come un problema di **classificazione multiclasse**: il modello assegna a ciascun post esattamente una delle tre classi: *Ironia*, *Sarcasmo* o *Non ironico* restituendo quindi una singola etichetta mutuamente esclusiva.

Semiotic Relation Detection (Multiclasse). Anche il riconoscimento della relazione semiotica tra testo e immagine è un task di **classificazione multiclasse**: il modello classifica ogni post multimodale in una delle tre categorie: *Additiva*, *Divergente* o *Parallela*.

4.1.2 Metriche di valutazione

Per valutare le prestazioni dei modelli, ci concentriamo su tre metriche standard per valutare i risultati di classificatori: **Precision**, **Recall** e **F1-score**.

Queste metriche si basano sui quattro possibili risultati di una classificazione:

- **True Positives (TP) - Veri Positivi**: istanze appartenenti a una determinata classe e correttamente identificate come tali dal modello.
- **True Negatives (TN) - Veri Negativi**: istanze non appartenenti alla classe e correttamente ignorate dal modello.
- **False Positives (FP) - Falsi Positivi**: istanze assegnate erroneamente alla classe dal modello (noti anche come errori di Tipo I).
- **False Negatives (FN) - Falsi Negativi**: istanze appartenenti alla classe ma non riconosciute dal modello (noti anche come errori di Tipo II).

La **Precision** (P) misura la proporzione di predizioni positive corrette sul totale delle predizioni positive effettuate dal modello:

$$P = \frac{TP}{TP + FP}$$

La **Recall** (R) misura la proporzione di istanze positive correttamente identificate sul totale delle istanze positive reali:

$$R = \frac{TP}{TP + FN}$$

L'**F1-score** è la media armonica di Precision e Recall, e fornisce una misura bilanciata che penalizza valori estremi di una delle due componenti:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R}$$

In un contesto multiclasse, queste metriche vengono calcolate per ciascuna classe e poi aggregate. Le due principali strategie di aggregazione sono:

- **Micro-averaging (Micro F1):** Aggrega globalmente i contributi di tutte le classi sommando le occorrenze totali dei veri positivi, falsi positivi e falsi negativi prima di calcolare la metrica. Tratta ogni singola *predizione* con lo stesso peso, avvantaggiando implicitamente le prestazioni sulle classi maggioritarie. La sua formulazione è:

$$Micro\ F1 = 2 \cdot \frac{Micro\ Precision \cdot Micro\ Recall}{Micro\ Precision + Micro\ Recall}$$

$$\text{dove} \quad Micro\ Precision = \frac{\sum_{i=1}^{C} TP_i}{\sum_{i=1}^{C} (TP_i + FP_i)} \quad \text{e} \quad Micro\ Recall = \frac{\sum_{i=1}^{C} TP_i}{\sum_{i=1}^{C} (TP_i + FN_i)}$$

  con C pari al numero di classi.

- **Macro-averaging (Macro F1):** Calcola la metrica in modo indipendente e separato per ciascuna classe, estraendo poi la media aritmetica non pesata dei risultati. Questo approccio tratta tutte le classi allo stesso modo, diventando severo quando le prestazioni sulle categorie meno frequenti degradano. La sua formulazione è:

$$Macro\ F1 = \frac{1}{C} \sum_{i=1}^{C} F1_i$$

$$\text{dove} \quad F1_i = 2 \cdot \frac{Precision_i \cdot Recall_i}{Precision_i + Recall_i}$$

Negli esperimenti di questa tesi, la metrica di riferimento principale è l'**F1-score Macro**, tranne nei casi esplicitamente indicati. La scelta del macro-averaging è motivata dal forte sbilanciamento delle classi nel dataset MultiEMit (come evidenziato nel Capitolo 3): il micro-averaging tenderebbe a sovrastimare le prestazioni del modello sulle classi maggioritarie (es. *Fiducia*, *Gioia*), mascherando le difficoltà sulle classi minoritarie (es. *Paura*, *Rabbia*). Il macro-averaging garantisce invece che il contributo di ogni classe sia equamente ponderato, fornendo una valutazione più realistica della capacità del modello di discriminare l'intero spettro emotivo.

4.2 Esperimenti con BERT

La prima fase del nostro approccio ha previsto la creazione di solide baseline puramente testuali per ciascuno dei tre task. Questa fase è stata cruciale per due motivi: validare la consistenza delle annotazioni del dataset, produrre encoder testuali specializzati da riutilizzare come componenti nell'architettura multimodale e creare delle baseline riguardanti i dati testuali da confrontare poi con l'aggiunta delle immagini e delle correlazioni.

4.2.1 Modelli pre-addestrati

Per garantire prestazioni elevate su testi in italiano, abbiamo evitato modelli multilingua generici in favore di risorse già specializzate sulla lingua italiana e su task affini:

- **FEEL-IT** [15]: Per il riconoscimento delle emozioni, siamo partiti dal modello `feel-it-italian-emotion`[1], un modello basato su BERT [14] e pre-addestrato specificamente su tweet italiani per emotion analysis. FEEL-IT è stato originariamente addestrato su un task *multiclasse* con 4 emozioni (rabbia, paura, gioia, tristezza). Partire da un modello già calibrato su un task di emotion recognition in italiano, sebbene con uno schema più ristretto, ci ha fornito un'inizializzazione molto più efficace rispetto a un BERT generico, permettendo al modello di estendere le proprie capacità discriminative alle 10 classi del nostro schema attraverso il fine-tuning. In questa fase, il task è stato trasformato da *multiclasse* a **multi-label**, gestendo le 10 emozioni tramite classificazione binaria indipendente per ciascuna classe (one-hot encoding) con una soglia di attivazione di 0.4.
- **UmBERTo** [16]: Per i task di irony detection e semiotic relation detection, abbiamo utilizzato il modello `UmBERTo`[2], un modello linguistico basato su BERT e addestrato sul corpus OSCAR[3] [29]. Grazie all'addestramento su un vasto corpus di testi italiani, UmBERTo è in grado di catturare sfumature semantiche e pragmatiche complesse della lingua, rendendolo un punto di partenza ideale per il fine-tuning sui nostri task specifici. Motivo ulteriore per cui abbiamo scelto UmBERTo è che Feel-IT stesso è nato da un finetune di UmBERTo.

4.2.2 Riconoscimento delle emozioni

Per il task di emotion detection, abbiamo adottato un approccio **multi-label**: un singolo post può esprimere più emozioni contemporaneamente, secondo il meccanismo delle diadi di Plutchik. Dopo vari esperimenti con diverse codifiche delle etichette (28 combinazioni vs 20 macro-categorie), la configurazione più efficace si è rivelata quella basata sulle 8 emozioni primarie più *Amore* e *Neutro*, gestite tramite classificazione binaria indipendente per ogni classe con una soglia di attivazione di 0.4.

Per aumentare la quantità di dati di addestramento mantenendo lo stesso schema di annotazione, abbiamo integrato il corpus **EMit** [26], creato

[1] `https://huggingface.co/MilaNLProc/feel-it-italian-emotion`
[2] `https://huggingface.co/Musixmatch/umberto-commoncrawl-cased-v1`
[3] `https://oscar-project.org/`

per la competizione EVALITA 2023 per il task di emotion detection in italiano. Questo dataset condivide il medesimo schema di annotazione basato su Plutchik, permettendo un'integrazione diretta senza adattamenti.

4.2.3 Riconoscimento dell'ironia

Per il task di irony detection, trattato come classificazione multiclasse (*Ironico*, *Sarcastico*, *Non ironico*), abbiamo seguito una strategia di addestramento in due fasi. In primo luogo, abbiamo fine-tunato UmBERTo sul dataset **IRONITA** [27], un corpus di riferimento per l'irony detection in italiano con annotazione binaria. Questo passaggio ha fornito al modello una base solida per il riconoscimento dell'ironia, analoga al ruolo che FEEL-IT ha svolto per le emozioni. Successivamente, il modello pre-addestrato su IRONITA è stato ulteriormente fine-tunato sui dati interni di MultiEMit, adattandolo al nostro schema a tre classi e al dominio specifico della Social TV.

4.2.4 Riconoscimento della relazione semiotica

Anche se la relazione semiotica (*Additiva*, *Divergente*, *Parallela*) è intrinsecamente multimodale, abbiamo addestrato un modello puramente testuale per identificare quali pattern linguistici sono più frequentemente associati a ciascuna relazione. Per questo task non è stato possibile reperire dataset esterni con uno schema di annotazione compatibile, pertanto il modello è stato addestrato esclusivamente sui dati di MultiEMit. Oltre a stabilire una baseline per valutare il guadagno introdotto dall'encoder visivo, questo modello testuale ha permesso al Dual-Encoder di partire da un encoder già orientato al task.

4.2.5 Addestramento con correlazioni

Basandoci sull'ipotesi che queste correlazioni rappresentino una conoscenza contestuale preziosa, abbiamo sviluppato una tecnica di *correlation prompting* per migliorare le prestazioni dei modelli.

L'idea consiste nell'arricchire il testo originale del post con informazioni esplicite riguardo alle etichette correlate, simulando una situazione in cui il modello "conosce" già il contesto pragmatico del messaggio.

In pratica, abbiamo concatenato al testo del tweet una stringa introduttiva (il prompt) che descrive le caratteristiche correlate al target di classificazione.

Ad esempio:

- *Testo originale:* "ma soleil é con sua nonna?"

- *Testo con prompt (Prompted):* "il seguente testo contiene ironia e offensività riguarda contenitore: ma soleil é con sua nonna?"

Questo metodo fornisce al modello degli "ancoraggi" espliciti: se il modello sa che il testo contiene ironia (magari dedotta dall'immagine o dal contesto), può aggiustare la sua previsione emotiva ad esempio passando da "tristezza" a "gioia" o "rabbia" a seconda del tipo di ironia.

Questa tecnica è stata applicata sia in fase di addestramento che di test, per valutare quanto l'informazione contestuale aggiuntiva (che in uno scenario reale potrebbe essere inferita da un modulo separato o dall'immagine) aiuti la classificazione finale.

Ciascuno dei tre task è stato addestrato in due configurazioni: **senza correlazioni** (testo originale) e **con correlazioni** (testo arricchito con la tecnica di *correlation prompting*). Questo ha permesso di valutare sistematicamente l'impatto dell'informazione contestuale aggiuntiva sulle prestazioni di ciascun modello testuale.

4.2.6 Parametri di addestramento e split dei dati

Per garantire la riproducibilità e la comparabilità dei risultati tra tutti gli esperimenti, i dataset sono stati suddivisi in *training* e *test set* applicando uno split (divisione del dataset in sottoinsiemi) fisso equivalente all'80% per l'addestramento e al 20% per il test (`random_state=42`, `test_size=0.2`).

È fondamentale specificare le partizioni impiegate in base al task affrontato:

- **Emotion Detection e Irony Detection**: Per l'addestramento degli encoder puramente testuali, abbiamo utilizzato congiuntamente lo split di *train* relativo al **dataset testuale** (che per le emozioni veniva concatenato ai dati aggiuntivi da EMit, mentre per l'ironia si partiva da un modello già pre-addestrato su IRONITA) e lo split di *train* relativo al **dataset multimodale**, del quale è stata osservata unicamente la componente testuale per questo fine-tuning. Successivamente, i modelli text-only così ottenuti sono stati valutati separatamente sia sullo split di *test* del dataset testuale, sia sullo split di *test* del dataset multimodale.
- **Semiotic Relation Detection**: A differenza dei due task precedenti, il livello delle relazioni semiotiche non è stato annotato sui post privi di immagine. Conseguentemente, per questo task l'addestramento ha impiegato esclusivamente lo split di *train* del **dataset multimodale**, ed è stato analogamente testato solo sul *test* set multimodale.

La Tabella 4.1 riporta gli iperparametri utilizzati per l'addestramento dei modelli basati su BERT (FEEL-IT e UmBERTo).

Tabella 4.1: Iperparametri di addestramento per i modelli BERT.

Parametro	**Valore**
Learning rate	2×10^{-5}
Batch size (train/eval)	16
Epoche	5
Weight decay	0.01
Strategia di valutazione	Per epoca
Metrica di selezione	F1 Macro

4.3 Architettura multimodale Dual-Encoder

Il cuore della nostra proposta è un'architettura *Dual-Encoder* progettata per fondere le informazioni provenienti da testo e immagini. Il modello è composto da due rami paralleli che convergono in un classificatore finale.

4.3.1 Encoder testuale e visivo

Il ramo testuale è costituito dal modello BERT (FEEL-IT o UmBERTo, a seconda del task) già fine-tunato nella fase precedente (Sezione 4.2). Riutilizzare gli encoder testuali specializzato sul task ci permette di sfruttare la conoscenza appresa nella fase di addestramento, garantendo embedding contestuali di alta qualità fin dall'inizio del training multimodale, e ci permette di confrontare meglio i risultati con e senza l'aggiunta delle immagini. L'encoder elabora la sequenza di token e produce un vettore di rappresentazione corrispondente al token `[CLS]`.

Il ramo visivo utilizza **ViT-Base-224** (*Vision Transformer*) [30], un modello pre-addestrato da Google. A differenza delle CNN tradizionali, il ViT processa l'immagine suddividendola in patch di dimensione fissa (16×16 pixel) e trattandole come una sequenza di token, alla quale applica meccanismi di self-attention identici a quelli usati nei Transformer testuali. Questa architettura si è rivelata particolarmente efficace nel catturare le relazioni spaziali globali nell'immagine, risultando ideale per il nostro task dove il significato dell'immagine (uno screenshot televisivo, un meme, una foto di scena) deve essere messo in relazione con il testo del post.

4.3.2 Fusione e classificazione

Come illustrato nella Figura 4.1, le rappresentazioni latenti prodotte dai due encoder, l'embedding testuale (vettore `[CLS]` di BERT) e l'embedding visivo (vettore di classe di ViT) vengono **concatenate** per formare un unico vettore multimodale. Questo vettore combinato rappresenta la fusione delle caratteristiche di testo e immagine e costituisce l'input per il classificatore finale.

Per la classificazione, abbiamo utilizzato un approccio basato su catene di classificatori (*Classifier Chains*), particolarmente adatto ai problemi multi-label come il nostro. Nello specifico, abbiamo impiegato l'implementazione `ClassifierChain` dalla libreria Scikit-Learn, che incatena un classificatore di base in una serie di classificatori, uno per ciascuna label da valutare. Il modello scelto è un `SGDClassifier`, configurato con i seguenti parametri:

- `loss='log_loss'`: Indica che il modello è una regressione logistica addestrata con discesa del gradiente stocastico, adatta a produrre probabilità.
- `penalty='l2'`: Applica una regolarizzazione L2 per prevenire l'overfitting.
- `n_jobs=-1`: Utilizza tutti i processori disponibili per parallelizzare il calcolo.
- `random_state=42`: Garantisce la riproducibilità degli esperimenti.

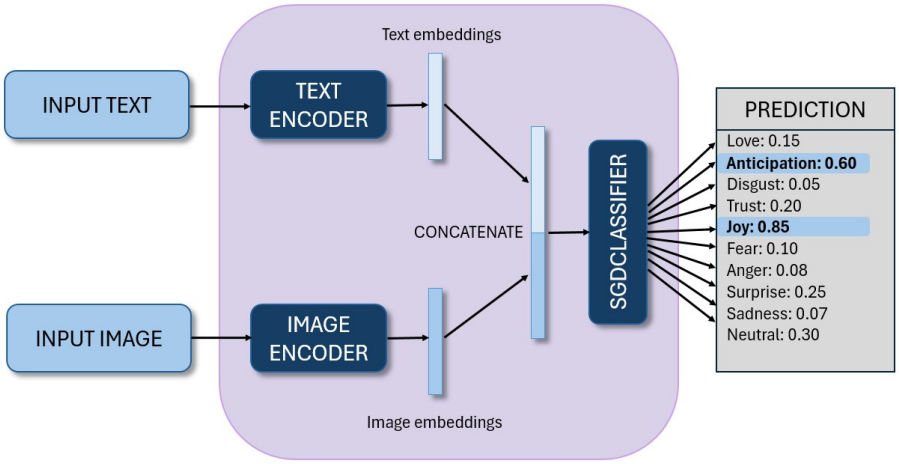


Figura 4.1: Rappresentazione dell'architettura Dual-Encoder. Gli encoder testuale e visivo processano gli input in parallelo. I loro embedding vengono concatenati e forniti al classificatore finale per la predizione.

Questa architettura permette al modello di apprendere interazioni complesse tra le due modalità: l'immagine può confermare il testo (relazione *Additiva*), contraddirlo (relazione *Divergente*, spesso veicolo di ironia) o aggiungere contesto emotivo non esplicitato nelle parole.

Per ciascun task, abbiamo condotto un esperimento aggiuntivo di comparazione diretta: sul dataset multimodale, abbiamo confrontato le prestazioni del modello alimentato con il **solo testo** rispetto a quello alimentato con **testo e immagine**.

4.4 Esperimenti con Pixtral

Per validare la robustezza dei risultati ottenuti con il Dual-Encoder e confrontare il paradigma del fine-tuning specializzato con quello dei Large Multimodal Models, abbiamo condotto una serie di esperimenti con **Pixtral**. A differenza di BERT, che durante l'addestramento apprende latentemente la distribuzione delle correlazioni tra le etichette direttamente dai dati, Pixtral in inferenza non ha accesso a questa conoscenza. Per colmare questo divario, le correlazioni sono state integrate esplicitamente nei prompt testuali.

A prescindere dal task affrontato, Pixtral è stato impiegato in inferenza (Zero-Shot e Three-Shot) esclusivamente sullo split di *test* del **dataset multimodale**. Per gli esperimenti in modalità Fine-Tuning, l'addestramento ha coinvolto solamente lo split di *train* del **dataset multimodale**.

Al fine di inquadrare correttamente i risultati del *test set multimodale* presentati nel successivo Capitolo 5, la Tabella 4.2 riassume la distribuzione delle classi presenti nei 129 post che definiscono questo split. A causa della distribuzione fortemente sbilanciata del dataset originale, alcune classi presentano una minoranza di campioni.

Tabella 4.2: Distribuzione delle etichette nel Test Set del dataset multimodale (129 post).

Etichetta	**Totale (129)**
Emozioni	
Amore	11
Anticipazione	10
Disgusto	19
Fiducia	42
Gioia	29
Neutro	17
Paura	1
Rabbia	6
Sorpresa	16
Tristezza	2
Ironia	
Ironia	18
Non ironico	104
Sarcasmo	7
Target	
Contenitore	77
Contenuto	44
Relazione	
Additiva	68
Divergente	38
Parallela	23

4.4.1 Strategie di Prompting

A differenza di un modello basato su architettura BERT, che viene addestrato per compiti specifici attraverso un processo di *fine-tuning*, Pixtral appartiene alla famiglia dei modelli linguistici di grandi dimensioni (*Large Language Models*, LLM) con architettura *decoder-only*. Questi modelli non richiedono un riaddestramento per ogni nuovo task, ma operano in modalità di inferenza diretta, interpretando le istruzioni fornite tramite un **prompt**. Il prompt diventa quindi uno strumento fondamentale per guidare il modello, spiegandogli il compito da eseguire, il formato della risposta e il contesto

di riferimento. Per questo motivo, abbiamo dovuto abbandonare l'approccio precedente, in cui l'input era costituito unicamente dal testo del post, e abbiamo sviluppato una serie di prompt strutturati.

Per ciascun task (*emotion*, *semiotic relation* e *irony detection*), abbiamo progettato cinque varianti di prompt con livelli crescenti di dettaglio, al fine di valutare la sensibilità del modello alla qualità e quantità delle informazioni fornite. Le varianti sono:

1. **Prompt corto:** Contiene esclusivamente la descrizione essenziale del task e le etichette di classificazione possibili.
2. **Prompt medio:** Espande la versione breve, aggiungendo informazioni contestuali sui programmi televisivi e istruzioni più dettagliate sull'analisi multimodale.
3. **Prompt lungo:** Fornisce una guida completa che include definizioni dettagliate per ogni etichetta, istruzioni esplicite sulla gestione dell'ironia e un contesto approfondito sui programmi TV. Di questa versione, abbiamo testato tre varianti (chiamate long_v1, long_v2 e long_v3) con lievi modifiche lessicali e sintattiche per misurare la robustezza del modello a diverse formulazioni.

Mentre un modello come BERT apprende implicitamente le **correlazioni** tra i dati durante il *fine-tuning*, Pixtral, essendo utilizzato in sola inferenza con il modello pre-addestrato disponibile su Hugging Face[4], non ha questa opportunità. Per sopperire a questa mancanza, abbiamo ipotizzato che inserire esplicitamente le correlazioni più significative (analizzate nel Capitolo 3.4) direttamente nel prompt potesse fornire al modello una conoscenza "pre-digerita" utile alla classificazione.

Abbiamo quindi creato una seconda versione di ogni prompt (corto, medio e lungo) arricchita con la spiegazione delle correlazioni. La quantità di informazione fornita è stata resa proporzionale alla lunghezza del prompt, seguendo soglie decrescenti del coefficiente di Pearson (r):

- I **prompt lunghi** includono tutte le correlazioni con magnitudine $|r| \geq 0.15$.
- I **prompt medi** includono le correlazioni più forti, con $|r| \geq 0.20$.
- I **prompt corti** includono solo le correlazioni molto forti, con $|r| \geq 0.25$.

Questa struttura è stata progettata per verificare se un numero maggiore di correlazioni potesse introdurre rumore e bias, o se, al contrario, limitarsi

[4] `https://huggingface.co/mistral-experimental/pixtral-12b`

alle associazioni più forti potesse offrire al modello segnali più chiari e meno ambigui.

4.4.2 Strategie Zero-Shot e Few-Shot

Gli esperimenti sono stati condotti principalmente con un approccio **zero-shot**, in cui il modello esegue il task basandosi solo sulla descrizione contenuta nel prompt, senza aver mai visto esempi di classificazione. Per il solo task di *Relation Detection*, abbiamo esplorato anche la strategia **few-shot** (nello specifico, *three-shot*), in cui il prompt, oltre alle istruzioni, include tre esempi completi di input e output corretto. L'obiettivo era valutare se fornire al modello esempi concreti potesse migliorare la sua capacità di generalizzazione e comprensione del compito. In Figura 4.2 viene mostrato un esempio di prompt *three-shot*.

Per ogni configurazione di prompt, sono state effettuate tre esecuzioni indipendenti (*run*) e abbiamo riportato la media di Precision, Recall e F1-score. Gli esperimenti sono stati condotti con due diverse temperature di campionamento (0.1 e 0.9) per analizzare l'impatto della stocasticità del modello sui risultati.

Sebbene Pixtral sia un modello nativamente multilingua e i post analizzati siano in italiano, abbiamo scelto di formulare tutti i prompt operativi in lingua inglese. Questa decisione progettuale è supportata da recenti evidenze in letteratura: come dimostrato dallo studio sul corpus BRIGHTER [21], i Large Language Models ottengono sistematicamente prestazioni migliori e più stabili nei task di classificazione testuale quando le istruzioni vengono fornite in inglese anziché nella lingua target dei testi analizzati.

Listing 4.1: Esempio di prompt corto senza correlazioni.

```
You are an expert in emotion classification. Classify the emotions
    expressed in a Twitter post written in Italian, consisting of an image
     and a caption-like text. Choose 1-2 emotions from: Love, Anticipation
    , Disgust, Trust, Joy, Fear, Anger, Surprise, Sadness, Neutral.

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Listing 4.2: Esempio di prompt corto con correlazioni.

```
You are an expert in emotion classification. Classify the emotions
    expressed in a Twitter post written in Italian, consisting of an image
     and a caption-like text. Choose 1-2 emotions from: Love, Anticipation
    , Disgust, Trust, Joy, Fear, Anger, Surprise, Sadness, Neutral.
    Consider the following relationships: Disgust correlates with Sarcasm.
     Anger correlates with Offensivity. Surprise correlates with Content.
    Trust correlates negatively with Irony and Divergent.

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Listing 4.3: Esempio di prompt medio senza correlazioni.

```
You are an expert in emotion classification. Classify the emotions
    expressed in a Twitter post written in Italian, consisting of an image
     and a caption-like text. The task is to analyze both the image and
    the accompanying text, considering how they interact to convey emotion
    , as they do in real Twitter posts. Choose 1-2 emotions from: Love,
    Anticipation, Disgust, Trust, Joy, Fear, Anger, Surprise, Sadness,
    Neutral.

The posts are from two Italian TV shows: Pechino Express (a travel-based
    reality show where contestants face challenges and cultural exchanges)
     and Propaganda Live (a satirical talk show mixing politics, field
    reports, debates, music, and guests).

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Listing 4.4: Esempio di prompt medio con correlazioni.

```
You are an expert in emotion classification. Classify the emotions
    expressed in a Twitter post written in Italian, consisting of an image
     and a caption-like text. The task is to analyze both the image and
    the accompanying text, considering how they interact to convey emotion
    , as they do in real Twitter posts. Choose 1-2 emotions from: Love,
    Anticipation, Disgust, Trust, Joy, Fear, Anger, Surprise, Sadness,
    Neutral.

The posts are from two Italian TV shows: Pechino Express (a travel-based
    reality show where contestants face challenges and cultural exchanges)
     and Propaganda Live (a satirical talk show mixing politics, field
    reports, debates, music, and guests).

Also consider the following relationships: Disgust correlates with Sarcasm
    , Content and Offensivness, but is negatively correlated with
    Container. Trust correlates with Container and negatively with Irony
    and Divergent. Anger correlates with Offensivity. Surprise correlates
    with Content and Divergent, but is negatively correlated with
    Container. Sadness correlates with Content focus. Anticipation
    correlates with Contentainer.

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Listing 4.5: Esempio di prompt lungo senza correlazioni.

```
You are an expert in emotion classification. Classify the emotions
    expressed in a Twitter post written in Italian, consisting of an image
     and a caption-like text. The task is to analyze both the image and
    the accompanying text, considering how they interact to convey emotion
    , as they do in real Twitter posts.

Use only the following set of emotions:
- Love (Affection or appreciation toward someone)
- Anticipation (Expectation of a future event)
- Disgust (Aversion or repulsion)
- Trust (Confidence, admiration, or respect)
- Joy (Positive emotions such as happiness or amusement)
- Fear (Response to threats or danger)
- Anger (Irritation, frustration, or indignation)
- Surprise (Reaction to the unexpected)
- Sadness (Sorrow, grief, or unhappiness)
- Neutral (No strong emotional expression)

Classify the post using only 1 or 2 emotions from this list. If no
    specific emotion is clearly expressed, select Neutral. Pay special
    attention to irony: when it is present, take it into account during
    classification, as it often shifts the intended emotional tone of the
    text.

The posts are from two Italian TV shows:
- Pechino Express: A travel-based reality show where contestants face
    challenges and cultural exchanges with little money.
- Propaganda Live: A satirical talk show mixing politics, field reports,
    debates, music, and guests.

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Listing 4.6: Esempio di prompt lungo con correlazioni.

```
You are an expert in emotion classification. Classify the emotions
    expressed in a Twitter post written in Italian, consisting of an image
     and a caption-like text. The task is to analyze both the image and
    the accompanying text, considering how they interact to convey emotion
    , as they do in real Twitter posts.

Use only the following set of emotions:
- Love (Affection or appreciation toward someone)
- Anticipation (Expectation of a future event)
- Disgust (Aversion or repulsion)
- Trust (Confidence, admiration, or respect)
- Joy (Positive emotions such as happiness or amusement)
- Fear (Response to threats or danger)
- Anger (Irritation, frustration, or indignation)
- Surprise (Reaction to the unexpected)
- Sadness (Sorrow, grief, or unhappiness)
- Neutral (No strong emotional expression)

Classify the post using only 1 or 2 emotions from this list. If no
    specific emotion is clearly expressed, select Neutral. Pay special
    attention to irony: when it is present, take it into account during
    classification, as it often shifts the intended emotional tone of the
    text.

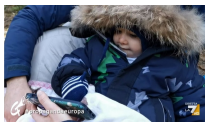
The posts are from two Italian TV shows:
- Pechino Express: A travel-based reality show where contestants face
    challenges and cultural exchanges with little money.
- Propaganda Live: A satirical talk show mixing politics, field reports,
    debates, music, and guests.

Also consider the following relationships between emotional expression and
     other annotation levels:
- Trust correlates with Container and Parallel relationships, and
    negatively with Irony, Divergent and Content.
- Surprise correlates with Content, Divergent relationships, and Irony and
     negatively with Container.
- Sadness correlates with Content and Additive relationships, but
    negatively with Container.
- Anticipation correlates with Content and negatively with Container.
- Disgust correlates with Sarcasm, Divergent relationships, Offensiveness
    and Content and negatively with Parallel relationships and Container
- Anger correlates with Offensiveness and Sarcasm
- Joy correlates with Irony

The sentences to analyze are always preceded by additional information
    from other annotation layers.

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

[Utente] – Esempio 1:



You are an expert in multimodal classification. Classify the relationship between an Italian Twitter post's text and image. Choose only one of the following categories: Additive (the text and image enrich each other), Parallel (the text and image express the same idea), Divergent (the text and image convey contrasting meanings, often producing irony or humor).

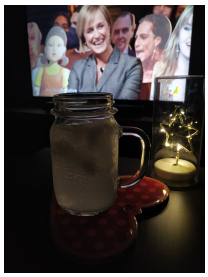
Your response must be without any additional text or explanations, and formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]

buonanotte piccolo! spero che tu stia dormendo in un caldo lettino, facendo tanti bei sogni, lontano da tutta questa disumanita. grazie a #propagandalive <url>

[Sistema]:

Relationship detected: Additive

[Utente] – Esempio 2:



You are an expert in multimodal classification. Classify the relationship between an Italian Twitter post's text and image. Choose only one of the following categories: Additive (the text and image enrich each other), Parallel (the text and image express the same idea), Divergent (the text and image convey contrasting meanings, often producing irony or humor).

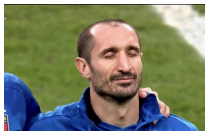
Your response must be without any additional text or explanations, and formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]

moscow mule e #propagandalive. <url>

[Sistema]:

Relationship detected: Parallel

[Utente] – Esempio 3:



You are an expert in multimodal classification. Classify the relationship between an Italian Twitter post's text and image. Choose only one of the following categories: Additive (the text and image enrich each other), Parallel (the text and image express the same idea), Divergent (the text and image convey contrasting meanings, often producing irony or humor).

Your response must be without any additional text or explanations, and formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]

toninelli: "grazie a #propagandalive" la reazione di zoro: <url>

[Sistema]:

Relationship detected: Divergent

[Utente] – Query Finale (Input):

[Nuova immagine da analizzare]

You are an expert in multimodal classification. Classify the relationship between an Italian Twitter post's text and image. Choose only one of the following categories: Additive, Parallel, Divergent.

Your response must be without any additional text or explanations, and formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]

[Nuovo testo da analizzare]

[Sistema in attesa di generare l'output...]

Figura 4.2: Prompt corto per *Relation Detection* (senza correlazioni) in formato *three-shot*

4.4.3 Fine-tuning di Pixtral

In aggiunta agli esperimenti di inferenza con prompting, abbiamo condotto il fine-tuning di Pixtral sui dati di MultiEMit per valutare il contributo dell'addestramento diretto rispetto al solo prompting. Per ciascun task, la strategia di base usata per il fine-tuning consisteva nel selezionare due varianti isolate di prompt: il modello *short* e la variante *long* che in fase di Zero-Shot, senza correlazioni fornite nel prompt, aveva performato meglio.

Un'eccezione riguarda specificamente il task di Emotion Detection. Per le emozioni, il fine-tuning è stato effettuato utilizzando la variante *long_v1*. Successivamente all'addestramento e alla raccolta dei test, ci siamo tuttavia accorti che un numero ristretto di risposte in output non veniva estratto e categorizzato correttamente a causa della rigidità dell'espressione regolare. Dopo aver aggiornato e perfezionato il sistema basato su *regex* per l'estrazione e validazione delle predizioni dall'output generativo di Pixtral, abbiamo ri-analizzato le prestazioni in Zero-Shot. Con il parser corretto, è emerso che la variante *long_v2* risultava in realtà leggermente superiore alla *long_v1*, con un piccolo vantaggio di meno dell'1%. Data l'irrilevanza statistica dello scarto e l'elevato costo computazionale richiesto per un addestramento, abbiamo scelto di non ripetere l'esperimento e mantenere i risultati consolidati con *long_v1*.

Nella Tabella 4.3 mostra i parametri utilizzati per il fine-tuning di Pixtral.

Tabella 4.3: Iperparametri di addestramento per il fine-tuning di Pixtral.

Parametro	**Valore**
Learning rate	3×10^{-5}
Batch size (train/eval)	1
Gradient accumulation steps	8
Epoche	2
Weight decay	0.01
LR scheduler	Lineare
Precisione	FP16
Gradient checkpointing	Sì
Valutazione / Salvataggio	Ogni 10 step

Le differenze cone la configurazione usata per BERT riflettono la diversa scala dei modelli e dei loro input. I modelli BERT, con circa 110 milioni di parametri, consentono batch size più grandi (numero di input elaborati prima di effettuare un aggiornamento dei pesi) e un numero maggiore di epoche. Pixtral, essendo un LMM (oltre che l'esempio da classificare richiede anche descrizione del task e l'immagine), ha input di dimensione molto

maggiore rispetto a BERT e di conseguenza ha bisogno più spazio di memoria durante l' allenamento e inferenza. Per questo motivo abbiamo usato un setup di parametri più conservativo: il batch size è ridotto a 1 con gradient accumulation su 8 step (simulando un batch effettivo di 8 calcolando i gradienti per un solo esempio alla volta e sommandoli prima di aggiornare i pesi, abbattendo così drasticamente il consumo di memoria), il numero di epoche è limitato a 2 e la precisione FP16 con gradient checkpointing sono necessari per ridurre l'occupazione di memoria GPU.

4.4.4 Addestramento tramite LoRA (Low-Rank Adaptation)

L'addestramento di un modello linguistico di grandi dimensioni come Pixtral richiede risorse computazionali ingenti. Per superare questi limiti hardware ed evitare i costi proibitivi di un addestramento completo, abbiamo adottato la tecnica LoRA (Low-Rank Adaptation) tramite la libreria PEFT (Parameter-Efficient Fine-Tuning). Questa metodologia prevede infatti di mantenere inalterati i pesi originali del modello, inserendo e addestrando esclusivamente nuove matrici di rango inferiore all'interno dei layer dell'architettura. In questo modo, si riduce drasticamente il carico computazionale della backpropagation senza alterare la struttura base della rete.

Nello specifico, abbiamo configurato LoRA con un rank pari a 16 e un fattore di scaling (`lora_alpha`) pari a 32, applicando l'adattamento a tutti i moduli lineari. Il Listato 4.7 mostra la configurazione utilizzata per l'inizializzazione.

Listing 4.7: Configurazione di LoRA per il fine-tuning di Pixtral tramite PEFT.

```
from peft import LoraConfig, get_peft_model

lora_config = LoraConfig(
    r=16,
    lora_alpha=32,
    use_rslora=True,
    target_modules="all-linear",
    lora_dropout=0.1,
    bias="none",
    task_type="CAUSAL_LM"
)

model = get_peft_model(model, lora_config).to(device)
model.print_trainable_parameters()
# trainable params: 66,322,432 || all params: 12,749,062,144 || trainable
    %: 0.5202
```

Questo setup ci ha permesso di addestrare attivamente una porzione estremamente ridotta della rete, pari ad appena lo 0.52% dei parametri totali. Osserviamo che questa drastica riduzione non ha compromesso l'efficacia del fine-tuning.

Capitolo 5

Risultati Sperimentali e Valutazione

In questo capitolo presentiamo e analizziamo i risultati ottenuti dalle architetture descritte. La discussione è organizzata attorno ai tre task principali definiti nel nostro studio: il riconoscimento delle emozioni, il rilevamento dell'ironia e la classificazione della relazione semiotica.

5.1 Setup Sperimentale

Per garantire una valutazione rigorosa e riproducibile, tutti gli esperimenti seguono un protocollo metodologico comune. Le performance dei modelli sono state misurate utilizzando le metriche standard di **Precision, Recall e F1-score**. Data la natura sbilanciata delle classi nel nostro dataset, abbiamo adottato la media **macro** per l'F1-score, in quanto pesa equamente ogni classe indipendentemente dalla sua frequenza.

Per assicurare la robustezza statistica, ogni esperimento è stato eseguito per tre volte (tre *run* indipendenti) con seed diversi, riportando la media delle performance.

Per i diversi modelli sono stati utilizzati train e test set differenti in base alle necessitá del task. Di seguito esplicitiamo il protocollo adottato.

Per i task di riconoscimento di **Emozioni** e **Ironia**, l'obiettivo era creare un encoder testuale (basato su BERT) il più robusto possibile. Per farlo, la fase di addestramento ha utilizzato un insieme di dati aggregato, composto da:

- Lo split di addestramento del **dataset testuale** (arricchito con dati esterni da EMit per le emozioni e IronITA per l'ironia).

- La sola componente testuale dello split di addestramento del **dataset multimodale**.

Successivamente, la fase di valutazione è stata segmentata. I modelli sono stati testati separatamente su due fronti: prima sul **test set del dataset testuale**, per misurare le performance in un contesto puramente unimodale; poi sul **test set del dataset multimodale**, per creare una baseline "cieca" (solo testo) con cui confrontare i modelli multimodali.

Il task di estrazione della **Relazione Semiotica** segue un'impostazione diversa, poiché l'etichetta di relazione semiotica esiste solo per i dati multimodali. Di conseguenza, l'addestramento della baseline solo testuale ha utilizzato esclusivamente gli split di addestramento e di test del **dataset multimodale** di MultiEMit.

Infine, il Large Multimodal Model **Pixtral** è stato valutato in modalità Zero-Shot e Three-Shot solo sul test set multimodale. La sua fase di fine-tuning, analogamente, ha utilizzato unicamente lo split di addestramento multimodale.

È utile fare una distinzione sul comportamento dei modelli in fase di inferenza. **BERT** (e la relativa architettura multimodale con ViT) è un modello discriminativo. Affronta il task calcolando le probabilità di classificazione in modo **deterministico**: a parità di input, l'output sarà sempre identico. Questo tipo di modello non è influenzato dal parametro di *temperature*, tipico dei modelli generativi.

Al contrario, **Pixtral** è un modello generativo. La sua predizione non è un calcolo diretto, ma un processo di **campionamento di token**. Per questo motivo, abbiamo esplorato il suo comportamento a due diversi valori di temperatura, ovvero il parametro che regola la casualità del processo di generazione:

- **T=0.1**, per ridurre la casualità e spingere il modello verso output più prevedibili e stabili.
- **T=0.9**, per concedergli maggiore "libertà creativa" e flessibilità, specialmente di fronte a input ambigui.

5.2 Riconoscimento delle Emozioni

5.2.1 Evoluzione delle Baseline Testuali e Codifica delle Emozioni

L'ottenimento di una base testuale solida per l'emotion detection, fondamentale per il successivo framework multimodale, ha richiesto una lunga

fase di sperimentazione sulle strategie di codifica delle etichette (riassunta nella Tabella 5.3). Indipendentemente dalla configurazione di classificazione (sperimentata come multiclasse o multi-label nei vari tentativi pregressi), come modello su cui effettuare i nostri addestramenti abbiamo scelto **FEEL-IT**, un modello BERT pre-addestrato per l'*emotion recognition* testuale in lingua italiana. Tale selezione è stata prettamente pragmatica: disporre di un modello deterministico già dotato di una solida rappresentazione latente delle sfumature emotive italiane ci ha fornito il *background* discriminativo ottimale di partenza, fungendo da solida base su cui operare variazioni e fine-tuning senza dover apprendere le feature sintattiche e semantiche da zero. Durante il periodo di ricerca, abbiamo esplorato le seguenti formulazioni del problema:

1. **Approcci Multiclasse su combinazioni (Plutchik):** Basandoci sulla teoria di Plutchik, è possibile unire più emozioni primarie in un'unica emozione complessa (diade). Inizialmente, estraendo tutte le occorrenze simultanee, si ottenevano 27 combinazioni di emozioni più la classe "Neutro", per un totale di 28 etichette univoche (modello **EMOTION-28**). Tuttavia, molti esempi contenevano più di tre etichette associate, casistica per la quale lo schema di Plutchik non consente l'unione diretta in una singola voce. Per ovviare al problema, abbiamo deciso di compattarle garantendo al massimo due emozioni combinate: nei casi di triple, è stata rimossa una delle componenti per rimappare il tutto in una singola emozione derivata che meglio rappresentasse l'integrità del messaggio. Seguendo questo schema sperimentale (dettagliato nella Tabella 5.1), le combinazioni sono state ri-mappate in 19 emozioni più il neutro (modello **EMOTION-20**). Nonostante lo sforzo di riduzione, la grave sparsità dei dati ha reso le predizioni di tali modelli inefficaci (F1 Macro tra 0.05 e 0.17).

Tabella 5.1: Mappatura di riduzione dalle 28 combinazioni originali a 20 emozioni derivate (secondo Plutchik).

Combinazione Originale	**Nuova Classe**
[Fiducia]	Fiducia
[Amore, Gioia]	Amore
[Disgusto, Rabbia, Sorpresa]	Disprezzo
[Gioia]	Gioia
[Gioia, Sorpresa]	Delizia
[Anticipazione, Tristezza]	Pessimismo
[Disgusto, Sorpresa, Tristezza]	Rimorso
[Fiducia, Tristezza]	Sentimentalità
[Tristezza]	Tristezza
[Disgusto, Rabbia]	Disprezzo
[Fiducia, Gioia]	Amore
[Anticipazione, Gioia]	Ottimismo
[Anticipazione, Fiducia]	Speranza
[Disgusto]	Disgusto
[Amore, Fiducia, Gioia]	Amore
[Paura, Tristezza]	Disperazione
[Sorpresa, Tristezza]	Disapprovazione
[Rabbia]	Rabbia
[Amore]	Amore
[Anticipazione]	Anticipazione
[Fiducia, Sorpresa]	Curiosità
[Disgusto, Rabbia, Tristezza]	Rimorso
[Disgusto, Sorpresa]	Incredulità
[Sorpresa]	Sorpresa
[Disgusto, Tristezza]	Rimorso
[Fiducia, Gioia, Sorpresa]	Delizia
[Amore, Fiducia]	Amore
[Neutro]	Neutro

2. **Mappatura sulle emozioni Big 6 (Ekman):** Per ridurre ulteriormente lo spazio delle classi e aumentare sistematicamente la densità dei campioni per classe, abbiamo tentato di astrarre le 20 classi ottenute seguendo il framework delle 6 emozioni fondamentali (*Big 6*) elaborato da Paul Ekman [22]. Le associazioni tra le derivate di Plutchik e le macro-categorie universali sono espresse nella Tabella 5.2. Sebbene sull'addestramento base di questo set (**EMOTION-Big6**) l'accuratezza sembrasse schizzata al 58%, il modello apprendeva collassando: favoriva ciecamente la dominante classe "Gioia" e ignorava sistematicamente le classi minoritarie, confinando il Macro F1 ad uno scarno 35%. Ripetuti accorpamenti correttivi (**EMOTION-Big6-Reworked**), come l'unione mirata di Paura e Tristezza in un singolo cluster per irrobustirne le istanze, hanno portato un lievissimo incremento dell'F1 testuale (39%), ma tale stratagemma tendeva a sacrificare le peculiarità espressive che le annotazioni originali volevano catturare.

Tabella 5.2: Riduzione dalle 20 emozioni residue alle 6 emozioni fondamentali (Big 6 Ekman).

Classe Plutchik	**Classe Ekman**	**Classe Plutchik**	**Classe Ekman**
Fiducia	Gioia	Speranza	Gioia
Amore	Gioia	Disgusto	Disgusto
Disprezzo	Disgusto	Disperazione	Paura
Gioia	Gioia	Disapprovazione	Rabbia
Delizia	Gioia	Rabbia	Rabbia
Pessimismo	Tristezza	Anticipazione	Neutro
Rimorso	Paura	Curiosità	Sorpresa
Sentimentalità	Tristezza	Incredulità	Sorpresa
Tristezza	Tristezza	Sorpresa	Sorpresa
Ottimismo	Gioia	Neutro	Neutro

3. **Svolta Multi-label (One-Hot) ed estensione del Dataset:** Abbandonato l'approccio multiclasse, abbiamo adottato una valutazione **One-Hot Encoding Multi-label a 10 componenti binarie indipendenti** (le 8 emozioni primarie di Plutchik, più la classe Neutro e la classe Amore). Il primissimo test testuale basato autonomamente su questo nuovo framework di codifica ha registrato un F1-score limitato a 0.33. Per superare questa barriera, abbiamo introdotto una novità cruciale nel pipeline: abbiamo integrato il dataset **EMit** (proveniente da EVALITA) all'interno del nostro *train set*, così da aumentare artificialmente la frequenza delle classi minoritarie sbilanciate. Abbinando questo set potenziato con la conoscenza base di FEEL-IT, abbiamo condotto le seguenti varianti di fine-tuning testuale:

    - *Modello Base*: Abbiamo creato un modello base effettuando un fine-tuning di FEEL-IT sul dataset rinforzato (MultiEMit + EMit) normale, ovvero senza la presenza di correlazioni in input, per 5 epoche. Questa mossa ha permesso di metabolizzare il nuovo vocabolario bilanciato e raggiungere un buon F1-score testuale di **0.46**.
    - *Modello con Correlazioni*: A puro scopo comparativo, abbiamo creato un modello con correlazioni effettuando il fine-tuning direttamente su FEEL-IT, addestrandolo sul nostro dataset nel quale sono state inserite le correlazioni statistiche. L'esposizione a questo contesto ha stimolato l'F1-score portandolo a **0.54**.
    - *Modello Base ri-addestrato con Correlazioni (Modello Definitivo)*: Infine, abbiamo preso il nostro modello base e lo abbiamo ri-addestrato, usando questa volta le correlazioni, per altre 5 epoche. Questo ha portato l'addestramento totale a 10 epoche per questo modello. Suddividere l'apprendimento in queste due fasi isolate si è rivelato un innesco risolutivo, issando le performance testuali definitive allo specchio di **0.59** in F1-score e **0.41** in Accuratezza.

Tabella 5.3: Evoluzione delle performance per il task testuale di Emotion Detection.

Modello / Strategia di codifica	**Accuratezza**	**F1-score**
Approcci Multiclasse (Combinazioni esplose o mappature)		
EMOTION-28 (Combinazioni dirette)	0.22	0.05
EMOTION-20 (Combinazioni filtrate)	0.23	0.17
EMOTION-Big6 (Mapping su 6 emozioni standard)	**0.58**	0.35
EMOTION-Big6-Reworked (Classi ri-bilanciate)	0.42	0.39
Sistemi Multi-label ed estensioni Dataset (10 classi)		
One-Hot Encoding testuale base (senza EMit)	0.21	0.33
Modello Base (FEEL-IT su MultiEMit+EMit)	0.32	0.46
Modello con Correlazioni	0.38	0.54
Modello Base ri-addestrato con Correlazioni	0.41	**0.59**

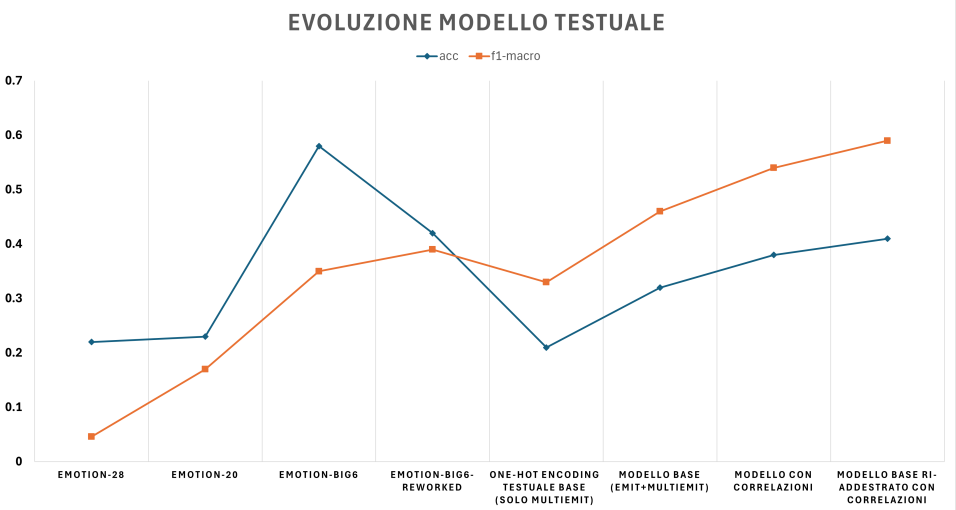


Figura 5.1: Evoluzione delle performance del modello testuale.

Nella Tabella 5.3, gli ultimi tre modelli (*Modello Base*, *Modello con Correlazioni*, *Modello Base ri-addestrato con Correlazioni*) rappresentano la baseline testuale valutata sul test set del dataset testuale. Una rappresentazione grafica dell'evoluzione di questi modelli è mostrata nella Figura 5.1.

5.2.2 Emozioni Text-only vs Dual-Encoder

Definito l'encoder puramente testuale (Sezione 4.2), abbiamo valutato l'impatto dell'architettura Dual-Encoder che integra il segnale visivo di ViT.

La Tabella 5.4 mette a confronto le prestazioni sul test set multimodale. In questo scenario, valutiamo sia l'encoder testuale "cieco" (che osserva solo

il testo dei post multimodali), sia l'architettura completa che sfrutta testo e immagine.

Come mostra la tabella, l'integrazione dell'immagine migliora le prestazioni rispetto all'uso del solo testo. Questo risultato conferma la nostra ipotesi iniziale: nei social media, le immagini forniscono un contesto visivo fondamentale per disambiguare emozioni che il solo testo lascerebbe ambigue. Inoltre, l'aggiunta delle correlazioni statistiche in fase di addestramento porta a un ulteriore incremento dell'efficacia. Guidare il modello con informazioni di contesto strutturate (ad esempio indicando esplicitamente le relazioni tipiche tra certe emozioni e l'ironia) aiuta la rete a scartare le interpretazioni meno probabili.

Tabella 5.4: Risultati Emotion Detection: confronto valutato sul test set multimodale.

Configurazione sperimentale	**F1-score**
Baseline testuale cieca sul dataset multimodale	
Solo testo (subset multimodale, senza correlazioni)	0.30
Solo testo (subset multimodale, con correlazioni)	0.37
Modello multimodale completo (testo + immagine)	
Dual-Encoder BERT-ViT (testo+immagine, senza correlazioni)	0.43
Dual-Encoder BERT-ViT (testo+immagine, con correlazioni)	**0.45**

5.2.3 Esperimenti Multimodali con Pixtral

Per comprendere come i grandi modelli linguistici (LLM) affrontino i contesti sfumati della Social TV, abbiamo condotto esperimenti mirati utilizzando Pixtral. La Tabella 5.5 confronta l'approccio specializzato Dual-Encoder con le diverse configurazioni testate su Pixtral.

Durante il fine-tuning di Pixtral abbiamo osservato un fenomeno peculiare: il modello tendeva a generare frequenti allucinazioni, producendo liste di etichette molto più lunghe del necessario. Tuttavia, un'analisi qualitativa dei risultati ha rivelato una logica latente. Le emozioni autogenerate non apparivano in ordine casuale, ma sembravano ordinate in base a una confidenza decrescente.

Per sfruttare questa intuizione, abbiamo introdotto in fase di post-elaborazione un parametro di troncamento ($n = 2$), estraendo unicamente le prime due emozioni suggerite. Come evidenziato dai risultati nella Tabella 5.5 (confrontando le righe "Finetuned (n=2)" con "Finetuned (all predictions)"), questa regola ha arginato efficacemente i falsi positivi, ripulendo il segnale utile e migliorando le prestazioni complessive. Un'analisi più approfondita sulle cause di questo comportamento generativo è rimandata alla Sezione 6.2.

Osserviamo inoltre un andamento interessante nei test zero-shot: i prompt più corti ottengono spesso risultati equivalenti o persino migliori rispetto a quelli lunghi e dettagliati. Questo comportamento suggerisce che fornire eccessive istruzioni testuali rischia di introdurre rumore semantico, distraendo l'attenzione del modello dal task principale (la classificazione multi-label).

Confrontando le aspettative con i risultati finali, notiamo che sebbene il fine-tuning aiuti Pixtral a migliorare rispetto alle configurazioni zero-shot, l'architettura dedicata Dual-Encoder mantiene il primato sul task. Questo dimostra che, per domini specifici e complessi come il riconoscimento delle emozioni in lingua italiana, un modello leggero ma profondamente specializzato sui dati target risulta ancora più affidabile di un grande modello generalista.

Tabella 5.5: Confronto completo Emotion Detection tra Dual-Encoder e Pixtral a Temperature $T = 0.1$ e $T = 0.9$. FT = Finetune, ZS = Zero-Shot

Modello	**Configurazione**	**T = 0.1 F1**	**T = 0.9 F1**
BERT-ViT	FT (Con Corr.)	**0.450**	**0.450**
BERT-ViT	FT (No Corr.)	0.430	0.430
Pixtral (long_v1)	FT (n=2)	0.426	0.359
Pixtral (short)	FT (n=2)	0.397	0.373
Pixtral (short)	FT (all predictions)	0.318	0.312
Pixtral (short)	ZS (Con Corr.)	0.291	0.251
Pixtral (long_v1)	ZS (Con Corr.)	0.275	0.266
Pixtral (medium)	ZS (Con Corr.)	0.269	0.262
Pixtral (long_v2)	ZS (No Corr.)	0.266	0.237
Pixtral (long_v1)	ZS (No Corr.)	0.261	0.261
Pixtral (short)	ZS (No Corr.)	0.261	0.291
Pixtral (long_v3)	ZS (Con Corr.)	0.258	0.262
Pixtral (medium)	ZS (No Corr.)	0.254	0.250
Pixtral (long_v2)	ZS (Con Corr.)	0.253	0.286
Pixtral (long_v1)	FT (all predictions)	0.238	0.290
Pixtral (long_v3)	ZS (No Corr.)	0.220	0.215

5.3 Rilevamento dell'Ironia

5.3.1 Ironia Text-only vs Dual-Encoder

Il rilevamento dell'ironia rappresenta una delle sfide più complesse nell'analisi del linguaggio naturale, poiché richiede di andare oltre il significato letterale del testo per coglierne il reale intento comunicativo. Poiché non disponevamo di un modello pre-addestrato specifico per l'ironia che fosse

paragonabile a FEEL-IT per le emozioni, abbiamo adottato una strategia di addestramento in due fasi per costruire la nostra baseline testuale.

In primo luogo, abbiamo effettuato noi stessi un fine-tuning del modello linguistico di base *UmBERTo* sul dataset esterno IronITA. Questo passaggio preparatorio ha fornito all'encoder testuale una solida competenza di base sui pattern tipici dell'ironia e del sarcasmo in lingua italiana. Successivamente, questo modello "inizializzato" è stato ulteriormente fine-tunato sui dati testuali di MultiEMit.

Valutando i risultati sul test set puramente testuale (Tabella 5.6), osserviamo che l'integrazione delle correlazioni statistiche migliora sensibilmente le capacità predittive della rete rispetto all'approccio privo di contesto aggiuntivo.

Tabella 5.6: Risultati Irony Detection: valutazione della baseline testuale sul test set testuale.

Configurazione sperimentale	**F1-score**
Solo testo (senza correlazioni)	0.44
Solo testo (con correlazioni)	**0.52**

Il passo successivo è stato spostare la valutazione sul test set del dataset multimodale (Tabella 5.7), confrontando l'encoder testuale "cieco" (che valuta solo il testo) con l'architettura Dual-Encoder (che osserva testo e immagine).

Tabella 5.7: Risultati Irony Detection: valutazione comparativa sul test set multimodale.

Configurazione sperimentale	**F1-score**
Baseline testuale cieca sul dataset multimodale	
Solo testo (subset multimodale, senza correlazioni)	0.67
Solo testo (subset multimodale, con correlazioni)	0.71
Modello multimodale completo (testo + immagine)	
Dual-Encoder BERT-ViT (testo+immagine, senza correlazioni)	0.63
Dual-Encoder BERT-ViT (testo+immagine, con correlazioni)	**0.74**

Analizzando i risultati in assenza di correlazioni, notiamo un fenomeno inaspettato: il modello alimentato col solo testo supera il sistema multimodale. In pratica, aggiungere l'immagine senza fornire ulteriore contesto degrada le prestazioni del sistema. Spieghiamo questa anomalia attraverso due ipotesi complementari:

1. **La natura dell'ironia (Rumore Semantico):** A differenza del riconoscimento delle emozioni, dove testo e immagine si supportano in mo-

do coerente, l'ironia si basa strutturalmente sull'incongruenza. Spesso l'immagine mostra qualcosa di completamente slegato o opposto a quanto affermato nel testo. Senza una guida esplicita, le feature visive estratte non aggiungono informazioni utili, ma si trasformano in puro rumore semantico che confonde la buona analisi testuale.

2. **Il Modality Gap:** Questa interpretazione è supportata dalla letteratura sul *Modality Gap* [31]. Modelli pre-addestrati separatamente (UmBERTo per il testo e ViT per le immagini) tendono a proiettare i loro vettori in regioni distanti dello spazio di rappresentazione. Forzare il classificatore a unire questi spazi così lontani senza una logica esterna di collegamento porta a un risultato inferiore rispetto all'utilizzo della singola modalità testuale.

La validità di queste ipotesi trova conferma nel momento in cui forniamo le correlazioni al modello. Dotando l'architettura Dual-Encoder di questo supporto contestuale, il sistema multimodale riesce a dare un senso all'incongruenza visiva, superando nettamente la baseline testuale e dominando lo scenario.

5.3.2 Esperimenti Multimodali con Pixtral

Il confronto sull'ironia con il modello generativo Pixtral (Tabella 5.8) evidenzia una marcata difficoltà dell'LLM in modalità zero-shot.

Tabella 5.8: Confronto completo Pixtral vs Dual-Encoder in Irony Detection. FT = Finetune, ZS = Zero-Shot

Modello	**Configurazione**	**T = 0.1 F1**	**T = 0.9 F1**
BERT-ViT	FT (Con Corr.)	**0.740**	**0.740**
BERT-ViT	FT (No Corr.)	0.630	0.630
Pixtral (long_v2)	ZS (Con Corr.)	0.512	0.396
Pixtral (long_v2)	FT (all predictions)	0.405	0.454
Pixtral (short)	ZS (Con Corr.)	0.348	0.298
Pixtral (long_v3)	ZS (Con Corr.)	0.340	0.281
Pixtral (short)	FT (all predictions)	0.329	0.394
Pixtral (medium)	ZS (Con Corr.)	0.264	0.270
Pixtral (long_v1)	ZS (Con Corr.)	0.248	0.295
Pixtral (long_v2)	ZS (No Corr.)	0.165	0.218
Pixtral (long_v3)	ZS (No Corr.)	0.148	0.198
Pixtral (long_v1)	ZS (No Corr.)	0.126	0.158
Pixtral (short)	ZS (No Corr.)	0.054	0.108
Pixtral (medium)	ZS (No Corr.)	0.051	0.137

Quando Pixtral viene privato delle informazioni sulle correlazioni, le sue prestazioni crollano drasticamente. L'inserimento delle correlazioni tramite prompt testuale si rivela quindi un supporto cruciale, innalzando in modo notevole la capacità della rete di identificare i pattern ironici. Il modello necessita infatti di ancore contestuali forti per comprendere una divergenza semantica così complessa.

Tuttavia, confrontando le metriche finali, l'architettura dedicata Dual-Encoder mantiene indiscutibilmente il primato. Questo dato conferma che, per sfumature linguistiche complesse come l'ironia nel dominio della televisione italiana, un addestramento dedicato e strutturato risulta ancora superiore rispetto alla flessibilità di un approccio puramente generativo.

5.4 Riconoscimento delle Relazioni Semiotiche

5.4.1 Relazioni Testuale vs Dual-Encoder

Per il task di classificazione delle relazioni semiotiche abbiamo seguito un'impostazione metodologica simile a quella dell'ironia, ma con un vincolo importante sui dati: non disponendo di dataset esterni con etichette compatibili, l'addestramento si è basato esclusivamente sul dataset multimodale MultiEMit.

In un primo momento, abbiamo addestrato una baseline puramente testuale basata su *UmBERTo*, oscurando completamente le immagini. Intuitivamente, l'individuazione di una relazione testo-immagine dovrebbe richiedere la vista. Tuttavia, analizzando i risultati nella Tabella 5.9, osserviamo che il modello testuale riesce a raggiungere prestazioni notevoli. Questo accade perché la rete impara a riconoscere specifici pattern lessicali latenti: ad esempio, frasi puramente descrittive si associano spesso a immagini con relazione di tipo *Parallelo*, mentre testi ricchi di espansioni contestuali si legano frequentemente a relazioni *Additive*.

Tabella 5.9: Risultati Relation Detection: confronto tra baseline testuale e Dual-Encoder (stesso test set multimodale per tutti i blocchi).

Configurazione sperimentale	**F1-score**
Baseline testuale (solo testo su dataset multimodale)	
Solo testo (senza correlazioni)	0.61
Solo testo (con correlazioni)	0.66
Modello multimodale (testo + immagine)	
Dual-Encoder BERT-ViT (testo+immagine, senza correlazioni)	0.64
Dual-Encoder BERT-ViT (testo+immagine, con correlazioni)	**0.69**

Il passaggio all'architettura Dual-Encoder, che introduce l'elaborazione del segnale visivo tramite ViT, spinge ulteriormente in alto le prestazioni. Come ci si può attendere, fornire al modello la possibilità di "vedere" l'immagine migliora la comprensione della scena. Anche in questo caso, però, è l'aggiunta delle correlazioni tramite prompt testuale a garantire il salto di qualità definitivo, permettendo al sistema completo di raggiungere l'apice dell'efficacia nell'identificazione delle tre sottocategorie.

5.4.2 Esperimenti Multimodali con Pixtral

Per valutare il comportamento del LLM generativo in questo task, oltre alle configurazioni Zero-Shot abbiamo introdotto un setting *Three-Shot*. In questa modalità, abbiamo fornito a Pixtral tre esempi concreti di classificazione corretta all'interno del prompt, con l'obiettivo di guidare il modello verso un ragionamento più strutturato.

La Tabella 5.10 raccoglie i risultati di questi esperimenti. Come possiamo notare, il fine-tuning continuo di Pixtral (nella variante con prompt lungo) accorcia il divario prestazionale con le architetture specializzate, pur non riuscendo a superarle.

Tabella 5.10: Confronto completo Pixtral vs Dual-Encoder in Relation Detection.FT = Finetune, ZS = Zero-Shot, TS = Three-Shots

Modello	**Configurazione**	**T = 0.1 F1**	**T = 0.9 F1**
BERT-ViT	Fine-Tune (Con Corr.)	**0.690**	**0.690**
BERT-ViT	Fine-Tune (No Corr.)	0.640	0.640
Pixtral (long_v1)	FT (all predictions)	0.613	0.574
Pixtral (short)	FT (all predictions)	0.555	0.546
Pixtral (long_v3)	ZS (Con Corr.)	0.517	0.486
Pixtral (long_v3)	TS (Con Corr.)	0.487	0.508
Pixtral (long_v2)	TS (Con Corr.)	0.483	0.530
Pixtral (medium)	TS (Con Corr.)	0.480	0.469
Pixtral (long_v1)	TS (Con Corr.)	0.467	0.495
Pixtral (medium)	ZS (Con Corr.)	0.429	0.414
Pixtral (long_v2)	TS (No Corr.)	0.424	0.402
Pixtral (medium)	TS (No Corr.)	0.403	0.381
Pixtral (long_v1)	ZS (Con Corr.)	0.394	0.409
Pixtral (medium)	ZS (No Corr.)	0.388	0.359
Pixtral (long_v3)	TS (No Corr.)	0.387	0.359
Pixtral (long_v1)	ZS (No Corr.)	0.387	0.408
Pixtral (short)	TS (Con Corr.)	0.387	0.448
Pixtral (long_v2)	ZS (Con Corr.)	0.382	0.367
Pixtral (long_v1)	TS (No Corr.)	0.369	0.414
Pixtral (short)	ZS (Con Corr.)	0.359	0.392
Pixtral (short)	TS (No Corr.)	0.355	0.378
Pixtral (long_v3)	ZS (No Corr.)	0.344	0.391
Pixtral (long_v2)	ZS (No Corr.)	0.323	0.315
Pixtral (short)	ZS (No Corr.)	0.242	0.304

Nonostante la superiorità generale dell'approccio Three-Shot, un dato interessante emerge dal confronto tra le modalità di inferenza: il setting Zero-Shot ottiene in alcuni casi risultati alla pari, o superiori, rispetto al contesto Three-Shot. Possiamo spiegare questo fenomeno analizzando il bias indotto dagli esempi forniti al modello. Includendo nel prompt esattamente un esempio per ciascuna delle tre relazioni semiotiche, il LLM è stato implicitamente condizionato a considerarle equiprobabili. Tuttavia, la distribuzione reale delle classi nel nostro dataset è fortemente sbilanciata. Di conseguenza, di fronte a meme ambigui o di difficile interpretazione, questo bias ha spinto il modello a sovrastimare la probabilità delle classi minoritarie, portando a un aumento dei falsi positivi. Al contrario, operando in regime Zero-Shot, Pixtral ha evitato questa forzatura statistica, basandosi unicamente sulla propria capacità di astrazione generale.

5.5 Discussione dei Risultati e Limiti

Alla luce degli esperimenti condotti sui tre task principali, possiamo trarre alcune conclusioni fondamentali sull'uso del contesto multimodale.

I risultati confermano che l'integrazione della componente visiva è cruciale per interpretare correttamente i post sui social media. Specialmente nel contesto televisivo, infatti, l'immagine fornisce spesso la chiave di lettura per decodificare il testo. Tuttavia, come abbiamo osservato in particolare per l'ironia, non è sufficiente "guardare" l'immagine: il modello deve essere messo in condizione di "capire" come testo e foto interagiscono tra loro, valutando se si supportano o si contraddicono.

Questo ci porta alla seconda evidenza chiave del nostro lavoro: l'importanza delle annotazioni multi-livello. L'utilizzo delle correlazioni statistiche tra le diverse etichette (emozioni, ironia, hate speech e relazione semiotica) non è stato un semplice esercizio teorico, ma ha portato a miglioramenti tangibili in tutte le architetture testate. Fornire queste informazioni a priori agisce come una guida logica per il modello. Conoscere il contesto riduce l'ambiguità e aiuta la rete a scartare ipotesi improbabili, come ad esempio associare un'emozione di gioia a un contenuto classificato come offensivo o denigratorio.

Nonostante i progressi registrati, il nostro approccio presenta alcune limitazioni oggettive. In primo luogo, gli esperimenti con l'LLM Pixtral hanno dimostrato che fornire un contesto eccessivamente dettagliato all'interno dei prompt può rivelarsi controproducente. In task complessi e multi-label come il riconoscimento delle emozioni, un eccesso di informazioni testuali introduce rumore anziché chiarezza, peggiorando le prestazioni.

In secondo luogo, la forte dipendenza dalle correlazioni statistiche solleva interrogativi sulla capacità di generalizzazione. I modelli specializzati potrebbero risultare meno accurati se applicati a contesti in cui queste associazioni cambiano drasticamente, come ad esempio un diverso genere televisivo o una piattaforma social differente. Infine, la dimensione contenuta del dataset MultiEMit, per quanto ricca di informazioni incrociate, rimane un fattore limitante per l'addestramento da zero di architetture neurali molto profonde.

Capitolo 6

Analisi dei Risultati ed Esperimenti

In questo capitolo analizziamo le implicazioni dei risultati sperimentali presentati, collegandoli agli obiettivi iniziali della tesi. L'analisi si concentra sul valore aggiunto dell'approccio multimodale e sul ruolo cruciale delle annotazioni strutturate.

6.1 Analisi sui Subset Relazionali

Per esplorare in dettaglio il comportamento dei nostri modelli multimodali (il Dual-Encoder specializzato e l'LLM generativo Pixtral), abbiamo condotto esperimenti mirati valutando le performance sui singoli subset del dataset, suddivisi in base alla relazione semiotica: *Additiva* (ADD), *Parallela* (PAR) e *Divergente* (DIV).

Questa analisi è fondamentale per comprendere quali combinazioni testo-immagine risultino più complesse per il riconoscimento di emozioni e ironia. Come anticipato nel Capitolo 4, mentre per le valutazioni globali abbiamo utilizzato la Macro F1-score (per garantire equità verso le classi minoritarie), in questa indagine sui subset abbiamo optato per la **Micro F1-score**. Le ridotte dimensioni di questi partizionamenti possono infatti causare l'assenza temporanea di alcune sottoclassi nei vari fold (sparsity). La Micro F1 risulta più stabile rispetto a queste fluttuazioni, fornendo una metrica più affidabile della prestazione complessiva.

Per quanto riguarda gli esperimenti con Pixtral, abbiamo selezionato le configurazioni di prompt rivelatesi più efficaci nei test precedenti: la variante *short* per le emozioni e la variante *long_v2* per l'ironia. Queste configurazioni sono confrontate nei regimi Zero-Shot e di Fine-Tuning.

6.1.1 Classificazione di Emozioni e Ironia nei Subsets

Analizzando i risultati dell'**Emotion Detection** sui tre subset relazionali (Tabella 6.1), emergono differenze significative legate alla struttura della comunicazione.

Tabella 6.1: Emotion Detection: Micro F1-score valutati sui subset relazionali (Confronto Dual-Encoder e Pixtral 12B).

Setting Modello	**ADD**	**PAR**	**DIV**
Architettura Dual-Encoder (BERT + ViT)			
Senza correlazioni	0.47	**0.52**	0.38
Con correlazioni	**0.54**	**0.60**	**0.42**
Generative LLM (Pixtral 12B)			
Zero-Shot (senza corr.)	0.29	0.23	**0.44**
Zero-Shot (con corr.)	0.32	0.30	0.43
Finetuned (senza corr.)	**0.33**	**0.41**	0.41

Entrambi i modelli incontrano le maggiori difficoltà nella categoria *Divergente*. Questo risultato riflette la complessità intrinseca di questi post: l'incongruenza strutturale tra immagine e testo, spesso unita all'uso dell'ironia, altera il messaggio emotivo e disorienta i classificatori automatici.

Al contrario, osserviamo buone prestazioni sul subset *Parallelo*. Questo dato potrebbe sembrare sorprendente, dato che le matrici di correlazione (discusse nel Capitolo 3.4) non mostravano legami forti per questa categoria. Tuttavia, il successo del modello deriva dalla chiarezza del contenuto: in questi casi, testo e immagine trasmettono messaggi paralleli e spesso letterali (ad esempio, un testo descrittivo accompagnato da un'immagine che mostra esattamente la stessa scena). Questa linearità facilita notevolmente la deduzione dell'emozione, evitando le complessità interpretative.

Notiamo anche una sensibile differenza sul subset *Additivo*. Il modello a Dual-Encoder sembra essere riuscito a sfruttare meglio le correlazioni con le labels associate alla relazione additiva rispetto a Pixtral, permettendogli di ottenere prestazioni migliori sul subset.

Passando all'**Irony Detection** (Tabella 6.2), le differenze tra le categorie diventano ancora più evidenti.

Tabella 6.2: Irony Detection: Micro F1-score valutati sui subset relazionali (Confronto Dual-Encoder e Pixtral 12B).

Setting Modello	**ADD**	**PAR**	**DIV**
Architettura Dual-Encoder (BERT + ViT)			
Senza correlazioni	0.83	**1.00**	0.55
Con correlazioni	**0.88**	**1.00**	**0.68**
Generative LLM (Pixtral 12B - T=0.1)			
Zero-Shot (senza corr.)	0.14	0.00	0.18
Zero-Shot (con corr.)	0.57	0.78	0.57
Finetuned (senza corr.)	**0.87**	**1.00**	**0.58**

Un dato salta subito all'occhio: sul sottoinsieme di relazione *Parallela*, sia l'architettura Dual-Encoder che la versione fine-tunata di Pixtral ottengono un punteggio perfetto. È importante chiarire che questo risultato deriva da una particolarità dei dati: nel nostro test set, non era presente alcun esempio classificato contemporaneamente come ironico (o sarcastico) e con relazione *Parallela*. Lo score perfetto indica quindi la capacità dei modelli addestrati di predire correttamente la classe neutra ("None") per tutti questi casi. Al contrario, il crollo di Pixtral in regime Zero-Shot (senza correlazioni) evidenzia una forte tendenza dell'LLM a generare falsi positivi quando non è supportato dal fine-tuning o correlazioni.

L'analisi statistica (Capitolo 3.4) aveva evidenziato un forte legame strutturale tra la relazione *Divergente* e l'ironia. I risultati sperimentali lo confermano pienamente: l'aggiunta delle correlazioni durante l'addestramento porta un miglioramento eccezionale sulle occorrenze *Divergenti* per il modello Dual-Encoder. Questo balzo prestazionale dimostra chiaramente l'importanza del contesto relazionale per riuscire a decodificare le divergenze ironiche e sarcastiche, che risultano altrimenti troppo ambigue per essere colte.

6.1.2 Analisi sulla Relation Detection nei diversi Modelli

La disaggregazione dei risultati si rivela utile anche per analizzare il task di Semiotic Relation Detection (Tabella 6.3). A differenza dei task precedenti, in cui valutavamo il riconoscimento di emozioni o ironia all'interno dei subset, in questo caso valutiamo le performance dirette nel discriminare le tre tipologie di relazione semiotica. Includiamo qui i risultati delle baseline testuali, del Dual-Encoder e di Pixtral (nella variante *long_v1*).

Tabella 6.3: Relation Detection: F1-score valutati analiticamente sulle singole classi relazionali (Confronto architetture custom e Pixtral 12B).

Setting Modello	**ADD**	**PAR**	**DIV**
Architetture Custom (BERT e Dual-Encoder)			
Solo Testo (senza correlazioni)	0.65	0.53	0.61
Modello Testo+Immagine (senza correlazioni)	0.73	**0.61**	0.59
Solo Testo (con correlazioni)	0.75	0.54	0.68
Modello Testo+Immagine (con correlazioni)	**0.77**	0.59	**0.72**
Generative LLM (Pixtral 12B - Variante: long_v1)			
Zero-Shot (senza corr.)	0.62	0.00	0.56
Three-Shot (senza corr.)	0.62	0.05	0.40
Zero-Shot (con corr.)	0.61	0.00	0.56
Three-Shot (con corr.)	0.60	0.17	**0.64**
Finetuned (senza corr.)	**0.71**	**0.28**	0.60

Passando dal modello solo testo all'architettura multimodale (Dual-Encoder), osserviamo un netto miglioramento nella capacità di separare le classi *Parallela* e *Additiva*. L'aggiunta dell'immagine aiuta il modello ad allineare le rappresentazioni testuali e visive, colmando il *Modality Gap* e differenziando meglio i post in cui testo e immagine si supportano da quelli in cui procedono in parallelo.

Ancora una volta, è l'inserimento delle correlazioni (che legano fortemente la classe *Divergente* all'ironia e a specifiche emozioni) a generare l'incremento prestazionale più evidente, sia nel modello testuale che in quello multimodale. Questo dato conferma la nostra tesi: per decodificare il sarcasmo e le divergenze visive, i modelli hanno assoluto bisogno di un contesto strutturato.

Osservando i risultati di Pixtral, emerge chiaramente quanto la Semiotic Relation Detection rappresenti una sfida per gli LLM generativi. La classe *Parallela*, che è anche la meno frequente nel dataset, si conferma la più difficile da identificare: in modalità Zero-Shot, il modello non riesce a riconoscerla. La situazione migliora introducendo esempi concreti nel prompt (*Three-Shot*) e ancor di più ricorrendo al fine-tuning, che porta l'LLM a superare l'incapacità iniziale. Tuttavia, a differenza degli altri task, fornire solo le correlazioni in un prompt Zero-Shot non sembra sufficiente ad aiutare Pixtral in questa specifica classificazione.

6.2 Allucinazioni Generative e Truncation Parameter in Pixtral

Come anticipato nella Sezione 5.2.3, il fine-tuning di Pixtral per il task di Emotion Detection ha innescato un comportamento inatteso: una massiccia sovra-generazione di etichette. Invece di restituire una o due emozioni (in linea con la reale distribuzione del dataset), il modello tendeva a produrre lunghe sequenze (fino a sei o sette emozioni). Questo fenomeno di allucinazione abbassava notevolmente la precisione del sistema, introducendo molti falsi positivi.

Analizzando qualitativamente gli output, abbiamo notato che queste lunghe liste non erano del tutto casuali. Spesso, le emozioni autogenerate sembravano ordinate in base a una confidenza decrescente. In pratica, il modello inseriva le previsioni più probabili all'inizio, per poi aggiungere etichette via via meno pertinenti.

Riportiamo due esempi concreti per illustrare questo comportamento:

Esempio 1 - Degrado degli output in Pixtral

[**INPUT**]
`#propagandalive @welikeduel quante coltellate nel cuore vedere queste immagini.`

[**OUTPUT PIXTRAL**]
`Emotions detected: Sadness, Surprise, Trust, Joy, Fear, Anger, Neutral`

[**TRUE LABELS**]
`Surprise, Sadness`

Nel primo esempio, Pixtral individua correttamente le emozioni principali ("Sadness" e ""urprise", legate al concetto figurato di "coltellate nel cuore"), ma prosegue elencando quasi tutte le opzioni fornite nel prompt, degradando in puro rumore semantico.

Esempio 2 - Degrado degli output e ripetizione dell'input in Pixtral

[**INPUT**]

```
finalmente inizia pechinoexpress su rai2 un bellissimo
viaggio fra mete orientali...cina e corea #pechinoexpress
#chinatrip #oriente #television #tvtime #love
```

[**OUTPUT PIXTRAL**]

```
Emotions detected: Anticipation, Joy, Surprise, Sadness,
Trust, Love
finalmente inizia pechinoexpress su rai2 un bellissimo
viaggio fra mete orientali...cina e corea #pechinoexpress
#chinatrip #oriente #television #tvtime #love
```

[**TRUE LABELS**]

```
Anticipation
```

Nel secondo caso, il modello prevede correttamente "Anticipation" come prima scelta. Tuttavia, oltre ad allucinare altre cinque emozioni errate, finisce per ricopiare l'intero testo di input, mostrando una grave perdita di controllo sulla generazione.

Per verificare e quantificare questa nostra intuizione sull'ordine decrescente di confidenza, abbiamo introdotto un parametro di troncamento (n) in fase di post-elaborazione, estraendo solo le prime n predizioni.

La Tabella 6.4 isola il comportamento del modello fine-tunato, misurando la macro F1 media (combinata tra prompt lunghi e corti) al variare del parametro n.

Tabella 6.4: Confronto della macro F1 media per il modello fine-tunato al variare del parametro di troncamento n.

Numero Predizioni (n)	**Mean F1-Macro**
1	0.3375
2	**0.3888**
3	0.3386
4	0.3246
5	0.3083



Figura 6.1: Confronto dell'andamento della F1-Macro tra inferenza (Zero/Three-Shot) e fine-tuning all'aumentare del limite di etichette estratte (n).

Come mostrato dalla Tabella 6.4, per il modello sottoposto a fine-tuning le prestazioni raggiungono il picco quando limitiamo l'estrazione esattamente alle prime due etichette ($n = 2$).

La Figura 6.1 amplia questa analisi, mettendo a confronto l'andamento del modello fine-tunato con quello del modello Pixtral base in fase di inferenza pura (Zero-Shot e Three-Shot). Il grafico evidenzia una distinzione nettissima. Al crescere del parametro n, le curve del modello fine-tunato decrescono drasticamente, confermando come la generazione eccessiva di etichette distrugga la bontà della previsione iniziale. Al contrario, le linee relative al modello in inferenza rimangono perfettamente piatte. Questo dimostra che il modello base non ha sofferto di allucinazioni: ha rispettato rigorosamente i limiti imposti dalle istruzioni testuali (che richiedevano un massimo di due emozioni), fermando la generazione in modo corretto.

Possiamo spiegare l'esplosione generativa del modello fine-tunato attraverso due ipotesi legate all'architettura degli LLM:

- **Influenza del pre-training (Task di Ranking):** I grandi modelli linguistici subiscono un forte addestramento iniziale su istruzioni generali (Instruction tuning). È probabile che Pixtral abbia interiorizzato pattern legati a task di ordinamento. Di fronte alla richiesta di classificare un post ambiguo in un contesto multi-label, il modello applica questa logica pregressa: prende tutte le opzioni fornite nel vocabolario del prompt e le riordina dalla più probabile alla meno probabile, anziché filtrare solo le classi corrette.

- **Perdita del token di stop (Exposure Bias):** Il processo di fine-tuning multimodale può alterare il delicato equilibrio interno della rete. In particolare, il modello può perdere la capacità di emettere in modo stabile il token di fine generazione (`<EOS>`). Senza questo "freno" naturale, la rete continua a generare per inerzia probabilistica, pescando etichette superflue in coda o arrivando a ripetere il prompt originale.

Alla luce di questa indagine, l'imposizione di un limite rigido a due predizioni ($n = 2$) per valutare l'Emotion Detection non rappresenta una forzatura arbitraria, ma una solida regola empirica. Questa soluzione ci ha permesso di isolare il segnale semantico corretto all'inizio della sequenza, arginando i danni causati dall'instabilità generativa del fine-tuning.

6.3 Esperimento con Image Captioning

Prima di adottare architetture puramente multimodali (come il Dual-Encoder o Pixtral), abbiamo condotto un esperimento esplorativo. L'obiettivo era testare l'efficacia di un approccio indiretto: tradurre le immagini in testo tramite un modello di Image Captioning e fornire questo testo aggiuntivo a un classificatore standard. Questa indagine preliminare è stata fondamentale, poiché ci ha fornito l'intuizione decisiva di usare prompt testuali contestuali (le correlazioni) negli esperimenti definitivi.

Abbiamo utilizzato il modello generativo LLaVA-1.5[1] [32] per creare una descrizione visiva (caption) di ogni immagine del dataset. Poiché il modello genera nativamente descrizioni in lingua inglese, ci siamo avvalsi della traduzione automatica per convertire i testi in italiano. Infine, abbiamo semplicemente concatenato queste didascalie all'inizio del tweet originale, passando il testo unificato a un modello basato su BERT.

Di seguito presentiamo un esempio del testo concatenato finale (Caption visiva + Testo originale):

[1] `https://huggingface.co/llava-hf/llava-1.5-7b-hf`



Figura 6.2: Immagine trasformata in testo tramite LLaVA-1.5 6.3.

> *"L'immagine mostra un uomo che indossa una camicia nera con un disegno rosso, in piedi su un palco. Ha in mano un microfono e sembra che stia tenendo un discorso o una presentazione. Il commento dice: oggi la maglietta di zoro e dedicata a freddie/damiano... diego non delude mai.* ***#****propagandalive* *@welikeduel"*

Nonostante la semplicità intuitiva dell'approccio, abbiamo riscontrato rapidamente dei limiti oggettivi. Il modello LLaVA, non essendo addestrato sul contesto specifico della televisione italiana (showgirl, presentatori, loghi dei programmi), produceva descrizioni troppo generiche, limitandosi spesso a identificare genericamente "un uomo" o "una donna".

Il problema principale, tuttavia, riguardava le allucinazioni. Di fronte a elementi visivi a lui sconosciuti, il modello inventava dettagli inesistenti per dare un senso all'immagine. Inserire questi errori nel testo concatenato signi-

ficava introdurre un forte rumore semantico nell'addestramento successivo di BERT. Un esempio emblematico di questo problema è il seguente:



Figura 6.3: Immagine trasformata in testo tramite LLaVA-1.5 6.3.

> *"L'immagine presenta una grande pubblicità per Pechino Express, che è un servizio ferroviario. L'annuncio viene visualizzato su uno sfondo rosso e include l'immagine di un treno e un logo. Il commento dice: finalmente, si parte... stasera solo #pechinoexpress #tv #tvshow #relaxtime..."*

In questo caso, non riconoscendo il contesto del noto reality show "Pechino Express", il modello visivo ha dedotto erroneamente che si trattasse di un reale servizio ferroviario. Questa associazione fuorviante si scontra con il tono ironico e il significato reale del post, confondendo inevitabilmente l'analisi testuale.

Questa architettura a cascata (pipeline) presentava un limite strutturale evidente: separava l'analisi visiva da quella testuale. Il primo modello riduceva l'immagine a testo isolato, mentre il secondo leggeva unicamente la stringa finale. In questo modo veniva a mancare una vera elaborazione multimodale, ovvero la capacità di confrontare contemporaneamente in tempo reale le sfumature visive e il flusso semantico. Per questo motivo, abbiamo abbandonato l'idea in favore dell'architettura Dual-Encoder e dei modelli Vision-Language nativi.

Tuttavia, l'esperimento si è rivelato prezioso. Nonostante il rumore generato dalle allucinazioni e l'approssimazione delle traduzioni, i test preliminari hanno mostrato che il modello testuale arricchito con le caption superava nettamente le prestazioni della baseline addestrata sul solo testo originale. Questo risultato inaspettato ci ha dimostrato un principio chiave per il prosieguo della tesi: fornire al modello linguistico un contesto esplicito aggiuntivo rappresenta una strategia estremamente efficace. Questa evidenza ha motivato e validato la successiva scelta di integrare le correlazioni statistiche direttamente nei prompt di addestramento.

Conclusioni

Questo lavoro di tesi ha affrontato la sfida del riconoscimento automatico delle emozioni e dell'ironia nei post dei social network legati alla televisione italiana, partendo dal presupposto che l'integrazione di immagini, meme e screenshot sia ormai imprescindibile per decodificare correttamente il linguaggio digitale. Il cuore di questa ricerca è stato lo sviluppo e l'analisi di **MultiEMit**, un dataset nativamente multimodale progettato per catturare la complessità della Social TV attraverso cinque livelli di annotazione indipendenti: emozioni (secondo lo schema di Plutchik), ironia, offensività, target della comunicazione e, infine, la relazione semiotica tra testo e immagine. Attraverso questo corpus e lo sviluppo di diverse architetture di classificazione, abbiamo dimostrato come l'informazione visiva possa essere sfruttata con successo dai modelli di intelligenza artificiale per superare i limiti dell'analisi puramente testuale.

I risultati ottenuti permettono di rispondere alla prima domanda di ricerca (**RQ1**) confermando che l'aggiunta delle immagini migliora sensibilmente le prestazioni dei modelli. L'immagine funge da contesto fondamentale per disambiguare messaggi altrimenti opachi; tuttavia, nel caso dell'ironia, abbiamo osservato che l'apporto visivo può degradare le performance se non accompagnato da un supporto informativo adeguato. Poiché l'ironia si basa strutturalmente sulla contraddizione tra testo e immagine, senza una guida interpretativa l'informazione visiva rischia di trasformarsi in rumore semantico. Questo limite è stato superato affrontando la nostra seconda domanda di ricerca (**RQ2**): l'integrazione delle correlazioni statistiche tra le etichette ha garantito miglioramenti costanti in tutti i task. È emerso, infatti, che le dimensioni semantiche non sono indipendenti: ad esempio, il disgusto correla spesso con il sarcasmo, mentre la fiducia si associa a relazioni semiotiche additive, dove testo e immagine partecipano congiuntamente alla creazione del significato. Sfruttare queste interdipendenze attraverso il *correlation prompting* ha permesso ai modelli di gestire meglio le divergenze interpretative, confermando che la conoscenza contestuale è una risorsa preziosa per la classificazione multimodale.

Per quanto riguarda il confronto tra architetture (**RQ3**), lo studio ha

dimostrato che i modelli specializzati e leggeri basati su BERT italiano superano i grandi modelli linguistici multimodali come Pixtral. Nonostante la potenza dei modelli di ultima generazione, la natura specifica del nostro dominio (caratterizzato da slang, riferimenti culturali locali e un dataset di dimensioni contenute) favorisce approcci dedicati e affinati sui dati target. Pixtral, pur mostrando capacità notevoli se guidato dalle correlazioni, ha sofferto di problemi di instabilità generativa, come la produzione di etichette eccessive per le emozioni, che hanno richiesto interventi di limitazione artificiale in fase di post-elaborazione.

Nonostante i progressi, il lavoro presenta limitazioni intrinseche dovute alla complessità dello schema di annotazione e alla natura del dataset. Durante la creazione di MultiEMit, abbiamo riscontrato casi di estrema ambiguità emotiva che rendono difficile il raggiungimento di un accordo perfetto anche tra annotatori umani. Inoltre, lo sbilanciamento delle classi e la dimensione ridotta del corpus multimodale rappresentano ostacoli per la piena generalizzazione dei modelli a generi televisivi diversi da quelli analizzati (talk show e reality).

In ottica futura, MultiEMit resterà una risorsa pubblica preziosa per la ricerca italiana sull'analisi multimodale delle emozioni[2]. Una direzione particolarmente promettente riguarda l'applicazione di queste tecniche in tempo reale per monitorare il coinvolgimento del pubblico durante le dirette televisive, fornendo a broadcaster e creatori di contenuti strumenti analitici basati sul sentiment multimodale. In conclusione, questo studio ribadisce che per comprendere le emozioni umane online non basta leggere le parole: è necessario osservare l'interazione complessa tra testo e immagine, valorizzando le correlazioni tra i diversi livelli del linguaggio.

[2] `https://github.com/lupobricco/MultiEMit`

Appendice

Lista di Prompt utilizzati

Qui a seguito la lista di tutti i prompt utilizzati negli esperimenti con Pixtral. Dalla lista sono esclusi i prompt: corto, medio e lungo (versione 1) giá presenti nell'elaborato nella sezione 4.4.1.

Prompt riguardo Emotion Detection con correlazioni:

Listing 6.1: Esempio di prompt lungo v2 con correlazioni.

```
As an emotion classification specialist, your task involves analyzing
    Italian Twitter posts that combine visual and textual elements. Each
    post contains an image paired with caption-like text. Your goal is to
    examine how these multimodal components work together to express
    emotions, mirroring authentic Twitter interactions.

Select 1-2 emotions exclusively from this predefined set:
- Love (expressing affection or appreciation toward someone)
- Anticipation (conveying expectation of future events)
- Disgust (showing aversion or repulsion)
- Trust (demonstrating confidence, admiration, or respect)
- Joy (reflecting positive emotions like happiness or amusement)
- Fear (indicating response to threats or danger)
- Anger (displaying irritation, frustration, or indignation)
- Surprise (revealing reaction to unexpected events)
- Sadness (expressing sorrow, grief, or unhappiness)
- Neutral (indicating absence of strong emotional expression)

When no distinct emotion emerges clearly, default to Neutral. Irony
    requires particular -attentionits presence frequently alters the
    intended emotional meaning of the content.

Context: These posts originate from two Italian television programs:
- Pechino Express: A reality travel show featuring contestants who
    navigate challenges and cultural interactions with limited financial
    resources.
- Propaganda Live: A satirical talk show that blends political commentary,
     field reporting, debates, musical performances, and guest appearances
    .

Additional information from other annotation layers always precedes the
    content to be analyzed.

Key correlational patterns to consider:
- Trust: positively linked with Container and Parallel relationships,
    negatively associated with Irony, Divergent relationships, and Content
     focus
- Surprise: connected to Content focus, Divergent relationships, and Irony
    ; negatively associated with Container relationships
- Sadness: associated with Content focus and Additive relationships;
    negatively associated with Container relationships
- Anticipation: linked to Content focus; negatively associated with
    Container relationships
- Disgust: correlates with Sarcasm, Offensiveness, Divergent relationships
    , and Content focus; negatively correlates with Parallel and Container
     relationships
- Anger: associated with Offensiveness and Sarcasm
- Joy: connected to Irony

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Listing 6.2: Esempio di prompt lungo v3 con correlazioni.

```
Your expertise in emotion classification is needed to evaluate Italian
    Twitter posts featuring both visual and textual content. Each post
    presents an image accompanied by text that functions as a caption or
    comment. Analyze how these elements combine to communicate emotional
    meaning, reflecting real Twitter posting behavior.

Choose strictly 1 or 2 emotions from the following categories:
- Love: Demonstrates affection or appreciation directed toward someone
- Anticipation: Indicates expectation or looking forward to future events
- Disgust: Reveals aversion, repulsion, or strong dislike
- Trust: Shows confidence, admiration, or respectful regard
- Joy: Encompasses positive emotional states including happiness and
    amusement
- Fear: Represents responses to perceived threats or dangerous situations
- Anger: Encompasses irritation, frustration, or feelings of indignation
- Surprise: Captures reactions to unexpected or unanticipated events
- Sadness: Includes sorrow, grief, or general unhappiness
- Neutral: Applied when no pronounced emotional expression is evident

If emotional content appears ambiguous or unclear, select Neutral. Be
    particularly mindful of ironic content, which commonly transforms the
    apparent emotional tone of the message.

Source material comes from these two Italian TV shows:
- Pechino Express: Reality-based travel program where participants
    encounter challenges and engage in cultural exchanges while operating
    with minimal funds
- Propaganda Live: Satirical talk show format incorporating political
    analysis, field journalism, debates, musical segments, and guest
    interviews

Sentences for analysis are consistently prefaced with supplementary
    information from additional annotation categories.

Relevant correlational relationships include:
- Trust: positively correlates with Container and Parallel relationships;
    exhibits negative correlation with Irony, Divergent relationships, and
     Content focus
- Surprise: demonstrates positive correlations with Content focus,
    Divergent relationships, and Irony; shows negative correlation with
    Container relationships
- Sadness: shows positive correlation with both Content focus and Additive
     relationships; exhibits negative correlation with Container
    relationships
- Anticipation: positively correlates with Content focus; negatively
    correlates with Container relationships
- Disgust: correlates positively with Sarcasm, Offensiveness, Divergent
    relationships, and Content focus; shows negative correlation with
    Parallel and Container relationships
- Anger: exhibits positive correlations with both Offensiveness and
    Sarcasm
- Joy: demonstrates positive correlation with Irony

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Prompt riguardo Emotion Detection senza correlazioni:

Listing 6.3: Esempio di prompt lungo v2 senza correlazioni.

```
As a specialist in emotion classification, analyze Italian Twitter posts
    that combine visual and textual elements. Each post features an image
    with accompanying caption-like text. Your objective is to examine how
    these multimodal components interact to express emotions, reflecting
    authentic Twitter usage patterns.

Select 1-2 emotions exclusively from this defined set:
- Love (expressing affection or appreciation toward someone)
- Anticipation (conveying expectation of future events)
- Disgust (showing aversion or repulsion)
- Trust (demonstrating confidence, admiration, or respect)
- Joy (reflecting positive emotions like happiness or amusement)
- Fear (indicating response to threats or danger)
- Anger (displaying irritation, frustration, or indignation)
- Surprise (revealing reaction to unexpected events)
- Sadness (expressing sorrow, grief, or unhappiness)
- Neutral (indicating absence of strong emotional expression)

When emotional content remains unclear or ambiguous, choose Neutral. Give
    particular consideration to ironic elements, which frequently modify
    the apparent emotional meaning of the content.

These posts originate from two Italian television programs:
- Pechino Express: A reality travel show where participants navigate
    challenges and cultural interactions with limited financial resources.
- Propaganda Live: A satirical talk show that combines political
    commentary, field reporting, debates, musical performances, and guest
    appearances.

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Listing 6.4: Esempio di prompt lungo v3 senza correlazioni.

```
Your expertise in emotion classification is required to evaluate Italian
    Twitter posts that incorporate both visual and textual components.
    Each post presents an image paired with text functioning as a caption
    or commentary. Determine how these elements work together to
    communicate emotional meaning, mirroring genuine Twitter interactions.

Choose strictly 1 or 2 emotions from these categories:
- Love: Demonstrates affection or appreciation directed toward someone
- Anticipation: Indicates expectation or anticipation of future events
- Disgust: Reveals aversion, repulsion, or strong dislike
- Trust: Shows confidence, admiration, or respectful regard
- Joy: Encompasses positive emotional states including happiness and
    amusement
- Fear: Represents responses to perceived threats or dangerous situations
- Anger: Encompasses irritation, frustration, or feelings of indignation
- Surprise: Captures reactions to unexpected or unanticipated events
- Sadness: Includes sorrow, grief, or general unhappiness
- Neutral: Applied when no pronounced emotional expression is evident

If emotional expression appears indistinct or unclear, select Neutral. Be
    especially attentive to ironic content, which commonly alters the
    perceived emotional tone of the message.

Source content derives from these two Italian TV shows:
- Pechino Express: Reality-based travel program where contestants
    encounter challenges and engage in cultural exchanges while operating
    with minimal funds
- Propaganda Live: Satirical talk show format incorporating political
    analysis, field journalism, debates, musical segments, and guest
    interviews

Your response must be without any additional text or explanations, and
    formatted as follows:
Emotions detected: [Emotion(s)]
```

Prompt riguardo Semiotic Relation Detection con correlazioni:

Listing 6.5: Esempio di prompt corto con correlazioni.

```
You are an expert in multimodal classification. Classify the relationship
    between an Italian Twitter post's text and image. Choose only one of
    the following categories: Additive (the text and image enrich each
    other), Parallel (the text and image express the same idea), Divergent
     (the text and image convey contrasting meanings, often producing
    irony or humor). Helpful correlations: Divergent correlates with Irony
     and Content focus. Additive correlates with Container.

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.6: Esempio di prompt medio con correlazioni.

```
You are an expert in multimodal classification. Classify the relationship
    between an Italian Twitter post's text and image. They appear together
     like a real post: the text is a caption or comment on the image.
    Choose only one of the following categories: Additive (the text and
    image enrich each other), Parallel (the text and image express the
    same idea), Divergent (the text and image convey contrasting meanings,
     often producing irony or humor).

Posts refer to two Italian TV shows: Pechino Express (a travel reality
    show with challenges and cultural exchange) and Propaganda Live (a
    satirical talk show mixing politics, reports, music, and guest
    commentary).

Helpful correlations: Divergent correlates with Irony, Content focus and
    Surprise, and negatively with Trust and Container. Additive correlates
     with Sadness and Container and negatively with Irony. Parallel
    correlates with Trust.

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.7: Esempio di prompt lungo v1 con correlazioni.

```
You are an expert in multimodal classification. Classify the relationship
    between an Italian Twitter post's text and image. They appear together
     like a real post: the text is a caption or comment on the image.

Choose only one of the following categories:
- Additive: the text and image enrich each other to form a deeper or more
    amplified meaning
- Parallel: the text and image express the same idea or sentiment
    independently
- Divergent: the text and image convey contrasting or conflicting meanings
    , often producing irony, humor, or nonsense

Posts refer to two Italian TV shows:
- Pechino Express: a travel reality show with challenges and cultural
    exchange
- Propaganda Live: a satirical talk show mixing politics, reports, music,
    and guest commentary

Guidelines:
- If the text and image clearly express the same idea: Parallel
- If they combine into a richer meaning: Additive
- If they conflict in tone, message, or intent: Divergent

Posts also include annotations such as emotions, irony, offensiveness, and
     target (Content vs. Container).

Helpful correlations:
- Divergent correlates with Irony, Sarcasm, Content focus, Disgust,
    Surprise, and negatively with Trust and Container
- Additive correlates with Trust, Anticipation, Sadness, and Container
    focus; negatively correlates with Content and Irony
- Parallel correlates with Trust and Container

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.8: Esempio di prompt lungo v2 con correlazioni.

```
As a multimodal classification specialist, analyze the relationship
    between textual and visual elements in Italian Twitter posts. These
    posts function as authentic social media content where text serves as
    a caption or commentary for the accompanying image.

Select exactly one category from these options:
- Additive: textual and visual components enhance each other, creating
    deeper or amplified meaning
- Parallel: text and image independently express identical ideas or
    sentiments
- Divergent: text and image present contrasting or conflicting meanings,
    frequently generating irony, humor, or absurdity

Content originates from two Italian television programs:
- Pechino Express: reality-based travel show featuring challenges and
    cultural exchange experiences
- Propaganda Live: satirical talk show format combining political
    commentary, field reports, musical elements, and guest discussions

Classification guidelines:
- When text and image convey identical concepts: select Parallel
- When they merge to create enriched meaning: select Additive
- When they clash in tone, message, or purpose: select Divergent

Additional annotations accompany these posts, including emotional markers,
     irony indicators, offensiveness ratings, and target classifications (
    Content vs. Container).

Relevant correlational patterns:
- Divergent: positively correlates with Irony, Sarcasm, Content focus,
    Disgust, Surprise; negatively correlates with Trust and Container
- Additive: positively correlates with Trust, Anticipation, Sadness, and
    Container focus; negatively correlates with Content and Irony
- Parallel: positively correlates with Trust and Container

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.9: Esempio di prompt lungo v3 con correlazioni.

```
Your expertise in multimodal classification is needed to determine the
    relationship between text and images in Italian Twitter posts. These
    posts mirror real social media interactions where textual content
    functions as captions or comments accompanying visual elements.

Choose one classification from these three categories:
- Additive: text and image work together synergistically, producing
    enriched or intensified meaning beyond individual components
- Parallel: textual and visual elements independently communicate the same
     concept or emotional sentiment
- Divergent: text and image present opposing or contradictory meanings,
    typically resulting in ironic, humorous, or nonsensical effects

Source material derives from two Italian TV shows:
- Pechino Express: travel-focused reality program incorporating challenges
     and cross-cultural interactions
- Propaganda Live: satirical talk show blending political analysis,
    investigative reporting, musical performances, and guest commentary

Decision framework:
- Identical expression across modalities: choose Parallel
- Synergistic combination creating enhanced meaning: choose Additive
- Contradictory tone, messaging, or intent: choose Divergent

Posts include supplementary annotations covering emotional content, ironic
     elements, offensive material, and focus targets (Content vs.
    Container).

Key correlational relationships:
- Divergent: shows positive correlations with Irony, Content focus,
    Disgust, Surprise; exhibits negative correlation with Trust and
    Container
- Additive: demonstrates positive correlations with Trust, Anticipation,
    Sadness, and Container focus; exhibits negative correlation with
    Content and Irony
- Parallel: correlates positively Trust and Container

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Prompt riguardo Relation Detection senza correlazioni:

Listing 6.10: Esempio di prompt corto senza correlazioni.

```
You are an expert in multimodal classification. Classify the relationship
    between an Italian Twitter post's text and image. Choose only one of
    the following categories: Additive (the text and image enrich each
    other), Parallel (the text and image express the same idea), Divergent
     (the text and image convey contrasting meanings, often producing
    irony or humor).

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.11: Esempio di prompt medio senza correlazioni.

```
You are an expert in multimodal classification. Classify the relationship
    between an Italian Twitter post's text and image. They appear together
     like a real post: the text is a caption or comment on the image.
    Choose only one of the following categories: Additive (the text and
    image enrich each other), Parallel (the text and image express the
    same idea), Divergent (the text and image convey contrasting meanings,
     often producing irony or humor).

Posts refer to two Italian TV shows: Pechino Express (a travel reality
    show with challenges and cultural exchange) and Propaganda Live (a
    satirical talk show mixing politics, reports, music, and guest
    commentary).

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.12: Esempio di prompt lungo v1 senza correlazioni.

```
You are an expert in multimodal classification. Classify the relationship
    between an Italian Twitter post's text and image. They appear together
     like a real post: the text is a caption or comment on the image.

Choose only one of the following categories:
- Additive: the text and image enrich each other to form a deeper or more
    amplified meaning
- Parallel: the text and image express the same idea or sentiment
    independently
- Divergent: the text and image convey contrasting or conflicting meanings
    , often producing irony, humor, or nonsense

Posts refer to two Italian TV shows:
- Pechino Express: a travel reality show with challenges and cultural
    exchange
- Propaganda Live: a satirical talk show mixing politics, reports, music,
    and guest commentary

Guidelines:
- If the text and image clearly express the same idea: Parallel
- If they combine into a richer meaning: Additive
- If they conflict in tone, message, or intent: Divergent

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.13: Esempio di prompt lungo v2 senza correlazioni.

```
As a specialist in multimodal classification, determine the relationship
    between textual and visual components in Italian Twitter posts. These
    posts function as authentic social media content where text operates
    as a caption or commentary for the associated image.

Select exactly one category from these options:
- Additive: textual and visual elements enhance each other, creating
    deeper or amplified meaning
- Parallel: text and image independently express identical ideas or
    sentiments
- Divergent: text and image present contrasting or conflicting meanings,
    frequently generating irony, humor, or absurdity

Content originates from two Italian television programs:
- Pechino Express: reality-based travel show featuring challenges and
    cultural exchange experiences
- Propaganda Live: satirical talk show format combining political
    commentary, field reports, musical elements, and guest discussions

Classification guidelines:
- When text and image convey identical concepts: select Parallel
- When they merge to create enriched meaning: select Additive
- When they clash in tone, message, or purpose: select Divergent

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Listing 6.14: Esempio di prompt lungo v3 senza correlazioni.

```
Your expertise in multimodal classification is required to analyze the
    relationship between text and images in Italian Twitter posts. These
    posts reflect genuine social media interactions where textual content
    serves as captions or comments for accompanying visual elements.

Choose one classification from these three categories:
- Additive: text and image work together synergistically, producing
    enriched or intensified meaning beyond individual components
- Parallel: textual and visual elements independently communicate the same
     concept or emotional sentiment
- Divergent: text and image present opposing or contradictory meanings,
    typically resulting in ironic, humorous, or nonsensical effects

Source material derives from two Italian TV shows:
- Pechino Express: travel-focused reality program incorporating challenges
     and cross-cultural interactions
- Propaganda Live: satirical talk show blending political analysis,
    investigative reporting, musical performances, and guest commentary

Decision framework:
- Identical expression across modalities: choose Parallel
- Synergistic combination creating enhanced meaning: choose Additive
- Contradictory tone, messaging, or intent: choose Divergent

Your response must be without any additional text or explanations, and
    formatted as follows:
Relationship detected: [Additive/Divergent/Parallel]
```

Prompt riguardo Irony Detection con correlazioni:

Listing 6.15: Esempio di prompt corto con correlazioni.

```
You are an expert in irony and sarcasm classification. Classify a Twitter
    post written in Italian, consisting of an image and a caption-like
    text. Choose only 1 category from: irony, sarcasm, or none (unironic).

Consider the following relationships: irony correlates positively with
    Divergent and Content. irony correlates negatively with Container,
    Additive, and Trust. sarcasm correlates with Disgust. none correlates
    positively with Container, Trust, and Additive. none correlates
    negatively with Divergent and Content.

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.16: Esempio di prompt medio con correlazioni.

```
You are an expert in irony and sarcasm classification. Classify a Twitter
    post written in Italian, consisting of an image and a caption-like
    text. The task is to analyze both the image and the accompanying text,
     considering how they interact to convey meaning, as they do in real
    Twitter posts. Choose only 1 category from: irony, sarcasm, or none (
    unironic).

The posts are from two Italian TV shows: Pechino Express (a travel-based
    reality show where contestants face challenges and cultural exchanges)
     and Propaganda Live (a satirical talk show mixing politics, field
    reports, debates, music, and guests).

Also consider the following relationships: irony correlates positively
    with Divergent and Content. irony correlates negatively with Container
    , Additive, and Trust. sarcasm correlates with Disgust. none
    correlates positively with Container, Trust, and Additive. none
    correlates negatively with Divergent and Content.

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.17: Esempio di prompt lungo v1 con correlazioni.

```
You are an expert in irony and sarcasm classification. Classify a Twitter
    post written in Italian, consisting of an image and a caption-like
    text. The task is to analyze both the image and the accompanying text,
     considering how they interact, as they do in real Twitter posts.

Use only the following set of categories:
- irony: Expressing meaning using language that normally signifies the
    opposite.
- sarcasm: A sharp, aggressive irony intended to hurt or criticize a
    specific target.
- none: No irony or sarcasm is present; the post is literal and unironic.

Classify the post using only 1 category from this list. If no irony or
    sarcasm is present, select none.

The posts are from two Italian TV shows:
- Pechino Express: A travel-based reality show where contestants face
    challenges and cultural exchanges with little money.
- Propaganda Live: A satirical talk show mixing politics, field reports,
    debates, music, and guests.

Also consider the following relationships between the classification and
    other annotation levels:
- irony correlates with Divergent, Content, Surprise, and Joy, and
    negatively with Container, Additive, Trust, and Parallel.
- sarcasm correlates with Disgust, Offensiveness, and Anger.
- none correlates with Container, Trust, Additive, and Parallel, and
    negatively with Divergent, Content, Disgust, and Surprise.

The sentences to analyze are always preceded by additional information
    from other annotation layers.

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.18: Esempio di prompt lungo v2 con correlazioni.

```
As an irony and sarcasm classification specialist, your task involves
    analyzing Italian Twitter posts that combine visual and textual
    elements. Each post contains an image paired with caption-like text.
    Your goal is to examine how these multimodal components work together,
     mirroring authentic Twitter interactions.

Select 1 category exclusively from this predefined set:
- irony: A form of expression where the intended meaning is the opposite
    of the literal meaning.
- sarcasm: Biting, cutting irony with a clear intent to mock, wound, or
    show contempt.
- none: The content is straightforward and does not use ironic or
    sarcastic devices.

When no irony or sarcasm emerges clearly, default to none.

Context: These posts originate from two Italian television programs:
- Pechino Express: A reality travel show featuring contestants who
    navigate challenges and cultural interactions with limited financial
    resources.
- Propaganda Live: A satirical talk show that blends political commentary,
     field reporting, debates, musical performances, and guest appearances
    .

Additional information from other annotation layers always precedes the
    content to be analyzed.

Key correlational patterns to consider:
- irony: positively linked with Divergent, Content, Surprise, and Joy;
    negatively associated with Container, Additive, Trust, and Parallel.
- sarcasm: associated with Disgust, Offensiveness, and Anger.
- none: positively associated with Container, Trust, Additive, and
    Parallel; negatively linked with Divergent, Content, Disgust, and
    Surprise.

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.19: Esempio di prompt lungo v3 con correlazioni.

```
Your expertise in irony and sarcasm classification is needed to evaluate
    Italian Twitter posts featuring both visual and textual content. Each
    post presents an image accompanied by text that functions as a caption
     or comment. Analyze how these elements combine to communicate meaning
    , reflecting real Twitter posting behavior.

Choose strictly 1 category from the following:
- irony: The use of words to convey a meaning that is the opposite of its
    literal sense.
- sarcasm: Sharp, bitter irony, often driven by anger or negativity
    towards a clear target.
- none: Represents literal, unironic, and direct communication.

If ironic or sarcastic content appears ambiguous or unclear, select none.

Source material comes from these two Italian TV shows:
- Pechino Express: Reality-based travel program where participants
    encounter challenges and engage in cultural exchanges while operating
    with minimal funds
- Propaganda Live: Satirical talk show format incorporating political
    analysis, field journalism, debates, musical segments, and guest
    interviews

Sentences for analysis are consistently prefaced with supplementary
    information from additional annotation categories.

Relevant correlational relationships include:
- irony: positively correlates with Divergent, Content, Surprise, and Joy;
     exhibits negative correlation with Container, Additive, Trust, and
    Parallel.
- sarcasm: correlates positively with Disgust, Offensiveness, and Anger.
- none: shows positive correlations with Container, Trust, Additive, and
    Parallel; negatively correlates with Divergent, Content, Disgust, and
    Surprise.

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Prompt riguardo Irony Detection con correlazioni:

Listing 6.20: Esempio di prompt corto senza correlazioni.

```
You are an expert in irony and sarcasm classification. Classify a Twitter
    post written in Italian, consisting of an image and a caption-like
    text. Choose only 1 category from: irony, sarcasm, or none (unironic).

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.21: Esempio di prompt medio senza correlazioni.

```
You are an expert in irony and sarcasm classification. Classify a Twitter
    post written in Italian, consisting of an image and a caption-like
    text. The task is to analyze both the image and the accompanying text,
     considering how they interact to convey meaning, as they do in real
    Twitter posts. Choose only 1 category from: irony, sarcasm, or none (
    unironic).

The posts are from two Italian TV shows: Pechino Express (a travel-based
    reality show where contestants face challenges and cultural exchanges)
     and Propaganda Live (a satirical talk show mixing politics, field
    reports, debates, music, and guests).

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.22: Esempio di prompt lungo v1 senza correlazioni.

```
You are an expert in irony and sarcasm classification. Classify a Twitter
    post written in Italian, consisting of an image and a caption-like
    text. The task is to analyze both the image and the accompanying text,
     considering how they interact, as they do in real Twitter posts.

Use only the following set of categories:
- irony: Expressing meaning using language that normally signifies the
    opposite.
- sarcasm: A sharp, aggressive irony intended to hurt or criticize a
    specific target.
- none: No irony or sarcasm is present; the post is literal and unironic.

Classify the post using only 1 category from this list. If no irony or
    sarcasm is present, select none.

The posts are from two Italian TV shows:
- Pechino Express: A travel-based reality show where contestants face
    challenges and cultural exchanges with little money.
- Propaganda Live: A satirical talk show mixing politics, field reports,
    debates, music, and guests.

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.23: Esempio di prompt lungo v2 senza correlazioni.

```
As a specialist in irony and sarcasm classification, analyze Italian
    Twitter posts that combine visual and textual elements. Each post
    features an image with accompanying caption-like text. Your objective
    is to examine how these multimodal components interact, reflecting
    authentic Twitter usage patterns.

Select 1 category exclusively from this defined set:
- irony: A form of expression where the intended meaning is the opposite
    of the literal meaning.
- sarcasm: Biting, cutting irony with a clear intent to mock, wound, or
    show contempt.
- none: The content is straightforward and does not use ironic or
    sarcastic devices.

When ironic or sarcastic content remains unclear or ambiguous, choose none
    .

These posts originate from two Italian television programs:
- Pechino Express: A reality travel show where participants navigate
    challenges and cultural interactions with limited financial resources.
- Propaganda Live: A satirical talk show that combines political
    commentary, field reporting, debates, musical performances, and guest
    appearances.

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Listing 6.24: Esempio di prompt lungo v3 senza correlazioni.

```
Your expertise in irony and sarcasm classification is required to evaluate
     Italian Twitter posts that incorporate both visual and textual
    components. Each post presents an image paired with text functioning
    as a caption or commentary. Determine how these elements work together
    , mirroring genuine Twitter interactions.

Choose strictly 1 category from these:
- irony: The use of words to convey a meaning that is the opposite of its
    literal sense.
- sarcasm: Sharp, bitter irony, often driven by anger or negativity
    towards a clear target.
- none: Represents literal, unironic, and direct communication.

If ironic or sarcastic expression appears indistinct or unclear, select
    none.

Source content derives from these two Italian TV shows:
- Pechino Express: Reality-based travel program where contestants
    encounter challenges and engage in cultural exchanges while operating
    with minimal funds
- Propaganda Live: Satirical talk show format incorporating political
    analysis, field journalism, debates, musical segments, and guest
    interviews

Your response must be without any additional text or explanations, and
    formatted as follows:
Label detected: [Irony/Sarcasm/None]
```

Bibliografia

[1] Pansy Nandwani e Rupali Verma. «A review on sentiment analysis and emotion detection from text». In: *Social Network Analysis and Mining* 11.1 (2021), p. 81. DOI: 10.1007/s13278-021-00776-6.

[2] José Alberto García-Avilés. «Roles of audience participation in multiplatform television: From fans and consumers, to collaborators and activists». In: *Participations. Journal of Audience and Reception Studies* 9 (2012), pp. 429–447.

[3] Robert Plutchik. «The Nature of Emotions: Human emotions have deep evolutionary roots, a fact that may explain their complexity and provide tools for clinical practice». In: *American Scientist* 89.4 (2001), pp. 344–350. URL: http://www.jstor.org/stable/27857503.

[4] Robert Plutchik. «Emotion, a psychoevolutionary synthesis». In: 1980. URL: https://api.semanticscholar.org/CorpusID:145227438.

[5] Francesco Paolo Gentile. *Teorie dell'ironia*. 2012. URL: http://hdl.handle.net/10077/30436.

[6] Julia Kruk, Jonah Lubin, Karan Sikka, Xiao Lin, Dan Jurafsky e Ajay Divakaran. «Integrating Text and Image: Determining Multimodal Document Intent in Instagram Posts». In: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. A cura di Kentaro Inui, Jing Jiang, Vincent Ng e Xiaojun Wan. Hong Kong, China: Association for Computational Linguistics, nov. 2019, pp. 4622–4632. DOI: 10.18653/v1/D19-1469. URL: https://aclanthology.org/D19-1469/.

[7] Daniel Jurafsky e James H. Martin. «Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models». In: 3rd. Online manuscript released January 6, 2026. Prentice Hall, 2026. Cap. Chapter 22: Lexicons for Sentiment, Affect, and Connotation. URL: https://web.stanford.edu/~jurafsky/slp3/.

[8] Robin M. Schmidt. *Recurrent Neural Networks (RNNs): A gentle Introduction and Overview*. 2019. arXiv: 1912.05911 [cs.LG]. URL: https://arxiv.org/abs/1912.05911.

[9] Sepp Hochreiter e Jürgen Schmidhuber. «Long Short-Term Memory». In: *Neural Computation* 9.8 (1997), pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.

[10] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser e Illia Polosukhin. «Attention Is All You Need». In: *Advances in Neural Information Processing Systems* 30 (2017).

[11] Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Ves Stoyanov e Luke Zettlemoyer. *BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension*. 2019. arXiv: 1910.13461 [cs.CL].

[12] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li e Peter J. Liu. *Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer*. 2020. arXiv: 1910.10683 [cs.LG].

[13] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever e Dario Amodei. *Language Models are Few-Shot Learners*. 2020. arXiv: 2005.14165 [cs.CL].

[14] Jacob Devlin, Ming-Wei Chang, Kenton Lee e Kristina Toutanova. «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2019.

[15] Federico Bianchi, Debora Nozza e Dirk Hovy. «FEEL-IT: Emotion and Sentiment Classification for the Italian Language». In: *Proceedings of the 11th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis*. Association for Computational Linguistics, 2021.

[16] Loreto Parisi, Simone Francia e Paolo Magnani. *UmBERTo: an Italian Language Model trained with Whole Word Masking*. `https://github.com/musixmatchresearch/umberto`. 2020.

[17] Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier et al. «Mistral 7B». In: *arXiv preprint arXiv:2310.06825* (2023).

[18] Daniel Jurafsky e James H. Martin. «Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models». In: 3rd. Online manuscript released January 6, 2026. Prentice Hall, 2026. Cap. Chapter 7: Large Language Models. URL: `https://web.stanford.edu/~jurafsky/slp3/`.

[19] Tommaso Caselli, Antonio Lieto, Malvina Nissim e Viviana Patti. «Sono solo parole. ChatGPT: anatomia e raccomandazioni per l'uso». In: *Sistemi intelligenti* 35.2 (2023), pp. 307–320.

[20] Pravesh Agrawal, Szymon Antoniak, Emma Hanna, Baptiste Bout, Devendra Chaplot, Jessica Chudnovsky, Diogo Costa, Baudouin De Monicault, Saurabh Garg et al. «Pixtral 12B». In: *arXiv preprint arXiv:2410.07073* (2024).

[21] Shamsuddeen Hassan Muhammad, Nedjma Ousidhoum, Idris Abdulmumin et al. «BRIGHTER: BRIdging the Gap in Human-Annotated Textual Emotion Recognition Datasets for 28 Languages». In: *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2025, pp. 8895–8916.

[22] Paul Ekman e Wallace V. Friesen. «Constants across cultures in the face and emotion». In: *Journal of Personality and Social Psychology* 17.2 (1971), pp. 124–129. DOI: `10.1037/h0030377`.

[23] Paul Ekman. «An argument for basic emotions». In: *Cognition and Emotion* 6.3-4 (1992), pp. 169–200.

[24] Francesco Barbieri, Valerio Basile, Danilo Croce, Malvina Nissim, Nicole Novielli e Viviana Patti. «Overview of the EVALITA 2016 SENTiment POLarity Classification Task». In: *Proceedings of the Fifth Evaluation Campaign of Natural Language Processing and Speech Tools for Italian (EVALITA 2016)*. Accademia University Press, 2016.

[25] Rachele Sprugnoli. «MultiEmotions-It: a New Dataset for Opinion Polarity and Emotion Analysis for Italian». In: *Proceedings of the Seventh Italian Conference on Computational Linguistics*. Accademia University Press, 2020. DOI: `10.4000/books.aaccademia.8910`.

[26] Oscar Araque, Simona Frenda, Rachele Sprugnoli, Debora Nozza, Viviana Patti et al. «EMit at EVALITA 2023: overview of the categorical emotion detection in Italian social media task». In: *CEUR Workshop Proceedings*. Vol. 3473. CEUR-WS. 2023, pp. 1–8.

[27] Alessandra Teresa Cignarella, Simona Frenda, Valerio Basile, Cristina Bosco, Viviana Patti e Paolo Rosso. «Overview of the EVALITA 2018 Task on Irony Detection in Italian Tweets (IronITA)». In: *Proceedings of the Sixth Evaluation Campaign of Natural Language Processing and Speech Tools for Italian. Final Workshop (EVALITA 2018) co-located with the Fifth Italian Conference on Computational Linguistics (CLiC-it 2018), Turin, Italy, December 12-13, 2018*. A cura di Tommaso Caselli, Nicole Novielli, Viviana Patti e Paolo Rosso. Vol. 2263. CEUR Workshop Proceedings. CEUR-WS.org, 2018.

[28] Andrea Luparia. «ProSAT: un corpus italiano per l'analisi multimodale delle emozioni di post Twitter». LT in Informatica. Relatori: Viviana Patti, Mirko Lai. Tesi di laurea. Università degli Studi di Torino, 2022.

[29] Pedro Javier Ortiz Suárez, Benoît Sagot e Laurent Romary. «Asynchronous Pipeline for Processing Huge Corpora on Medium to Low Resource Infrastructures». In: *Proceedings of the Workshop on Challenges in the Management of Large Corpora (CMLC-7)*. Leibniz-Institut für Deutsche Sprache, 2019.

[30] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit e Neil Houlsby. «An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale». In: *International Conference on Learning Representations (ICLR)*. 2021.

[31] Weixin Liang, Yuhui Zhang, Yongchan Kwon, Serena Yeung e James Zou. *Mind the Gap: Understanding the Modality Gap in Multimodal Contrastive Representation Learning*. 2022. arXiv: 2203.02053 [cs.CL]. URL: https://arxiv.org/abs/2203.02053.

[32] Haotian Liu, Chunyuan Li, Yuheng Li e Yong Jae Lee. *Improved Baselines with Visual Instruction Tuning*. 2024. arXiv: 2310.03744 [cs.CV]. URL: https://arxiv.org/abs/2310.03744.