Corso di Laurea Magistrale in Informatica



UNIVERSITÀ
DI TORINO

MultiEMit

Il ruolo della multimodalità e del contesto nel riconoscimento automatico di emozioni e ironia in social media italiani

Candidato: Andrea Luparia

Relatrice: Viviana Patti, Università di Torino
Correlatore: Oscar Araque, Universidad Politécnica de Madrid
Correlatore: Daniel Russo, Fondazione Bruno Kessler

La SocialTV

Definizione

L'attività di **interagire attraverso le reti sociali con programmi televisivi:**

- Pubblicazione di **post allo scopo di interagire con gli spettatori** tramite gli #
- **Coinvolgimento in diretta** con le trasmissioni
- **Opinioni o votazioni su come proseguire** il programma







Sentiment vs Emotion

L'estrazione del Sentiment (positivo, negativo o neutro) **non è sufficiente per capire l'intenzione** di commenti o post sui social, **si perdono troppe informazioni** che invece possono essere colte osservandone le emozioni e il target.

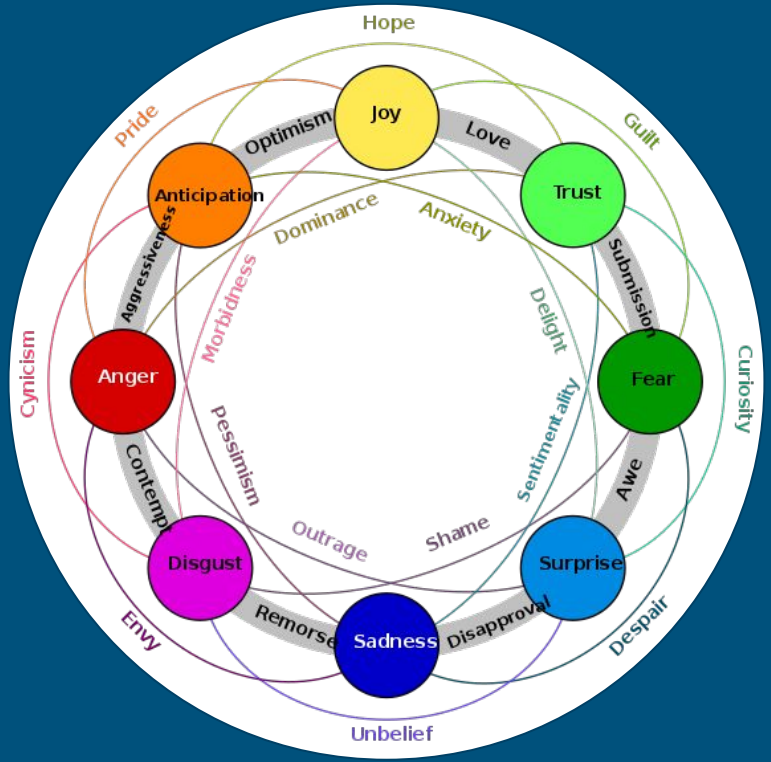
"piango e mi chiedo come l'uomo possa fare simili atrocità. e inaccettabile. possibile che l'europa resti a guardare?! #propagandalive"

Target: Contenuto del programma

"#propagandalive ormai per me inguardabile."

Target: **Contenitore** (il programma stesso, regia)

Diadi di Plutchik



Dato Multimodale nella SocialTV

Le pagine social ufficiali condividono immagini di scene specifiche **per invogliare gli utenti a commentare** e interagire con i contenuti.

L'immagine quindi diventa una parte fondamentale del messaggio dell'utente, **spesso contenendo il soggetto** verso cui il commento é rivolto o portando informazioni importanti sul significato delle frasi.

Montaggio imbarazzante...ma tifiamo per voi!!!!!



Buonanotte piccolo! Spero che tu stia dormendo in un caldo lettino, facendo tanti bei sogni, lontano da tutta questa disumanità. Grazie a #propagandalive



Ironia e Sarcasmo nella SocialTV

L’ironia è una componente predominante nei messaggi social, spesso pure incentivata dalle pagine ufficiali delle trasmissioni per creare contenuti comici che diventino virali sui social.

Ironia

Consiste nell'**affermare il contrario di ciò che si pensa**, ribaltando il significato per produrre un effetto comico o di critica costruttiva.

Sarcasmo

Si manifesta quando l'**effetto ironico** diventa **tagliente, amaro o apertamente offensivo** verso il soggetto interessato.

Ironia Multimodale

199 gradini dopo, costantino che aspetta le coppie #pechinoexpress

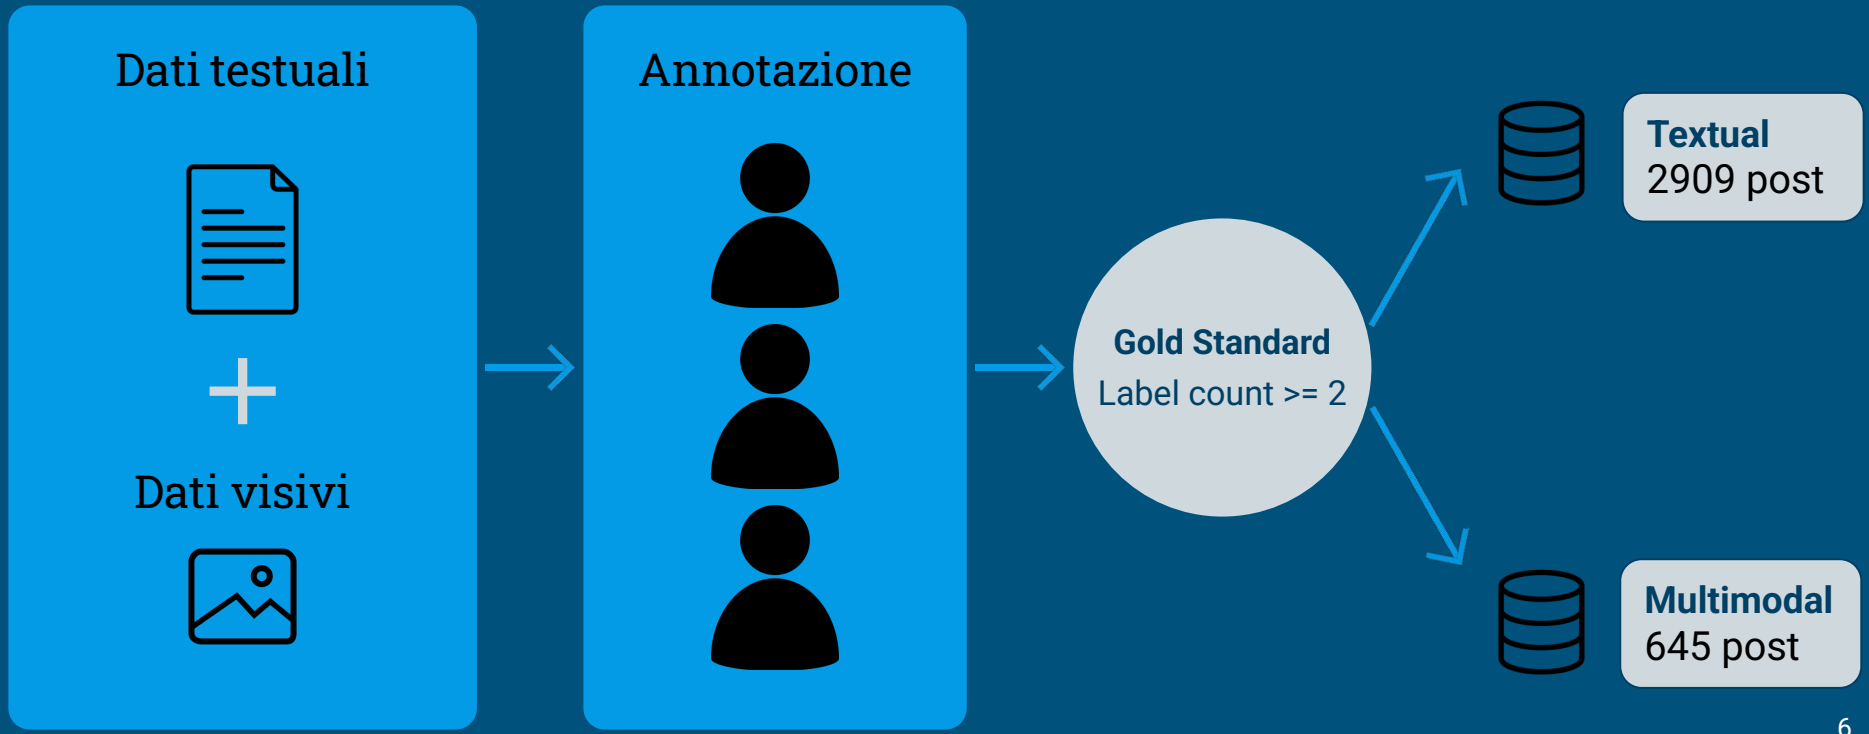


Ironia Ecoica

“Un piatto da portata” ti hanno sicuramente capito enzo #pechinoexpress



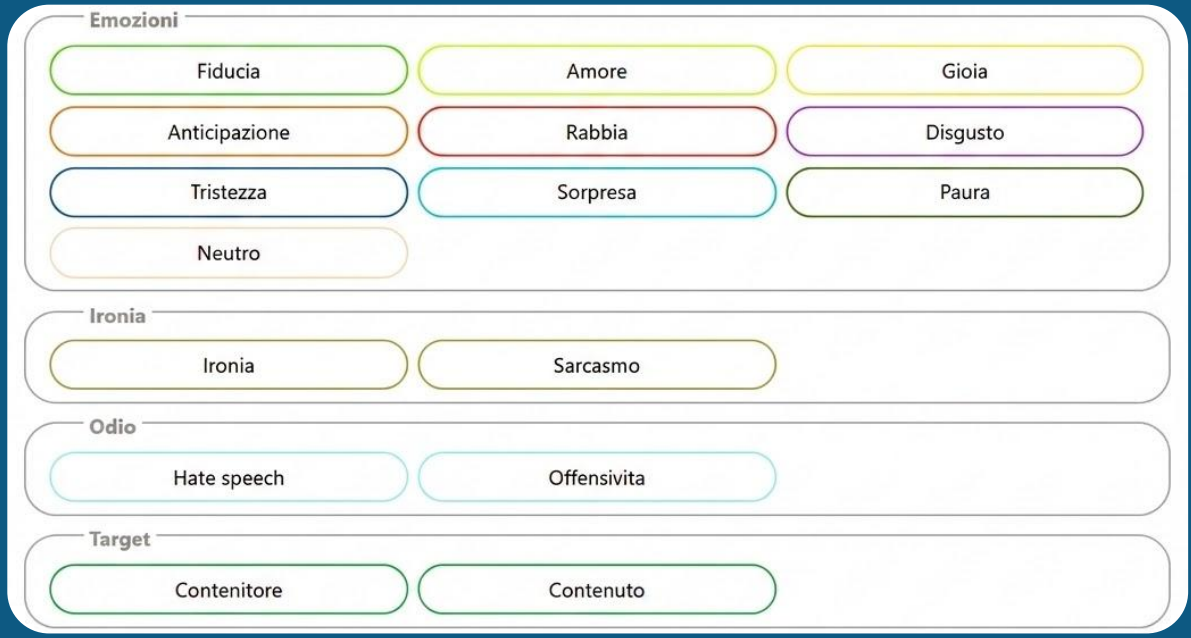
Dataset MultiEMit - PropagandaLive e PechinoExpress



Annotazione Multi-Livello

Livelli:

- Emozioni
- Ironia
- Odio
- Target
- **Relazione Semiotica**



Relazioni Semiotiche

bravo enzo! complimenti!!!! che forza!



Additiva

Toninelli: “Grazie a #propagandalive.”
La reazione di Zoro:



Divergente

Moscow mule e #propagandalive.



Parallela

Julia Kruk, Jonah Lubin, Karan Sikka, Xiao Lin, Dan Jurafsky e Ajay Divakaran.
«Integrating Text and Image: Determining Multimodal Document Intent in Instagram Posts»

Distribuzione Etichette

- Sia nei testi sia nei contenuti multimodali dominano emozioni positive (**Fiducia e Gioia**)
- Nei dati multimodali **prevale la relazione Additiva**, dove le due componenti si arricchiscono reciprocamente
- **Sbilanciamento delle etichette**, ad esempio **Paura** quasi **non rappresentata nel Multimodale**

Dataset testuale

Etichetta	**Totale (2.909)**
Emozioni (multi-label)	
Amore	340
Anticipazione	201
Disgusto	410
Fiducia	613
Gioia	552
Neutro	321
Paura	55
Rabbia	163
Sorpresa	486
Tristezza	255
Ironia	
Ironia	481
Non ironico	2.072
Sarcasmo	41
Offensività	
Offensivo	52
Target	
Contenitore	1.147
Contenuto	1.138

Dataset multimodale

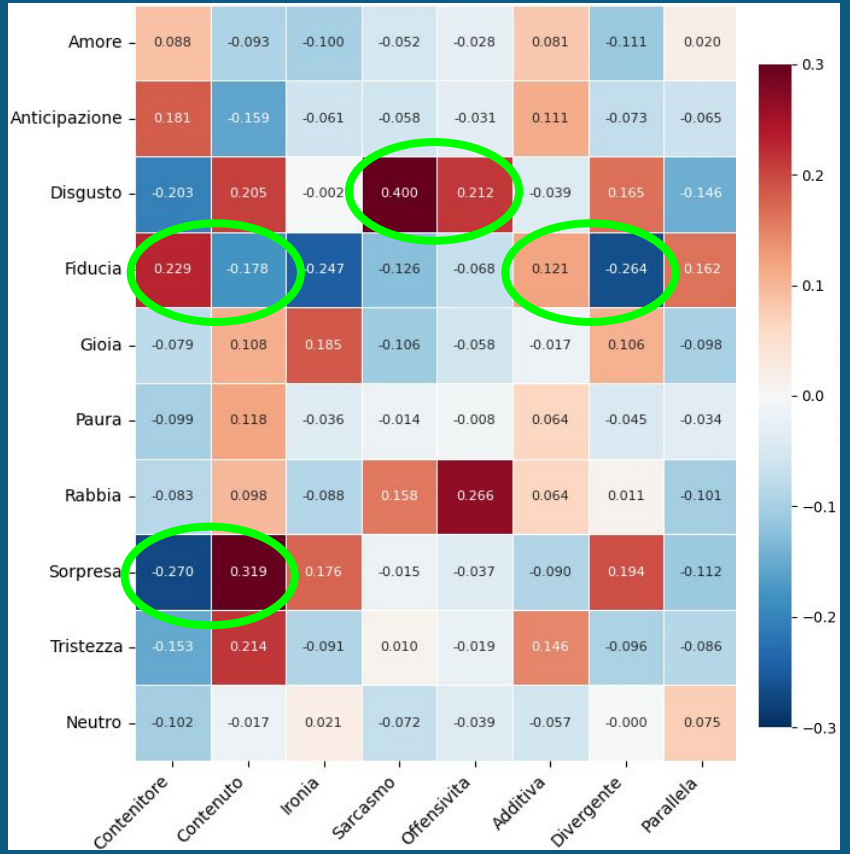
Etichetta	**Totale (645)**
Emozioni (multi-label)	
Amore	50
Anticipazione	61
Disgusto	78
Fiducia	214
Gioia	168
Neutro	90
Paura	4
Rabbia	34
Sorpresa	82
Tristezza	25
Ironia	
Ironia	109
Non ironico	516
Sarcasmo	20
Offensività	
Offensivo	6
Target	
Contenitore	395
Contenuto	199
Relazione Semiotica	
Additiva	389
Divergente	158
Parallela	100

Correlazioni tra Livelli

Sfruttando il **coefficiente di correlazione di Pearson** abbiamo valutato le co-occorrenze di etichette di livelli differenti negli esempi del dataset.

Il coefficiente di Pearson è un valore compreso tra **-1 e 1**:

- **Valore Positivo:** Le etichette compaiono spesso insieme.
- **Valore Negativo:** Le etichette tendono ad escludersi.



Correlazioni tra Livelli: Ironia vs Sarcasmo



Ironia

- **Relazione Visiva:** Divergente
- **Target:** Contenuto
- **Emozioni:** Gioia e Sorpresa

Tono leggero e divertito.

Sarcasmo

- **Linguaggio:** Offensivo
- **Emozioni:** Disgusto e Rabbia

Intento chiaramente denigratorio.

Difficoltà nella classificazione



Annotatore 1:
Rabbia
Disgusto

→ **Disprezzo** verso l'Europa

Annotatore 2:
Tristezza
Sorpresa

→ **Disapprovazione** verso l'Europa

Annotatore 3:
Disgusto
Paura

→ **Vergogna** di essere Europeo

Domande di Ricerca

1. **RQ1: Sottoponendo agli annotatori** umani **gli stessi post** in due fasi distinte, prima potendo leggere solo il testo e poi potendo osservare anche l'immagine, abbiamo notato un incremento nell'accordo sulle etichette assegnate durante la seconda fase. **La componente multimediale aiuta i modelli** neurali a riconoscere le emozioni, **cosí come hanno aiutato gli annotatori**?
2. **RQ2: Le correlazioni** tra etichette di diversi livelli di annotazione (emozioni - ironia - odio - target - relazioni) **possono essere usate per migliorare i nostri modelli**?
3. **RQ3: Come si confrontano** su diversi task **modelli specializzati**, come Encoders basati su BERT e VIT, **con i moderni LLM multimodali**, come Pixtral?

Metodologia Sperimentale

Emozioni

Ironia

Relazioni

Solo testo

Solo testo e correlazioni

Con immagini

Con immagini e correlazioni







Modelli Testuali BERT

Emozioni

Pre-trained Model:
Feel-it

Dataset allenamento:
- **EMit Evalita 2023**
- MultiEMit testuale
- MultiEMit multimodale (solo testo)

Dataset test:
- MultiEMit testuale
- **MultiEMit multimodale** (solo testo)

Ironia

Pre-trained Model:
UmBERTo

Dataset allenamento:
- **IronITA Evalita 2018**
- MultiEMit testuale
- MultiEMit multimodale (solo testo)

Dataset test:
- MultiEMit testuale
- **MultiEMit multimodale** (solo testo)

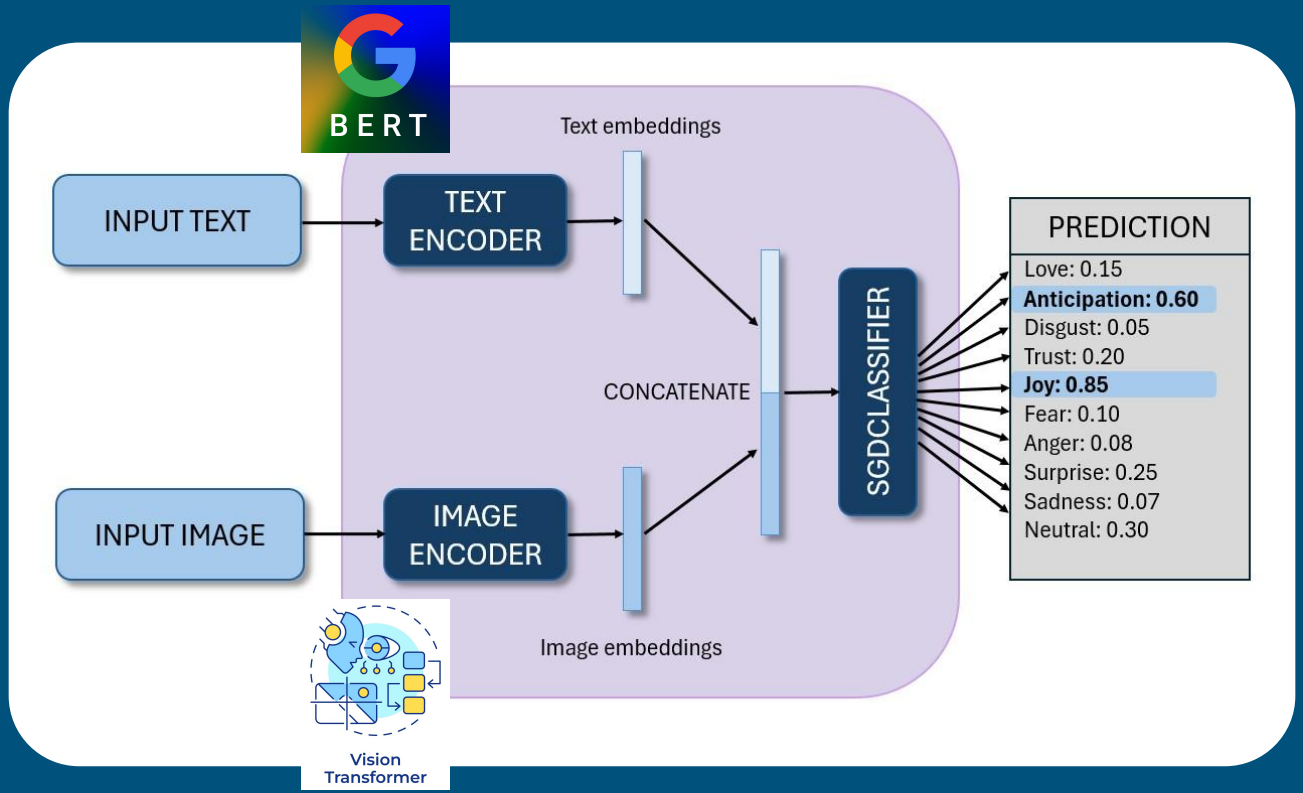
Relazioni

Pre-trained Model:
UmBERTo

Dataset allenamento:
- MultiEMit multimodale (solo testo)

Dataset test:
- MultiEMit multimodale (solo testo)

Dual-Encoder Multimodale



Correlation Prompting

Per ciascun task, tutti gli altri livelli di annotazione sono stati inseriti nel prompt, ad esempio:

Testo originale

“ma soleil é con sua nonna?”

→

Testo con correlazioni (emozioni)

“il seguente testo contiene ironia e offensività riguarda contenitore: ma soleil é con sua nonna?”

Con questa tecnica **possiamo verificare se l’informazione contestuale aggiuntiva** (che in uno scenario reale potrebbe essere inferita da un modulo separato) **aiuti la classificazione** finale.

Pixtral



A differenza di BERT (encoder), Pixtral (decoder) necessita della descrizione del task nell'input. Per ciascun task **abbiamo testato tre prompt di lunghezza diversa**:

1. Prompt Corto

Contiene esclusivamente la **descrizione essenziale del task** e le etichette di classificazione possibili

2. Prompt Medio

Aggiunge **informazioni contestuali sui programmi** televisivi e **istruzioni più dettagliate** sull'analisi multimodale

3. Prompt Lungo

Definizioni dettagliate per ogni etichetta e **maggiori informazioni sul contesto**

Sono state **testate 3 varianti lessicali** e sintattiche per verificare la robustezza del modello chiamate **v1, v2 e v3**

Poi abbiamo **effettuato un fine-tuning del modello usando il prompt corto e** la variante lessicale **del prompt lungo** che ha ottenuto i risultati migliori nei test in inferenza.

Prompting Pixtral - Corto

```
You are an expert in emotion classification.
Classify the emotions expressed in a Twitter
post written in Italian, consisting of an
image and a caption-like text.
Choose 1-2 emotions from: Love, Anticipation,
Disgust, Trust, Joy, Fear, Anger, Surprise,
Sadness, Neutral.

Your response must be without any additional
text or explanations, and formatted as
follows: Emotions detected: [Emotion(s)]
```

Prompting Pixtral - Medio

```
You are an expert in emotion classification. Classify the emotions expressed in a Twitter post written in Italian, consisting of an image and a caption-like text. The task is to analyze both the image and the accompanying text, considering how they interact to convey emotion, as they do in real Twitter posts. Choose 1-2 emotions from: Love, Anticipation, Disgust, Trust, Joy, Fear, Anger, Surprise, Sadness, Neutral. The posts are from two Italian TV shows: Pechino Express (a travel -based reality show where contestants face challenges and cultural exchanges) and Propaganda Live (a satirical talk show mixing politics, field reports, debates, music and guests). Your response must be without any additional text or explanations, and formatted as follows: Emotions detected: [Emotion(s)]
```

Prompting Pixtral - Lungo

You are an expert in emotion classification. Classify the emotions expressed in a Twitter post written in Italian, consisting of an image and a caption -like text. The task is to analyze both the image and the accompanying text, considering how they interact to convey emotion, as they do in real Twitter posts.
Use only the following set of emotions:
- Love (Affection or appreciation toward someone)
- Anticipation (Expectation of a future event)
- Disgust (Aversion or repulsion)
- Trust (Confidence, admiration, or respect)
- Joy (Positive emotions such as happiness or amusement)
- Fear (Response to threats or danger)
- Anger (Irritation, frustration, or indignation)
- Surprise (Reaction to the unexpected)
- Sadness (Sorrow, grief, or unhappiness)
- Neutral (No strong emotional expression)

Classify the post using only 1 or 2 emotions from this list. If no specific emotion is clearly expressed, select Neutral. Pay special attention to irony: when it is present, take it into account during classification, as it often shifts the intended emotional tone of the text.
The posts are from two Italian TV shows:
- Pechino Express: A travel -based reality show where contestants face challenges and cultural exchanges with little money.
- Propaganda Live: A satirical talk show mixing politics, field reports, debates, music, and guests.
Your response must be without any additional text or explanations, and formatted as follows:
Emotions detected: [Emotion(s)]

Correlation Prompting Pixtral

Per **Pixtral** é stato necessario **aggiungere una spiegazione di come sfruttare le correlazioni** all'interno dei prompt. Basandoci sulle tabelle viste precedentemente, **abbiamo aggiunto piú o meno informazioni sulle correlazioni rispettando lo schema dei prompt**:

1. Prompt Corto

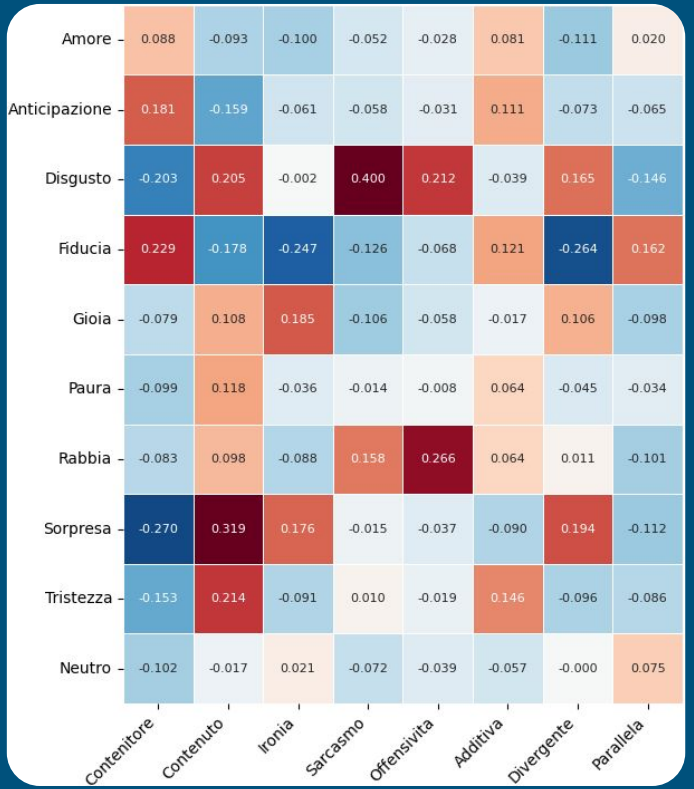
Contiene le correlazioni forti, con indice di **Pearson >= 0.25**

2. Prompt Medio

Contiene le correlazioni **medie-forti**, con indice di **Pearson >= 0.20**

3. Prompt Lungo

Contiene tutte le correlazioni, con indice di **Pearson >= 0.15**



Correlation Prompting Pixtral - Medio

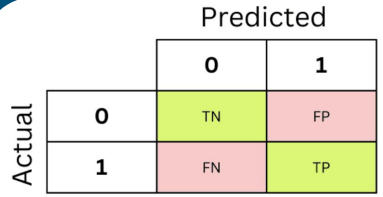
You are an expert in emotion classification. Classify the emotions expressed in a Twitter post written in Italian, consisting of an image and a caption -like text. The task is to analyze both the image and the accompanying text, considering how they interact to convey emotion, as they do in real Twitter posts. Choose 1-2 emotions from: Love, Anticipation, Disgust, Trust, Joy, Fear, Anger, Surprise, Sadness, Neutral. The posts are from two Italian TV shows: Pechino Express (a travel -based reality show where contestants face challenges and cultural exchanges) and Propaganda Live (a satirical talk show mixing politics, field reports, debates, music, and guests).
Also consider the following relationships: Disgust correlates with Sarcasm, Content and Offensivness, but is negatively correlated with Container. Trust correlates with Container and negatively with Irony and Divergent. Anger correlates with Offensivity. Surprise correlates with Content and Divergent, but is negatively correlated with Container. Sadness correlates with Content focus. Anticipation correlates with Contentainer.
Your response must be without any additional text or explanations, and formatted as follows: Emotions detected: [Emotion(s)]

Risultati e metriche

Per ciascun prompt di Pixtral abbiamo **eseguito tre run a temperatura 0.1** e **calcolato la media dei risultati ottenuti**. Abbiamo poi ripetuto gli esperimenti a temperatura **0.9** per verificare l'impatto della casualitá sui risultati.
A seguire vedremo i risultati di BERT e Pixtral (con temperatura 0.1) a confronto sulla F1 score.

Metrica F1-Score

Una metrica che bilancia precisione e richiamo (recall), spesso usata per valutare task di classificazione.



$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Emotion Detection - BERT

F1 score dei Modelli BERT e Dual-Encoder sul test set multimodale

SOLO TESTO

0.30

Baseline usando solo il testo

TESTO + CORRELAZIONI

0.37

Aggiungendo le correlazioni negli input

TESTO + IMMAGINI

0.43

Sfruttando il Dual-Encoder per elaborare le immagini

TESTO + IMMAGINI + CORR.

0.45

Testo, immagini e correlazioni.

Emotion Detection - Pixtral

F1 score di Pixtral sul test set multimodale

TESTO + IMMAGINI (zero-shot)

0.26

Prompt longV1

TESTO + IMMAGINI + CORR. (zero-shot)

0.28

Prompt longV1

TESTO + IMMAGINI (finetuned)

0.24

Prompt longV1 (all predictions)

TESTO + IMMAGINI (finetuned)

0.43

Prompt longV1 (prime 2 predizioni)

Emotion Detection - Confronto

Osservazioni:

- I prompt **corti** si sono dimostrati **piú efficaci** rispetto a quelli **lunghi**
- **Correlazioni migliorano solo lievemente** le prestazioni
- Dopo aver effettuato un fine-tuning, ci sono stati problemi di allucinazioni negli output

Prompt/Model	Experiment Type	F1 score
BERT-Vit	Finetune - With Corr	0.45
BERT-Vit	Finetune- No Corr	0.43
long	Finetuned Redo (n=2)	0.43
short	Finetuned Redo (n=2)	0.4
short	Finetuned Redo (all predictions)	0.32
short	With Corr - Zero Shot	0.29
long_v1	With Corr - Zero Shot	0.28
medium	With Corr - Zero Shot	0.27
long_v2	No Corr - Zero Shot	0.27
long_v1	No Corr - Zero Shot	0.26
short	No Corr - Zero Shot	0.26
long_v3	With Corr - Zero Shot	0.26
medium	No Corr - Zero Shot	0.25
long_v2	With Corr - Zero Shot	0.25
long	Finetuned Redo (all predictions)	0.24
long_v3	No Corr - Zero Shot	0.22

Irony Detection - BERT

F1 score dei Modelli BERT e Dual-Encoder sul test set multimodale

SOLO TESTO

0.67

Baseline usando solo il testo

TESTO + CORRELAZIONI

0.71

Aggiungendo le correlazioni negli input

TESTO + IMMAGINI

0.63

Le immagini da sole aggiungono rumore negli input

TESTO + IMMAGINI + CORR.

0.74

Aggiungendo le correlazioni il rumore delle immagini diventa informazione

Irony Detection - Pixtral

F1 score di Pixtral sul test set multimodale

TESTO + IMMAGINI (zero-shot)

0.17

Prompt longV2

TESTO + IMMAGINI + CORR. (zero-shot)

0.51

Prompt longV2

TESTO + IMMAGINI (finetuned)

0.41

Prompt longV2

Le correlazioni si sono dimostrate estremamente efficaci nel riconoscere l'ironia. Sia in modelli a encoder come BERT sia per modelli decoder come Pixtral

Irony Detection - Confronto

Osservazioni:

- **Bias** nell'assegnare ironia o sarcasmo **superato grazie alle correlazioni**
- I prompt con **correlazioni hanno avuto risultati migliori** degli allenamenti

Prompt/Model	Experiment Type	F1 score
BERT-Vit	With Corr - Finetune	0.74
BERT-Vit	No Corr - Finetune	0.63
long_v2	With Corr - Zero Shot	0.51
long	Finetuned (all predictions)	0.41
short	With Corr - Zero Shot	0.35
long_v3	With Corr - Zero Shot	0.34
short	Finetuned (all predictions)	0.33
medium	With Corr - Zero Shot	0.26
long_v1	With Corr - Zero Shot	0.25
long_v2	No Corr - Zero Shot	0.17
long_v3	No Corr - Zero Shot	0.15
long_v1	No Corr - Zero Shot	0.13
short	No Corr - Zero Shot	0.05
medium	No Corr - Zero Shot	0.05

Relation Detection - BERT

F1 score dei Modelli BERT e Dual-Encoder sul test set multimodale

SOLO TESTO

0.61

Baseline usando solo il testo

TESTO + CORRELAZIONI

0.66

Aggiungendo le correlazioni negli input

TESTO + IMMAGINI

0.64

Sfruttando il Dual-Encoder per elaborare le immagini

TESTO + IMMAGINI + CORR.

0.69

Testo, immagini e correlazioni.

Relation Detection - Pixtral

F1 score di Pixtral sul test set multimodale

TESTO + IMMAGINI (zero-shot // three-shots)

0.39 // 0.37

Prompt longV1 zero-shot e three-shot

TESTO + IMMAGINI + CORR. (zero-shot // three-shot)

0.39 // 0.47

Prompt longV1 zero-shot e three-shot

TESTO + IMMAGINI (finetuned)

0.61

Prompt longV1

Le correlazioni si sono dimostrate estremamente efficaci nel riconoscere le relazioni e evitare Bias dovuti al three-shot.

Relation Detection - Confronto

Osservazioni:

- **Prompt lunghi** hanno **migliori** risultati
- Di nuovo **le correlazioni** si sono dimostrate **efficaci** nell'aiutare il modello a classificare correttamente

Prompt/Model	Experiment Type	F1 score
Bert/Vit	With Corr - Finetune	0.69
Bert/Vit	No Corr- Finetune	0.64
long	Finetuned (all predictions)	0.61
short	Finetuned (all predictions)	0.56
long_v3	With Corr - Zero Shot	0.52
long_v3	With Corr - **Three Shot**	0.49
long_v2	With Corr - **Three Shot**	0.48
medium	With Corr - **Three Shot**	0.48
long_v1	With Corr - **Three Shot**	0.47
medium	With Corr - Zero Shot	0.43
long_v2	No Corr - **Three Shot**	0.42
medium	No Corr - **Three Shot**	0.4
long_v1	With Corr - Zero Shot	0.39
medium	No Corr - Zero Shot	0.39
long_v3	No Corr - **Three Shot**	0.39
long_v1	No Corr - Zero Shot	0.39
short	With Corr - **Three Shot**	0.39
long_v2	With Corr - Zero Shot	0.38
long_v1	No Corr - **Three Shot**	0.37
short	With Corr - Zero Shot	0.36
short	No Corr - **Three Shot**	0.36
long_v3	No Corr - Zero Shot	0.34
long_v2	No Corr - Zero Shot	0.32
short	No Corr - Zero Shot	0.24

Conclusioni - Domande di Ricerca

1. **RQ1:** Le **immagini migliorano** sensibilmente **le prestazioni dei modelli**, tuttavia **nel caso dell'ironia** abbiamo notato che **l'aggiunta puó portare rumore nell'input degradando le performance** se non accompagnata da informazioni contestuali.
2. **RQ2:** Le **correlazioni** h**anno garantito miglioramenti costanti** in ogni task. Sfruttare queste dipendenze tra labels **ha permesso ai modelli di gestire meglio le ambiguitá** interpretative di testi e immagini.
3. **RQ3:** Le analisi hanno dimostrato che **modelli BERT specializzati superano** la potenza **degli LLM in questi task di classificazione**. Il nostro dominio dei dati, caratterizzato da **slang italiano e riferimenti ai programmi televisivi**, favorisce l'utilizzo di modelli leggeri e specializzati rispetto a modelli generativi multilingua.

Possibili futuri sviluppi

Ampliamento Dataset

Attualmente il dataset contiene solo i post derivati da **due puntate di due trasmissioni** televisive.

Per migliorare le capacità di classificazione e bilanciare le etichette è necessario aggiungere post da altri show televisivi con background differenti.

Applicazione Real-time

Applicare i modelli **durante le dirette TV** o streaming **per monitorare l'opinione pubblica in tempo reale**.

Fornire ai broadcaster feedback realistici sui contenuti e sulla qualità della regia.

Grazie per l'attenzione

UNIVERSITÀ DI TORINO

Repository github